

Project: Baseline Data Exploration | Client: Executive Board / TLC Commission
PACE Phase: Share (Data Health Translation)



Business
Context/ Contexto
de Negocio

- EN:
- The Bottom Line: Before *designing* any *algorithmic* pricing engines or *predictive models*, the infrastructure must be *audited* for *data health*. Early-stage data ingestion often conceals *logging corruption*, *duplicate rows*, and *invalid system entries* that can heavily distort future *business projections* if left *uncorrected*.
 - The Goal: Perform a complete structural inventory using *Python* to *map variable* domains, identify *column shapes*, and isolate immediate operational *anomalies* within the NYC *taxi matrix*.
- ES:
- La Conclusión: Antes de *diseñar* cualquier motor de precios *algorítmico* o *modelo predictivo*, la infraestructura debe ser *auditada* en su *salud de datos*. La ingesta de datos en etapas tempranas a menudo oculta *corrupción de registros*, *filas duplicadas* y *entradas de sistema inválidas* que pueden *distorsionar* fuertemente las proyecciones comerciales futuras si no se corrigen.
 - El Objetivo: Realizar un *inventario estructural* completo usando *Python* para mapear los dominios de las *variables*, identificar las formas de las columnas e *aislar anomalías* operativas inmediatas dentro de la *matriz de taxis* de NYC.



Statistical Inventory
& Data Health /
Inventario
Estadístico y Salud
de Datos

Metric / Métrica	Value / Valor	Technical Meaning / Significado Técnico
Total Rows / Filas Totales	~22,699	Full volume of recorded transit events. / Volumen total de viajes registrados.
Data Types / Tipos de Datos	int64, float64, object	Numeric values are clean, but chronological timestamps load as strings. / Los valores numéricos están limpios, pero las marcas de tiempo se cargan como texto.
Missing Fields / Campos Vacíos	0 (.isna().sum() == 0)	The core matrix contains zero structural voids or missing rows. / La matriz central contiene cero vacíos estructurales o filas faltantes.



Key Discoveries &
Anomalies /
Hallazgos Clave y
Anomalías

- EN:
- The Structural Skew: Using *.describe()*, data evaluation shows that *variables* like *trip_distance* and *fare_amount* are *heavily right skewed*. The vast majority of operations represent short metropolitan trips, while a small group of *long-distance* runs stretches the *maximum values*.
 - Critical Operational Anomalies: The summary *statistics* flagged systemic recording flaws: *Negative Fares*: The *minimum value* in *fare_amount* drops below zero (e.g., *negative values*), representing impossible financial charges.
 - Zero-Distance Frictions: Multiple rows show a *trip_distance* of exact *0.0 miles* but record *significant cash fares*, pointing to static waiting times or toll adjustments.
- ES:
- El Sesgo Estructural: Al usar *.describe()*, la evaluación de datos muestra que *variables* como *trip_distance* y *fare_amount* están *fuertemente sesgadas a la derecha*. La gran mayoría de las operaciones representan *viajes* metropolitanos *cortos*, mientras que un pequeño grupo de trayectos de *larga distancia* estira los *valores máximos*.
 - Anomalías Operativas Críticas: Las estadísticas de resumen alertaron sobre *fallas de registro sistémicas*:
 - Tarifas Negativas*: El *valor mínimo* en *fare_amount* cae por debajo de *cero* (*valores negativos*), representando cobros financieros imposibles.
 - Fricciones de Distancia Cero*: Múltiples filas muestran una *trip_distance* de exactamente *0.0 millas* pero registran tarifas de dinero significativas, apuntando a tiempos de espera estáticos o ajustes de peajes.



Strategic
Recommendations /
Recomendaciones
Estratégicas

- EN:
- Data Type Correction (Next Stage): *Convert time columns* (*tpep_pickup_datetime*) from text *string objects* into native *Python datetime* properties to extract duration insights.
 - Mandatory Bounding Filters: Implement strict *cleaning masks* to discard or *isolate negative* prices before passing the data to *business intelligence* tools.
 - Isolate Flat-Rate Zones: Separate *zero-distance* transactions with fixed costs to prevent them from corrupting standard metered averages.
- ES:
- Corrección de Tipos de Datos (Próxima Etapa): *Convertir* las *columnas de tiempo* (*tpep_pickup_datetime*) de objetos de *cadena de texto* a propiedades *datetime* nativas de *Python* para extraer métricas de duración.
 - Filtros de Limitación Obligatorios: Implementar *máscaras de limpieza* estrictas para descartar o *aislar* los *precios negativos* antes de transferir los datos a las herramientas de *inteligencia de negocios*.
 - Aislar Zonas de Tarifa Plana: Separar las transacciones de *distancia cero* con costos fijos para evitar que *corrompan* los promedios estándar medidos por taxímetro.

Project: Baseline Data Exploration | Client: Executive Board / TLC Commission
PACE Phase: Share (Data Health Translation)



Core Data Shape &
Structural Inventory /
Inventario Estructural
de Datos

- EN:
- The Structural Dimensions: Executing `df.shape` establishes a strict operational footprint consisting of exactly **22,699 rows** and **18 columns**.
 - Type Constraints Identification: The `.info()` structural audit reveals a mix of data frames (**float64, int64, object**). A key engineering constraint identified is that critical temporal metrics—such as `tpep_pickup_datetime` and `tpep_dropoff_datetime`—are currently loaded as generic **text objects**, confirming that a **date-time** casting phase is mandatory to unlock temporal calculations in the **dashboard layers**.
- Statistical Evidence of Contamination (`.describe()`):
- The Negative Fare Defect: Analytical queries flag a minimum value of **negative charges** (e.g., **-\$120.00** or arbitrary credit adjustments) in **fare_amount**, proving system logging errors.
 -
 - The Distance Friction: Multiple records log a **trip_distance** of **0.0 miles** alongside **non-zero** financial charges, revealing static wait times or flat-rate exceptions.
- ES:
- Las Dimensiones Estructurales: La ejecución de `df.shape` establece una huella operativa estricta que consiste exactamente en **22,699 filas** y **18 columnas**.
 - Identificación de Restricciones de Tipo: La auditoría estructural `.info()` revela una mezcla de marcos de datos (**float64, int64, object**). Una restricción de ingeniería clave identificada es que las métricas temporales críticas —como `tpep_pickup_datetime` y `tpep_dropoff_datetime`— se cargan actualmente como **objetos de texto** genéricos, confirmando que una fase de conversión a **fecha-hora** es obligatoria para de-serializar los datos y hacer cálculos temporales en las capas del **dashboard**.
- Evidencia Estadística de Contaminación (`.describe()`):
- El Defecto de Tarifa Negativa: Las consultas analíticas alertan sobre un **valor mínimo** de **cargos negativos** (ej. **-\$120.00** o ajustes arbitrarios de crédito) en **fare_amount**, demostrando errores de registro en el sistema.
 - La Fricción de Distancia: Múltiples registros asientan una **trip_distance** de **0.0 millas** junto a cobros financieros significativos, revelando tiempos de espera estáticos o excepciones de tarifa plana.