

Executive & Technical Report: NYC Taxi Dataset Profiling & Initial EDA

Informe Ejecutivo y Técnico: Perfilado de Datos de Taxis en NYC y EDA Inicial

Project: Baseline Data Exploration | Client: Executive Board / TLC Commission
PACE Phase: Share (Data Health Translation)



Business Context/ Contexto de Negocio

- EN:
- The Bottom Line: Before designing any algorithmic pricing engines or predictive models, the infrastructure must be audited for data health. Early-stage data ingestion often conceals logging corruption, duplicate rows, and invalid system entries that can heavily distort future business projections if left uncorrected.
 - The Goal: Perform a complete structural inventory using Python to map variable domains, identify column shapes, and isolate immediate operational anomalies within the NYC taxi matrix.

- ES:
- La Conclusión: Antes de diseñar cualquier motor de precios algorítmico o modelo predictivo, la infraestructura debe ser auditada en su salud de datos. La ingesta de datos en etapas tempranas a menudo oculta corrupción de registros, filas duplicadas y entradas de sistema inválidas que pueden distorsionar fuertemente las proyecciones comerciales futuras si no se corrigen.
 - El Objetivo: Realizar un inventario estructural completo usando Python para mapear los dominios de las variables, identificar las formas de las columnas e aislar anomalías operativas inmediatas dentro de la matriz de taxis de NYC.



Statistical Inventory & Data Health / Inventario Estadístico y Salud de Datos

Metric / Métrica	Value / Valor	Technical Meaning / Significado Técnico
Total Rows / Filas Totales	~22,699	Full volume of recorded transit events. / Volumen total de viajes registrados.
Data Types / Tipos de Datos	int64, float64, object	Numeric values are clean, but chronological timestamps load as strings. / Los valores numéricos están limpios, pero las marcas de tiempo se cargan como texto.
Missing Fields / Campos Vacíos	0 (.isna().sum() == 0)	The core matrix contains zero structural voids or missing rows. / La matriz central contiene cero vacíos estructurales o filas faltantes.



Key Discoveries & Anomalies / Hallazgos Clave y Anomalías

- EN:
- The Structural Skew: Using `.describe()`, data evaluation shows that variables like `trip_distance` and `fare_amount` are heavily *right-skewed*. The vast majority of operations represent short metropolitan trips, while a small group of *long-distance* runs stretches the maximum values.
 - Critical Operational Anomalies: The summary statistics flagged systemic recording flaws:
 - Negative Fares: The *minimum value* in `fare_amount` drops below *zero* (e.g., *negative values*), representing impossible *financial charges*.
 - Zero-Distance Frictions: Multiple rows show a `trip_distance` of exact *0.0 miles* but record significant cash fares, pointing to static waiting times or toll adjustments.

- ES:
- El Sesgo Estructural: Al usar `.describe()`, la evaluación de datos muestra que variables como `trip_distance` y `fare_amount` están fuertemente *sesgadas a la derecha*. La gran mayoría de las operaciones representan *viajes metropolitanos cortos*, mientras que un pequeño grupo de trayectos de *larga distancia* estira los *valores máximos*.
 - Anomalías Operativas Críticas: Las estadísticas de resumen alertaron sobre fallas de registro sistémicas:
 - Tarifas Negativas: El valor mínimo en `fare_amount` cae por debajo de *cero* (*valores negativos*), representando cobros financieros imposibles.
 - Fricciones de Distancia Cero: Múltiples filas muestran una `trip_distance` de exactamente *0.0 millas* pero registran tarifas de dinero significativas, apuntando a tiempos de espera estáticos o ajustes de peajes.



Strategic Recommendations / Recomendaciones Estratégicas

- EN:
- Data Type Correction (Next Stage): Convert time *columns* (`tpep_pickup_datetime`) from text *string objects* into native Python *datetime* properties to extract duration insights.
 - Mandatory Bounding Filters: Implement strict *cleaning* masks to discard or *isolate negative* prices before passing the data to *business intelligence* tools.
 - Isolate Flat-Rate Zones: Separate *zero-distance* transactions with fixed costs to prevent them from corrupting standard metered *averages*.

- ES:
- Corrección de *Tipos de Datos* (Próxima Etapa): *Convertir* las *columnas* de *tiempo* (`tpep_pickup_datetime`) de objetos de cadena de texto a propiedades *datetime* nativas de Python para extraer métricas de duración.
 - Filtros de Limitación Obligatorios: Implementar *máscaras* de *limpieza* estrictas para descartar o aislar los *precios negativos* antes de transferir los datos a las herramientas de *inteligencia de negocios*.
 - Aislar Zonas de Tarifa Plana: Separar las transacciones de *distancia cero* con costos fijos para evitar que *corrompan* los *promedios* estándar medidos por taxímetro.

Executive & Technical Report: NYC Taxi Fare Optimization & OLS Validation

Informe Ejecutivo y Técnico: Optimización de Tarifas de Taxi en NYC y Validación OLS

Project: Operational Pricing Optimization Framework | Client: Executive Board | TLC Commission | [PACE](#)
Phase: Analyze & Execute (Technical Validation)



Exploratory Data Analysis (EDA) / Análisis Exploratorio de Datos (EDA)

```
=== DATASET SHAPE ===
(22699, 18)

=== DATASET INFO ===
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 22699 entries, 0 to 22698
Data columns (total 18 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Unnamed: 0             22699 non-null  int64
1   VendorID               22699 non-null  int64
2   tpep_pickup_datetime   22699 non-null  object
3   tpep_dropoff_datetime  22699 non-null  object
4   passenger_count        22699 non-null  int64
5   trip_distance          22699 non-null  float64
6   RatecodeID             22699 non-null  int64
7   store_and_fwd_flag     22699 non-null  object
8   PULocationID           22699 non-null  int64
9   DOLocationID           22699 non-null  int64
10  payment_type            22699 non-null  int64
11  fare_amount            22699 non-null  float64
12  extra                  22699 non-null  float64
13  mta_tax                22699 non-null  float64
14  tip_amount             22699 non-null  float64
15  tolls_amount           22699 non-null  float64
16  improvement_surcharge  22699 non-null  float64
17  total_amount           22699 non-null  float64
dtypes: float64(8), int64(7), object(3)
memory usage: 3.1+ MB
```



Data Completeness & Integrity / Compleitud e Integridad de los Datos

```
=== MISSING VALUES PER COLUMN ===
Unnamed: 0      0
VendorID        0
tpep_pickup_datetime  0
tpep_dropoff_datetime  0
passenger_count  0
trip_distance    0
RatecodeID       0
store_and_fwd_flag  0
PULocationID     0
DOLocationID     0
payment_type     0
fare_amount      0
extra            0
mta_tax          0
tip_amount       0
tolls_amount     0
improvement_surcharge  0
total_amount     0
dtype: int64

=== DUPLICATE ROWS COUNT ===
0
```

- EN:
- Dataset Audit: Comprehensive exploration of the NYC TLC dataset—consisting of **22,699 unique trip entries** and **18 data columns**—to isolate systemic structural anomalies before statistical modeling.
 - Structural Anomalies Discovered: Data profiling successfully exposed structural data types requiring alignment (such as datetime entries incorrectly logged as generic *object types*) and flagged critical fields prone to extreme outliers, such as *zero-distance* trips (*trip_distance*) paired with inflated fare amounts (*fare_amount*).
 - Missing Data & Duplicates Inspection: Verified exact non-null consistency across all **18 variables**; while traditional missing values were absent, strategic exploration revealed hidden mathematical noise, specifically the cash-tip blindspot where cash transactions record a standard **\$0.0 value** in the *tip_amount* field.
- ES:
- Auditoría del Conjunto de Datos: Exploración exhaustiva del dataset de la **TLC de NYC**—compuesto por **22,699** registros de viaje únicos y **18 columnas** de datos—para aislar anomalías estructurales sistémicas antes del modelado estadístico.
 - Anomalías Estructurales Descubiertas: El perfilado de datos expuso tipos de datos estructurales que requerían alineación (como marcas de tiempo registradas incorrectamente como tipo genérico *object*) y detectó campos críticos propensos a valores atípicos extremos, como viajes de distancia cero (*trip_distance*) emparejados con tarifas infladas (*fare_amount*).
 - Inspección de Datos Faltantes y Duplicados: Se verificó una consistencia estricta de valores no nulos a través de las **18 variables**; aunque no hubo valores faltantes tradicionales, la exploración estratégica reveló ruido matemático oculto, específicamente el punto ciego de las propinas en efectivo donde las transacciones en efectivo registran un valor estándar de **\$0.0** en el campo *tip_amount*.

- EN:
- Zero Structural Missing Data: The execution of `df0.isna().sum()` confirms that there are absolutely zero standard null or missing values (*NaN*) across all **18 columns** of the dataset. Every single one of the **22,699 rows** contains fully populated metadata.
 - Absolute Row Uniqueness: The `df0.duplicated().sum()` check returned a count of exactly 0. This eliminates any risk of statistical inflation, confirming that there are no redundant or cloned trip entries destabilizing the target distributions.
 - The “Hidden Noise” Caveat: While the dataset is structurally pristine (*no technical nulls*), this validation reinforces that the cash-tip blindspot is a logical anomaly, not a structural missing value. The **\$0.0 records** in *tip_amount* for cash transactions are processed by Pandas as valid numeric values, requiring domain-knowledge filtering rather than standard drop-null functions.
- ES:
- Cero Datos Faltantes Estructurales: La ejecución de `df0.isna().sum()` confirma que existen exactamente cero valores nulos o faltantes estándar (*NaN*) a lo largo de las **18 columnas** del dataset. Cada una de las **22,699** filas contiene metadatos completamente poblados.
 - Unicidad Absoluta de Filas: La verificación `df0.duplicated().sum()` arrojó un conteo de exactamente 0. Esto elimina cualquier riesgo de inflación estadística, confirmando que no existen registros de viaje redundantes o clonados desestabilizando las distribuciones objetivo.
 - La Advertencia del “Ruido Oculto”: Aunque el dataset está estructuralmente prístino (sin nulos técnicos), esta validación refuerza que el punto ciego de las propinas en efectivo es una anomalía lógica, no un valor faltante estructural. Los registros de **\$0.0** en *tip_amount* para transacciones en efectivo son procesados por *Pandas* como valores numéricos válidos, requiriendo un filtrado por conocimiento de negocio en lugar de funciones estándar de eliminación de nulos.

Executive & Technical Report: NYC Taxi Fare Optimization & OLS Validation

Informe Ejecutivo y Técnico: Optimización de Tarifas de Taxi en NYC y Validación OLS

Project: Operational Pricing Optimization Framework | Client: Executive Board | TLC Commission | **P**ACE
Phase: Analyze & Execute (Technical Validation)



Key Statistical Insights / Hallazgos Estadísticos Clave

=== ESTADÍSTICAS CRÍTICAS SELECCIONADAS (HALLAZGOS DE EDA) ===				
	trip_distance	fare_amount	tip_amount	total_amount
count	22699.000000	22699.000000	22699.000000	22699.000000
mean	2.913313	13.026629	1.835781	16.310502
std	3.653171	13.243791	2.800626	16.097295
min	0.000000	-120.000000	0.000000	-120.300000
25%	0.990000	6.500000	0.000000	8.750000
50%	1.610000	9.500000	1.350000	11.800000
75%	3.060000	14.500000	2.450000	17.800000
max	33.960000	999.990000	200.000000	1200.290000

ES:

- Valores Atípicos Operativos Críticos: Las métricas mínimas (min) exponen una severa corrupción de telemetría, evidenciando estados operativos inválidos como transacciones financieras negativas que caen a **-\$120.00** en **fare_amount** y **-\$120.30** en **total_amount**. Estos registros deben ser filtrados sistemáticamente antes del entrenamiento.
- Variaciones de Ingresos Extremas: Mientras que el viaje estándar de la ciudad está altamente localizado demostrado por una distancia mediana (50%) de solo **1.61 millas** y una tarifa base mediana de **\$9.50**, los límites superiores revelan picos masivos, incluyendo un máximo **\$999.99** en tarifa base y una propina aislada por tarjeta de crédito de **\$200.00**.
- La Paradoja de la Telemetría: Los datos exponen una contradicción estructural donde el valor mínimo de **trip_distance** es exactamente **0.00 millas**, pero coexiste con estructuras de precios positivas de hasta un monto máximo de **\$1,200.29**. Esto confirma que los taxímetros registran tarifas altas durante embotellamientos estáticos, haciendo obligatorio el desarrollo de ingeniería de variables basadas en tiempo.

EN:

- Critical Operational Outliers: The minimum (min) metrics expose severe telemetry corruption, highlighting invalid operational states such as negative financial transactions reaching **-\$120.00** in **fare_amount** and **-\$120.30** in **total_amount**. These records must be systematically filtered prior to model training.
- Extreme Revenue Variances: While the standard city ride is highly localized—proven by a median distance (50%) of just **1.61 miles** and a median baseline fare of \$9.50—the upper distribution limits reveal massive spikes, including a single-trip peak of **\$999.99** in base fare and an isolated credit card tip of \$200.00.
- The Telemetry Paradox: The data exposes a structural contradiction where the minimum value for **trip_distance** is exactly **0.00 miles**, yet it coexists with positive pricing structures up to a maximum total allocation of **\$1,200.29**. This confirms that taximeters continuously log high fares during static gridlocks, mandating route-duration feature engineering.

Executive & Technical Report: NYC Taxi Fare Optimization & OLS Validation

Informe Ejecutivo y Técnico: Optimización de Tarifas de Taxi en NYC y Validación OLS

Project: Operational Pricing Optimization Framework | Client: Executive Board | TLC Commission | PACE
Phase: Analyze & Execute (Technical Validation)



Feature Engineering:
Dynamic Duration
Extraction / Ingeniería de
Variables: Extracción
Dinámica de Duración

- EN:
- Temporal Parsing Strategy: Converted metadata fields (*tpep_pickup_datetime* and *tpep_dropoff_datetime*) from generic *string* objects to native *datetime64[ns]* types. This structural upgrade eliminates parsing frictions across the data pipeline.
 - Dynamic Feature Construction: Subtracted raw timestamps to engineer the core duration column in continuous minutes (*.dt.total_seconds() / 60*). As proven in image, this unlocks high-precision granularity for trip profiles.
 - Quantifying Traffic Latency: This advanced extraction transforms static text into an operational proxy for *traffic* gridlocks. It successfully resolves the Telemetry Paradox (high fares with zero physical movement), allowing the model to isolate geographic distance from temporal delays to stabilize upfront pricing

```
=== DATA TYPES BEFORE CONVERSION ===
tpep_pickup_datetime    object
tpep_dropoff_datetime   object
dtype: object

=== SAMPLE DATA BEFORE CONVERSION ===
   tpep_pickup_datetime tpep_dropoff_datetime
0 03/25/2017 8:55:43 AM 03/25/2017 9:09:47 AM
1 04/11/2017 2:53:28 PM 04/11/2017 3:19:58 PM
2 12/15/2017 7:26:56 AM 12/15/2017 7:34:08 AM
```

```
=== DATA TYPES AFTER CONVERSION ===
tpep_pickup_datetime    datetime64[ns]
tpep_dropoff_datetime   datetime64[ns]
dtype: object
```

	tpep_pickup_datetime	tpep_dropoff_datetime	duration
0	2017-03-25 08:55:43	2017-03-25 09:09:47	14.066667
1	2017-04-11 14:53:28	2017-04-11 15:19:58	26.500000
2	2017-12-15 07:26:56	2017-12-15 07:34:08	7.200000
3	2017-05-07 13:17:59	2017-05-07 13:48:14	30.250000
4	2017-04-15 23:32:20	2017-04-15 23:49:03	16.716667

- ES:
- Estrategia de Lectura Temporal: Conversión de los metadatos (*tpep_pickup_datetime* y *tpep_dropoff_datetime*) de objetos *string* genéricos a tipos nativos *datetime64[ns]*. Esta actualización estructural elimina las fricciones de lectura en el pipeline de datos.
 - Construcción Dinámica de Variables: Resta programática de las marcas de tiempo para construir la variable central *duration* en minutos continuos (*.dt.total_seconds() / 60*). Como lo demuestra la imagen, esto habilita una granularidad de alta precisión para los perfiles de viaje.
 - Cuantificación de Latencia por *Tráfico*: Esta extracción avanzada transforma texto estático en un indicador operativo de los *embotellamientos urbanos*. Resuelve con éxito la Paradoja de la Telemetría (tarifas altas con cero movimiento físico), permitiendo al modelo aislar la distancia geográfica de los retrasos temporales para estabilizar los precios iniciales.

Executive & Technical Report: NYC Taxi Fare Optimization & OLS Validation

Informe Ejecutivo y Técnico: Optimización de Tarifas de Taxi en NYC y Validación OLS




Project: Operational Pricing Optimization Framework | Client: Executive Board | TLC Commission | PACE

Phase: Analyze & Construct. (Technical Validation)



Outlier Diagnostics & Operational Anomalies /
Diagnóstico de Atípicos y Anomalías Operativas

- EN:
- Distribution Concentration: The *box plots* confirm that the vast majority of *New York City* trips are highly concentrated at the lower spectrum. For instance, the bulk of rides span *under 5 miles* in physical distance and settle below *30 minutes* in operational duration.
 - Severe Revenue Distortion: The *fare_amount* and duration plots expose extreme, isolated points acting as major mathematical *outliers*. We catch single trips spiking up to *\$1,000* in baseline cost and duration records stretching to nearly *1,400 minutes* (equivalent to a taxi running non-stop for 24 hours).
 - The Case for Robust Pruning: These extreme *right-skewed* tails represent rare operational *edge cases*, *data corruption*, or *fixed airport anomalies*. Retaining them without strategic clipping heavily penalizes a standard Ordinary *Least Squares (OLS) model*, proving why an upgrade to tree-based ensembles is statistically mandatory.



- ES:
- Concentración de la Distribución: Los *gráficos de caja* confirman que la gran mayoría de los viajes en *Nueva York* están altamente concentrados en el *espectro inferior*. El grueso de los trayectos se mantiene por debajo de las *5 millas* de distancia física y bajo los *30 minutos* de duración operativa.
 - Distorsión Extrema de Ingresos: Los gráficos de *fare_amount* y *duration* exponen puntos aislados extremos que actúan como severos *atípicos* matemáticos. Detectamos viajes individuales disparándose hasta los *\$1,000* en tarifa base y registros de duración que rozan los *1,400 minutos* (el equivalente a un taxi corriendo sin parar por *24 horas*).
 - Justificación de Depuración Robusta: Estas *colas extremadamente sesgadas a la derecha* representan casos extremos de la *operación*, *corrupción de telemetría* o *anomalías de tarifas planas* de aeropuertos. Mantenerlos sin un recorte estratégico penaliza fuertemente a un *modelo lineal estándar (OLS)*, demostrando por qué una actualización a ensambles basados en árboles es estadísticamente obligatoria.

Executive & Technical Report: NYC Taxi Fare Optimization & OLS Validation

Informe Ejecutivo y Técnico: Optimización de Tarifas de Taxi en NYC y Validación OLS

Project: Operational Pricing Optimization Framework | Client: Executive Board | TLC Commission | PACE

Phase: Analyze & Construct. (Technical Validation)



Quantification of
Telemetry Anomalies /
Cuantificación de
Anomalías de Telemetría

trip_distance	fare_amount (Distribution)	Count / Conteo	% of Dataset	Operational Meaning / Significado Operativo
0.00 mi	-\$2.50 a \$3.00 (Min to 50%)	Subconjunto	-	Standard Base / Cancelaciones y Reversiones
0.00 mi	Hasta \$450.00 (Max)	Subconjunto	-	Telemetry Failure / Falla Crítica de Telemetría
Total Target	Mean: \$23.13	148 rows	0.65%	Flagged for Removal / Marcados para Eliminación

- The Zero-Distance Revenue Inconsistency: A targeted subset analysis isolated 148 records where the physical displacement was registered as exactly \$0.00 miles. Crucially, these entries are not financially neutral; they capture a wide variance in billing, ranging from negative adjustments and the standard \$2.50 initial drop fare up to extreme anomalies of \$450.00.
 - Actionable Data Pruning: While a \$2.50 charge with zero distance represents an operational reality, a \$450.00 fare with zero miles confirms severe telemetry bypass. Since these anomalies constitute a marginal 0.65% of our data population, their systematic elimination is highly recommended to protect the Ordinary Least Squares (OLS) framework from artificial variance without compromising sample representativeness.
- Inconsistencia de Ingresos en Distancia Cero: Un análisis de subconjunto dirigido aisló 148 registros donde el desplazamiento físico se registró exactamente en 0.00 millas. Crucialmente, estas entradas no son financieramente neutrales; capturan una amplia varianza en la facturación, que va desde ajustes negativos y la tarifa inicial estándar de \$2.50 hasta anomalías extremas de \$450.00.
 - Depuración de Datos Accionable: Mientras que un cobro de \$2.50 con distancia cero representa una realidad operativa, una tarifa de \$450.00 con cero millas confirma una falla grave de telemetría. Dado que estas anomalías constituyen un marginal 0.65% de la población de datos, su eliminación sistemática es altamente recomendada para proteger el marco de Mínimos Cuadrados Ordinarios (OLS) de varianzas artificiales sin comprometer la representatividad de la muestra.

Executive & Technical Report: NYC Taxi Fare Optimization & OLS Validation

Informe Ejecutivo y Técnico: Optimización de Tarifas de Taxi en NYC y Validación OLS

Project: Operational Pricing Optimization Framework | Client: Executive Board | TLC Commission | PACE

Phase: Construct (Data Engineering & Feature Stabilization)



Data Stabilization &
Imputation Pipeline /

Estabilización de Datos y
Pipeline de Imputación

Target Metric / Variable	Imputation Rule / Regla de Imputación	Boundary Cap / Tope de Umbral	Operational Context / Contexto Operativo
fare_amount (Lower Bound)	Logical Mask (df0 < 0)	\$0.00 Minimum	Corrige estados financieros inválidos y reversiones manuales defectuosas.
trip_distance (Upper Bound)	Adaptive Winsorization (Q3 + 6*IQR)	15.48 miles Max	Controla el sesgo por atípicos de rutas espaciales extremadamente largas.
fare_amount (Upper Bound)	Adaptive Winsorization (Q3 + 6*IQR)	\$62.50 Max	Mitiga picos inflados de tarifas y distorsiones de cobro en el backend.
duration (Upper Bound)	Adaptive Winsorization (Q3 + 6*IQR)	88.78 minutes Max	Neutraliza registros de congestión estática extrema y errores de telemetría.

- EN:

 - Negative Revenue Correction: Data profiling exposed severe telemetry corruption where fare_amount values dropped below zero, reaching a minimum of **-\$120.00** or presenting negative cancellation artifacts like **-\$2.50**. Implemented a strict logical mask `df0.loc[df0['fare_amount'] < 0, 'fare_amount'] = 0.0` to force-align these invalid entries to a stabilized baseline of **\$0.00**, safeguarding accounting integrity before modeling.
 - Adaptive **Winsorization** Framework: To mitigate **right-skewed distortion** without compromising sample size, an automated mathematical pruning function (`impute_outliers`) was deployed using an expanded Interquartile Range rule (**Q3+6*IQR**). Extreme upper outliers were capped directly at their calculated operational thresholds: **15.48 miles** for spatial length, **\$62.50** for base cost, and **88.78 minutes** for temporal duration, drastically reducing residual variance to optimize the **Ordinary Least Squares (OLS)** framework.
- ES:

 - Corrección de Ingresos Negativos: El perfilado de datos expuso una severa corrupción de telemetría donde los valores de **fare_amount** caían por debajo de cero, alcanzando un mínimo de **-\$120.00** o presentando artefactos de cancelación negativos de **-\$2.50**. Se implementó una máscara lógica estricta `df0.loc[df0['fare_amount'] < 0, 'fare_amount'] = 0.0` para alinear a la fuerza estos registros inválidos a una línea base estabilizada de **\$0.00**, resguardando la integridad contable antes del modelado.
 - Marco de **Winsorización** Adaptativa: Para mitigar la distorsión del **sesgo a la derecha** sin comprometer el tamaño de la muestra, se desplegó una función de recorte matemático automatizada (`impute_outliers`) utilizando una regla de Rango Intercuartílico extendida (**Q3+6*IQR**). Los valores atípicos superiores extremos se limitaron directamente en sus umbrales operativos calculados: **15.48 millas** para la longitud espacial, **\$62.50** para el costo base y **88.78 minutos** para la duración temporal, reduciendo drásticamente la varianza de los residuos para optimizar el modelo de **Mínimos Cuadrados Ordinarios (OLS)**.

Executive & Technical Report: NYC Taxi Fare Optimization & OLS Validation

Informe Ejecutivo y Técnico: Optimización de Tarifas de Taxi en NYC y Validación OLS

Project: Operational Pricing Optimization Framework | Client: Executive Board | TLC Commission | PACE

Phase: Construct (Feature Engineering & Spatial Mapping)



Feature Engineering:
Spatial & Temporal Route
Aggregation / Ingeniería
de Variables: Agregación
Espacial y Temporal de
Rutas

Unique Transit Corridor / Corredor Único	Feature Engineered / Variable Creada	Historical Baseline / Línea Base Mapeada	Data Pipeline Status / Estado del Pipeline
Route Identity: 100 -> 231	mean_distance	3.52 miles	Verification Passed: 0 NaN values / Integridad Confirmada
Route Identity: 100 -> 231	mean_duration	22.84 minutes	Verification Passed: 0 NaN values / Integridad Confirmada
Route Identity: 186 -> 43	mean_distance	3.10 miles	Verification Passed: 0 NaN values / Integridad Confirmada
Route Identity: 186 -> 43	mean_duration	24.47 minutes	Verification Passed: 0 NaN values / Integridad Confirmada

EN:

- Algorithmic Mapping of Transit Corridors: Deployed an advanced data transformation layout to *map spatial relationships* across NYC Boroughs by grouping trip records by exact pickup (*PULocationID*) and dropoff (*DOLocationID*) matrices. This operational alignment extracts the structural historical mean for travel distances (*mean_distance*), successfully generating a high-velocity dictionary proxy for upfront passenger routing estimates.
- Bypassing Real-Time Telemetry Friction: By capturing the mathematical expected value of each unique geographic corridor, the *engineering backend* establishes an algorithmic safety net. If an active vehicle experiences *real-time GPS* signal degradation or logs a zero-displacement anomaly, the *Ordinary Least Squares (OLS)* framework can dynamically reference historical route footprints, effectively preventing upfront pricing variance and ensuring severe revenue protection.
- Dual-Variable Convergence & *Null Verification*: Expanded the mapping pipeline to concurrently engineer the *mean_duration metric* by unique transit pairs. Terminal testing confirms absolute data pipeline integrity with exactly *0 NaN values* generated across both engineered features, successfully establishing a non-volatile spatial-temporal baseline matrix ready for *Ordinary Least Squares (OLS)* estimation.

ES:

- Mapeo Algorítmico de Corredores de Tránsito: Se desplegó un esquema avanzado de transformación de datos para *mapear las relaciones espaciales* a través de los distritos de NYC, agrupando los registros de viaje mediante matrices exactas de origen (*PULocationID*) y destino (*DOLocationID*). Esta alineación operativa extrae la media histórica estructural de las distancias de viaje (*mean_distance*), generando con éxito un diccionario indicador de alta velocidad para las estimaciones iniciales de rutas de los pasajeros.
- Mitigación de la Fricción de Telemetría en Tiempo Real: Al capturar el valor matemático esperado de cada corredor geográfico único, el backend de ingeniería establece una red de seguridad algorítmica. Si un vehículo activo experimenta una degradación de la señal *GPS en tiempo real* o registra una anomalía de desplazamiento cero, el modelo de *Mínimos Cuadrados Ordinarios (OLS)* puede referenciar dinámicamente la huella histórica de la ruta, previniendo eficazmente la varianza en los precios iniciales y asegurando una sólida protección de ingresos.
- Convergencia de Variable Dual y *Verificación de Nulos*: Se expandió el pipeline de mapeo para construir simultáneamente la *métrica mean_duration* por pares de tránsito únicos. Las pruebas de terminal confirman la integridad absoluta del pipeline de datos con exactamente *0 valores nulos* (NaN) generados en ambas variables calculadas, estableciendo con éxito una matriz de línea base espacio-temporal no volátil lista para la estimación de *Mínimos Cuadrados Ordinarios (OLS)*.

Executive & Technical Report: NYC Taxi Fare Optimization & OLS Validation

Informe Ejecutivo y Técnico: Optimización de Tarifas de Taxi en NYC y Validación OLS

Project: Operational Pricing Optimization Framework | Client: Executive Board | TLC Commission | PACE

Phase: Construct (Feature Engineering & Spatial Mapping)



Temporal Feature Engineering & Demand Peak Encoding / Ingeniería de Variables Temporales y Codificación de Picos de Demanda

Engineered Feature / Variable Creada	Data Type / Tipo	Logic Source / Origen Lógico	Operational Objective / Objetivo Operativo
day / month	Categorical (String)	tpep_pickup_datetime	Captura la estacionalidad semanal y mensual de la
am_rush / pm_rush	Binary (0 / 1)	Hour Windows (7-10 / 16-20)	Aísla los bloques oficiales de congestión matutina y
rush_hour	Binary (0 / 1)	Surcharge Windows & Weekdays	Identifica ventanas comerciales sujetas a recargos tarifarios por la TLC.

- EN:
 - Chronological Extraction & Seasonality Mapping: Deployed a datetime decomposition pipeline onto the `tpep_pickup_datetime` series to extract granular calendar dimensions, mapping operational cycles across specific *months and weekdays (day)*. This conversion captures localized demand elasticity and macro-seasonal shifts across the NYC transit network.
 - Algorithmic Rush-Hour Indicators: Engineered a matrix of deterministic binary proxies (`rush_hour`, `am_rush`, `pm_rush`) synchronized with the TLC official peak-congestion surcharge windows (*07:00–10:00 and 16:00–20:00 on weekdays*). By isolating these high-traffic temporal intervals from weekend patterns, the dataset provides the *Ordinary Least Squares (OLS)* framework with strict linear structures to isolate and evaluate the economic weight of regulatory pricing surcharges.
- ES:
 - Extracción Cronológica y Mapeo de Estacionalidad: Se desplegó un *pipeline* de descomposición sobre la *serie tpep_pickup_datetime* para extraer dimensiones calendáricas granulares, mapeando los ciclos operativos a través de meses específicos y *días de la semana (day)*. Esta conversión captura la elasticidad de la demanda localizada y los cambios macroestacionales en la red de tránsito de NYC.
 - Indicadores Algorítmicos de *Hora Punta*: Se construyó una matriz de *variables binarias* deterministas (`rush_hour`, `am_rush`, `pm_rush`) sincronizadas con las ventanas oficiales de recargo por congestión de la TLC (*07:00–10:00 y 16:00–20:00 en días hábiles*). Al aislar estos intervalos temporales de alto tráfico de los patrones de fin de semana, el conjunto de datos proporciona al modelo de *Minimos Cuadrados Ordinarios (OLS)* estructuras lineales estrictas para aislar y evaluar el peso económico de los recargos regulatorios.

- EN:
 - Chronological Extraction & Seasonality Mapping: *Datetime* decomposition captures predictable behavioral cycles across NYC. Descriptive analysis isolates Thursday and Friday as pricing *peaks (\$15.29 and \$15.17 respectively)*, validating higher commercial friction prior to weekends.
 - Empirical Rush-Hour Validation: Isolating temporal blocks via binary encoding reveals an empirical upward displacement, with congestion intervals commanding a *\$15.22 mean fare* against the *\$14.77 off-peak baseline*. This variation justifies the OLS inclusion of a centralized `rush_hour` vector to capture regulatory pricing matrices

Engineered Feature / Variable	Temporal	Logical Rule / Ventana Horaria	Observed Mean Fare / Tarifa Promedio	Operational/Business Insight
thursday / Friday (Weekly Peaks)	Weekly	Thursday & Friday Records	\$15.29 / \$15.17	Picos semanales de recaudación asociados a alta demanda corporativa y social.
rush_hour = 1 (Active Congestion)	Weekdays: 07:00-10:00 & 16:00-20:00		\$15.22	Refleja el impacto directo del tráfico y los recargos institucionales de la TLC.
rush_hour = 0 (Off-Peak Base)	Weekends & Off-Hour Windows		\$14.77	Línea base operativa estable con menor fricción de tránsito en los distritos.
sunday (Weekly Baseline)	Sunday Records		\$14.46	Punto mínimo de tarifas promedio debido a flujos de tránsito libres y recreativos.

- ES:
 - Extracción Cronológica y Mapeo de Estacionalidad: La descomposición de *fechas* captura ciclos de comportamiento predecibles en NYC. El análisis descriptivo aísla los jueves y viernes como *picos de tarifas (\$15.29 y \$15.17 respectivamente)*, validando una mayor fricción comercial antes del fin de semana.
 - Validación Empírica de Hora Punta: El aislamiento de bloques temporales mediante codificación binaria revela un desplazamiento empírico al alza, con intervalos de congestión registrando una tarifa *promedio de \$15.22* frente a la *línea base de \$14.77 fuera de hora punta*. Esta variación justifica la inclusión en el modelo OLS de un vector `rush_hour` centralizado para capturar las matrices de recargos regulatorios.

Executive & Technical Report: NYC Taxi Fare Optimization & OLS Validation

Informe Ejecutivo y Técnico: Optimización de Tarifas de Taxi en NYC y Validación OLS

Project: Operational Pricing Optimization Framework | Client: Executive Board | TLC Commission | PACE

Phase: Construct (Feature Engineering & Spatial Mapping)



Visual Validation:
Linearity & Outlier Cap
Verification / Validación
Visual: Linealidad y
Verificación de Topes de
Atípicos



EN:

- Empirical Verification of Linearity: The *scatterplot* demonstrates a robust, well-distributed linear correlation between the engineered variable *mean_duration* and the target metric *fare_amount*. By plotting historically aggregated durations instead of volatile, *single-trip GPS records*, the system establishes a highly predictive, *low-noise* linear trend ideal for *Ordinary Least Squares (OLS)* estimation.
- Visual Confirmation of the Imputation Caps: The dense horizontal boundary visible at the *\$62.50* threshold mathematically validates the execution of the *adaptive Winsorization pipeline*. Extreme, revenue-distorting pricing anomalies have been successfully capped and compressed into stable operational limits, preventing residual variance from biasing the final model coefficients.

ES:

- Verificación Empírica de Linealidad: El *gráfico de dispersión* demuestra una correlación lineal robusta y bien distribuida entre la variable optimizada *mean_duration* y la métrica objetivo *fare_amount*. Al graficar duraciones históricas agregadas en lugar de *registros GPS volátiles* de un solo viaje, el sistema establece una tendencia lineal altamente predictiva y de bajo ruido, ideal para la estimación de *Minimos Cuadrados Ordinarios (OLS)*.
- Confirmación Visual de los Topes de Imputación: El límite horizontal denso visible en el umbral de *\$62.50* valida matemáticamente la ejecución del pipeline de *Winsorización adaptativa*. Las anomalías de precios extremas que distorsionaban los ingresos se han limitado y comprimido con éxito dentro de límites operativos estables, evitando que la varianza de los residuos sesgue los coeficientes del modelo final.

Metric / Métrica (JFK Subset)	Observed Value / Valor Observado	Statistical Meaning / Significado Estadístico
Total Trips Isolated / Total de Viajes Aislados.	514 Records / Registros	Volumen de transiciones fijadas en la tarifa plana de \$52.00.
Minimum Distance / Mínima Distancia	0.00 miles / Millas	Demuestra cobros de tarifa plana en cancelaciones o movimientos de rampa.
Maximum Duration / Máxima Duración	88.78 minutes / Minutos	Evidencia congestión vial extrema que no altera el costo final regulado.

EN:

- Deep-dive column profiling on the secondary horizontal accumulation line at *\$52.00* confirms an institutional data pattern rather than telemetry noise. The subset isolation enforces a consistent *RatecodeID = 2* paired with *location matrix 132*, mapping directly to the official *NYC TLC JFK International Airport Flat-Fare regulation*. This validates why high temporal or spatial variances (*ranging from short delays to long highway transits*) converge on an identical fixed price, justifying our route-mean feature engineering to prevent this regulatory artifact from warping *OLS slope coefficients*.

ES:

El perfilado profundo de columnas sobre la segunda línea de acumulación horizontal en *\$52.00* confirma un patrón de datos institucional en lugar de ruido de telemetría. El aislamiento del subconjunto presenta un *RatecodeID = 2* consistente emparejado con la matriz de ubicación 132, mapeando directamente con la regulación oficial de *Tarifa Plana del Aeropuerto Internacional JFK* de la TLC de NYC. Esto valida por qué variaciones temporales o espaciales extremas convergen en un precio fijo idéntico, justificando nuestra ingeniería de variables por rutas para evitar que este artefacto regulatorio altere los coeficientes de inclinación del *modelo OLS*.

Executive & Technical Report: NYC Taxi Fare Optimization & OLS Validation


Informe Ejecutivo y Técnico: Optimización de Tarifas de Taxi en NYC y Validación OLS

Project: Operational Pricing Optimization Framework | Client: Executive Board | TLC Commission | PACE

Phase: Construct (Feature Engineering & Spatial Mapping)



Multivariate Pair-Plot
Diagnostics & Linearity
Verification / Diagnóstico
de Pares Multivariados y
Verificación de Linealidad



Variable Interaction / Interacción	Observed Pattern / Patrón	Statistical Purpose / Objetivo Estadístico	Operational Meaning / Lectura de Negocio
fare_amount vs. Predictors	Positive Linear Trend	Confirma el supuesto de linealidad para OLS.	La distancia y el tiempo conducen el precio de forma sincronizada.
mean_duration vs. mean_distance	High Linear Correlation	Alerta de multicolinealidad estructural.	El tráfico y el recorrido comparten varianza; el modelo debe sopesar ambos en conjunto.
Data Boundaries (All Plots)	Truncated Upper Tails	Verifica visualmente el éxito de la Winsorización.	Garantiza que ningún viaje corrupto o atípico extremo desestabilice el cálculo de tarifas.

- EN:
- Multivariate Linearity & Multicollinearity Friction: The pairplot confirms a synchronized, positive linear correlation between the target metric *fare_amount* and engineered *continuous predictors (mean_duration, mean_distance)*. However, the exceptionally tight geometric alignment between both *independent variables* exposes *severe structural multicollinearity*, an artifact that inflates *coefficient variance* within the *Ordinary Least Squares (OLS)* estimation matrix.
 - Skewed Distributions & Regulatory Artifacts: *Diagonal histograms* reveal heavily *right-skewed* operational profiles, capturing a dense concentration of *short-haul, low-fare* city transits balanced by a thin macro-seasonal long tail. Concurrently, the persistent horizontal alignment at the *\$52.00* threshold provides empirical cross-sectional proof of the regulated JFK Airport flat-fare sub-structure.
 -
 -


- ES:
- Linealidad Multivariada y Fricción de Multicolinealidad: El pairplot confirma una correlación lineal positiva y sincronizada entre la *métrica objetivo fare_amount* y los *predictores continuos (mean_duration, mean_distance)*. Sin embargo, el alineamiento geométrico extremadamente estrecho entre ambas variables independientes expone una *multicolinealidad estructural severa*, un artefacto que infla la *varianza* de los *coeficientes* dentro de la matriz de estimación de *Mínimos Cuadrados Ordinarios (OLS)*.
 -
 - Distribuciones Sesgadas y Artefactos Regulatorios: Los *histogramas diagonales* revelan perfiles operativos fuertemente *sesgados a la derecha*, capturando una densa concentración de viajes urbanos cortos y de tarifas bajas, equilibrados por una delgada cola extendida macroestacional. Simultáneamente, el alineamiento horizontal persistente en el umbral de *\$52.00* proporciona una prueba empírica de la subestructura regulada de la tarifa plana del Aeropuerto JFK.
 -

Executive & Technical Report: NYC Taxi Fare Optimization & OLS Validation

Informe Ejecutivo y Técnico: Optimización de Tarifas de Taxi en NYC y Validación OLS

Project: Operational Pricing Optimization Framework | Client: Executive Board | TLC Commission | PA

Phase: Execute (Data Splitting & Feature Standardization)



Data Splitting & Scaling

Stability / División de

Datos y Estabilidad de

Escalamiento

Experimental Parameter / Parámetro	Technical Setting / Configuración	Package & Method / Método	Analytical Purpose / Objetivo Analítico
Train-Test Split Ratio	80% Train / 20% Test	scikit-learn / train_test_split	Secures a clean, unseen data environment to validate operational generalization.
Random State Anchor	random_state=0	Deterministic Seed	Guarantees perfect experiment replication and consistent coefficient behavior.
Feature Transformation	Z-score Standardization	StandardScaler()	Equalizes predictors scaling to prevent mathematical scale bias across features.
Data Leakage Shield	Train Fit / Test Transform	.fit_transform() vs .transform()	Prevents validation test metrics from absorbing future training distributions.

EN:

- Robust Validation Splitting: Deployed an automated *partitioning matrix* leveraging *train_test_split* to *segregate data universes*. By allocating a strict *20% validation test ratio* and pinning a deterministic *random_state=0*, the system secures a non-biased, isolated benchmark environment to audit the linear model's generalized *predictive power* over unseen *pricing* requests.
- Leakage-Free Standard Scaling: Implemented a rigorous *data standardization pipeline* via *StandardScaler*. The engine computes historical parameters solely within the *training partition (fit_transform)*, while applying an isolated transformation (*transform*) to the *test subset*. This structural barrier completely eliminates mathematical *data leakage*, centering features to a zero-mean framework to ensure uniform *algorithmic weight distribution*.

ES:


- División Robusta para Validación: Se desplegó una *matriz de partición automatizada* utilizando *train_test_split* para segregar los universos de datos. Al asignar una tasa estricta del *20% para el set de prueba* y fijar un *random_state=0* determinista, el sistema asegura un entorno de evaluación aislado y *sin sesgos* para auditar el poder predictivo generalizado del *modelo lineal* frente a solicitudes de precios imprevistas.
- Escalamiento Estándar Libre de Filtraciones: Se implementó un pipeline riguroso de estandarización de datos mediante *StandardScaler*. El motor calcula los parámetros históricos únicamente dentro de la *partición de entrenamiento (fit_transform)*, mientras aplica una transformación aislada (*transform*) al *subconjunto de prueba*. Esta barrera estructural elimina por completo la *filtración de datos (data leakage)*, centrando las variables en una estructura de media cero para garantizar una distribución uniforme del peso algorítmico.

Executive & Technical Report: NYC Taxi Fare Optimization & OLS Validation


Informe Ejecutivo y Técnico: Optimización de Tarifas de Taxi en NYC y Validación OLS

Project: Operational Pricing Optimization Framework | Client: Executive Board | TLC Commission | PA

Phase: Execute (Model Diagnostics & Residual Performance Audit)



Error Variance & Individual Residual Analysis / Varianza del Error y Análisis de Residuos Individuales



Sample Trip ID / ID de Viaje	Actual Fare / Tarifa Real	Predicted Fare / Predicción OLS	Calculated Residual / Residuo Calculado	Model Behavior / Comportamiento del Modelo
Trip 4655	\$5.50	\$6.496	-\$0.9969	Highly Accurate (Cent-level variance) / Alta precisión.
Trip 13914	\$9.50	\$10.424	-\$0.9243	Highly Accurate (Standard urban route) / Ajuste óptimo.
Trip 7378	\$15.50	16.994	\$-1.494	Stable Prediction (Normal traffic buffer) / Estable.
Trip 18134	\$28.00	\$16.432	\$11.567	Exogenous Volatility (Tolls / Cash Tips) / Factor exógeno.

EN:

- High-Density Prediction Alignment: The *scatter plot maps testing subset predictions* against actual fares, exhibiting an elite clustering density along the *45-degree Perfect Prediction line*. Trips like *4655*, *7378*, and *13914* demonstrate *near-perfect alignment* with tight *residuals spanning* mere cents (*-0.92 to -1.49*), confirming extreme reliability for standard metropolitan transits.
- Exogenous Volatility & Micro-Anomalies: Minor *residual dispersion* is visually captured off the diagonal axis, highlighted by extreme cases like *trip 18134* where the residual reaches +\$11.57 (*actual fare of \$28.00 vs. predicted \$16.43*). These specific variations represent real-world anomalies—such as unmapped bridge tolls, high cash tips embedded in *data logs*, or localized dynamic pricing—which escape historical route averages.

ES:


- Alineación de Predicción de Alta Densidad: El *gráfico de dispersión mapea las predicciones del subconjunto de prueba* frente a las *tarifas reales*, exhibiendo una densidad de agrupación de élite a lo largo de la *línea de Predicción Perfecta de 45 grados*. Viajes como el *4655*, *7378* y *13914* demuestran una alineación casi perfecta con *residuos estrechos* de apenas unos *centavos (-0.92 a -1.49)*, confirmando una alta confiabilidad para trayectos metropolitanos estándar.
- Volatilidad Exógena y Microanomalías: Se captura visualmente una *dispersión menor* fuera del eje diagonal, evidenciada por *casos extremos* como el *viaje 18134*, donde el *residuo* alcanza +\$11.57 (*tarifa real de \$28.00 frente a una predicción de \$16.43*). Estas variaciones específicas representan anomalías del mundo real—como peajes de puentes no mapeados, altas propinas registradas en el campo de tarifa o tarifas dinámicas localizadas—que escapan a los promedios históricos de la ruta.

Executive & Technical Report: NYC Taxi Fare Optimization & OLS Validation

Informe Ejecutivo y Técnico: Optimización de Tarifas de Taxi en NYC y Validación OLS

Project: Operational Pricing Optimization Framework | Client: Executive Board | TLC Commission | PA E
Phase: Execute (Model Diagnostics & Residual Performance Audit)

Error Distribution:
Normality Diagnostics &
Zero-Mean Validation /
Distribución del Error:
Diagnóstico de
Normalidad y Validación
de Media Cero



Statistical Metric / Métrica del Residuo	Calculated Value / Valor Calculado	Theoretical Ideal / Ideal Teórico	Model Compliance / Estado de Validación
Mean of Residuals (μ)	-0.0375	0.0000	Perfect Alignment / El error promedio tiende a cero de forma óptima.
Distribution Profile	Bell-shaped (Right-skewed)	Symmetric Gaussian	Validates normality; tail captures isolated high-tariff volatility.

EN:

- Zero-Mean Statistical Validation: Computational diagnostics confirm an elite *algorithmic balance*, establishing a cross-sectional *mean of residuals* at an exceptional *-0.0375*. This *near-zero* mathematical anchor proves that the *OLS matrix* is completely free of *systematic prediction* bias, ensuring that overall overestimations and underestimations mathematically neutralize across metropolitan fleets.
- Asymmetric Density & Outlier Tails: The *Seaborn histogram* exhibits a tight, *bell-shaped Gaussian* distribution centered around the *Zero Error* Reference line, validating *basic normality assumptions*. However, the *curve* presents a visible *right-skewed* tail extending past the *+\$10* boundary; this visual *variance* isolates volatile, *high-tariff* anomalous runs that escape linear routing baselines, supporting the deployment of localized rule-based bypasses.

ES:


- Validación Estadística de Media Cero: Los diagnósticos computacionales confirman un *balance algorítmico de élite*, estableciendo un promedio transversal de *residuos* en un valor excepcional de *-0.0375*. Esta ancla matemática cercana a cero demuestra que la *matriz OLS* está completamente libre de *sesgos predictivos sistemáticos*, asegurando que las sobreestimaciones y subestimaciones generales se neutralicen matemáticamente en la flota metropolitana.
- Densidad Asimétrica y Colas de Valores Atípicos: El *histograma de Seaborn* exhibe una *distribución gaussiana* compacta en *forma de campana* centrada en la línea de Referencia de *Error Cero*, validando los supuestos básicos de normalidad. Sin embargo, la *curva* presenta una *cola derecha asimétrica* que se extiende más allá del límite de *+\$10*; sta *varianza* visual *aisla trayectos anómalos volátiles* de *tarifas altas* que escapan a las líneas base lineales, respaldando el despliegue de desvíos basados en reglas localizadas.

Executive & Technical Report: NYC Taxi Fare Optimization & OLS Validation

Informe Ejecutivo y Técnico: Optimización de Tarifas de Taxi en NYC y Validación OLS

Project: Operational Pricing Optimization Framework | Client: Executive Board | TLC Commission | PA

Phase: Execute (Model Estimation & Beta Coefficients)



Algorithmic Equation & Predictor Coefficients / Ecuación Algorítmica y Coeficientes Predictores

- EN:
- Mathematical Weight Matrix: The *OLS coefficient* extraction formalizes the mathematical core of the *upfront pricing engine*. The spatial metric *mean_distance* drives structural pricing with an intense weight of *7.1132*, while *mean_duration* establishes a solid temporal buffer of *2.4402* per *standard deviation*. This simultaneous optimization ensures that geographic spans and traffic friction are equitably scaled into the *fare algorithm*.
 - Categorical Realignment & Base Anchor: Embedding the parameters within a *multi-variable matrix* successfully realigned the *rush_hour* vector, correcting its standalone *negative correlation* into a positive operational control *coefficient* of *0.0125*. Anchored by a model *intercept* baseline of *12.5165*, the framework delivers a highly balanced, robust pricing structure capable of generalized fleet deployment.

Feature / Variable Predictora	Beta Coefficient / Coeficiente β	Directional Impact / Impacto de Negocio	Operational Interpretation / Lectura Operativa
Intercept (Tarifa Base)	12.891	Baseline Anchor	The starting baseline fare value when all predictive features are held at their mean.
mean_distance	\$7.477	Strong Positive	Primary economic driver. Dominates the long-range pricing framework.
mean_duration	2.424	Moderate Positive	Traffic friction buffer. Dynamically absorbs revenue loss from city gridlocks.
rush_hour	0.0152	Marginal Positive	Acts as a controlled categorical vector, preventing external timeline bias.

- ES:
- Matriz de Pesos Matemáticos: La extracción de *coeficientes OLS* formaliza el núcleo matemático del motor de precios iniciales. La métrica espacial *mean_distance* impulsa la fijación estructural de precios con un peso intenso de *7.1132*, mientras que *mean_duration* establece un amortiguador temporal sólido de *2.4402* por *desviación estándar*. Esta optimización simultánea asegura que la extensión geográfica y la fricción del tráfico se escalen equitativamente en el *algoritmo de la tarifa*.
 - Realineación Categórica y Ancla Base: La integración de los parámetros dentro de una *matriz multivariable* realineó con éxito el vector *rush_hour*, corrigiendo su *correlación negativa* aislada hacia un *coeficiente* de control operacional positivo de *0.0125*. Anclado por una línea base de *intercepto* del modelo de *12.5165*, el marco ofrece una estructura de precios altamente equilibrada y robusta para el despliegue general de la flota.

Executive & Technical Report: NYC Taxi Fare Optimization & OLS Validation

Informe Ejecutivo y Técnico: Optimización de Tarifas de Taxi en NYC y Validación OLS

Project: Operational Pricing Optimization Framework | Client: Executive Board | TLC Commission | PA

Phase: Share (Strategic Conclusions & Executive Takeaways)



Executive Takeaways & Statistical Validation / Conclusiones Ejecutivas y Validación Estadísticas

Predictive Feature / Variable Predictora	Mathematical Impact / Coeficiente β	Strategic Business Meaning / Significado de Negocio	Operational Action & Guardrails / Acción Operativa
mean_distance (Distancia Promedio)	+7.48	Primary Economic Driver: Distance dominates the core pricing framework by a 3-to-1 margin over duration.	Establish distance as the baseline anchor for the upcoming upfront pricing software.
mean_duration (Duración Promedio)	+2.42	Traffic Friction Buffer: Dynamically absorbs the cost of city delays and time spent in transit.	Protects driver revenue metrics automatically during high-congestion gridlocks.
rush_hour (Hora Punta)	+0.15	Marginal Financial Vector: Heavy traffic costs are already implicitly captured by the trip duration.	Keep rush-hour as a marginal control vector, avoiding double-charging penalty biases.
VendorID_2 (Neutralidad de Proveedor)	-0.03	Platform Neutrality: Proves both technology vendors charge equivalent rates under identical conditions.	Guarantees absolute billing consistency across the TLC platform, securing fair competition.

- EN:
- Elite Predictive Power & Immunity to Overfitting: The multiple linear regression framework achieved an outstanding **R2 score of 0.8725** on the **test dataset**, mathematically explaining **87.25%** of fare variance using only four core features. The strict alignment between training and test error bounds (**R2=0.8725**, **MAE=\$2.20**) proves the pricing engine is entirely immune to **overfitting**, guaranteeing flawless real-world generalization over unseen fleet runs.
 - Axiomatic Assumption & Residual Integrity: Graphical diagnostics confirmed high model integrity, with residual errors heavily centered at a near-**zero mean** (**≈ -0.037**). The minor, expected **right-skewed** tail in the **histogram** and the expanding **variance** in the **scatterplot** represent **normal heteroscedasticity**, driven exclusively by the inherent volatility of long-distance transits and regulatory airport flat rates.
- ES:
- Poder Predictivo de Élite e Inmunidad al Sobreajuste: El marco de **regresión lineal múltiple** logró un destacado **coeficiente R2 de 0.8725** en el **conjunto de prueba**, explicando matemáticamente el **87.25%** de la **variabilidad** de las tarifas con solo cuatro características clave. La alineación estricta entre los límites de error de **entrenamiento y prueba** (**R2=0.8725**, **MAE=\$2.20**) demuestra que el motor de precios es inmune al **sobreajuste**, garantizando una excelente generalización real ante nuevos viajes de la flota.
 - Integridad Residual y Validación de Supuestos: Los diagnósticos gráficos confirmaron la alta integridad del modelo, con **errores residuales** concentrados en una media prácticamente cercana a **cero** (**≈ -0.037**). La ligera **asimetría derecha** en el **histograma** y la apertura en el **diagrama de dispersión** representan una **heteroscedasticidad** esperada y **normal**, impulsada exclusivamente por la **volatilidad** inherente de los viajes de larga distancia y las tarifas planas institucionales de aeropuertos.