

Course Two

Get Started with Python



Instructions

Use this PACE strategy document to record decisions and reflections as you work through this end-of-course project. You can use this document as a guide to consider your responses and reflections at different stages of the data analytical process. Additionally, the PACE strategy documents can be used as a resource when working on future projects.

Course Project Recap

Regardless of which track you have chosen to complete, your goals for this project are:

- ☐ Complete the questions in the Course 2 PACE strategy document
- ☐ Answer the questions in the Jupyter notebook project file
- ☐ Complete coding prep work on project's Jupyter notebook
- ☐ Summarize the column Dtypes
- ☐ Communicate important findings in the form of an executive summary

Relevant Interview Questions


Completing the end-of-course project will help you respond these types of questions that are often asked during the interview process:

- Describe the steps you would take to clean and transform an unstructured data set.
- What specific things might you look for as part of your cleaning process?
- What are some of the outliers, anomalies, or unusual things you might look for in the data cleaning process that might impact analyses or ability to create insights?



Reference Guide

This project has three tasks; the visual below identifies how the stages of PACE are incorporated across those tasks.



Data Project Questions & Considerations



PACE: Plan Stage

- How can you best prepare to understand and organize the provided information?

EN:

To best prepare for organizing and understanding the initial phase of your data project, you should focus on basic data exploration steps, fundamental Python libraries, and a clean folder structure that matches your current learning level.

ES:

Para prepararse de la mejor manera en la organización y comprensión de la fase inicial de su proyecto de datos, debe enfocarse en los pasos básicos de exploración de datos, las librerías fundamentales de Python y una estructura de carpetas limpia que coincida con su nivel actual de aprendizaje.

1. Basic Framework Steps (PACE) / Pasos Básicos del Marco (PACE)

 **EN:**

Instead of advanced modeling, use the **PACE** framework to guide your first look at the raw data:

- **Plan:** Define what you want to find in the dataset and check its total size (rows and columns).
- **Analyze:** Look at the column names, check data types (numbers vs. text), and find missing values.
- **Construct:** Use simple Python commands to filter, sort, and clean the data.
- **Ejecute:** Document your findings in a simple notebook summary so others can see your clean dataset.

 **ES:**

En lugar de un modelado avanzado, utiliza el marco **PACE** para guiar tu primer vistazo a los datos brutos:

- **Plan (Planificar):** Definir qué deseas encontrar en el conjunto de datos y verificar su tamaño total (filas y columnas).
- **Analyze (Analizar):** Mirar los nombres de las columnas, revisar los tipos de datos (números vs. texto) y encontrar valores faltantes.
- **Construct (Construir):** Usar comandos simples de Python para filtrar, ordenar y limpiar los datos.
- **Ejecutar:** Documentar tus hallazgos en un resumen simple dentro del cuaderno para que otros puedan ver tu conjunto de datos limpio.

2. Core Python Tools to Master / Herramientas Clave de Python a Dominar

 **EN:**

Focus on the foundational libraries and commands designed for data manipulation:

- **Libraries:** Import **pandas** as your main tool to work with data tables (dataframes).
- **Inspection Commands:** Master basic functions like `.head()` to see the first rows, `.info()` to check data types, and `.describe()` to see simple statistics like averages, minimums, and maximums.
- **Data Verification:** Use functions like `.isna().sum()` to quickly find and count blank spaces or empty fields in your columns.

 **ES:**

Enfócate en las librerías y comandos fundamentales diseñados para la manipulación de datos:

- **Librerías:** Importar **pandas** como tu herramienta principal para trabajar con tablas de datos (dataframes).

- **Comandos de Inspección:** Dominar funciones básicas como `.head()` para ver las primeras filas, `.info()` para revisar los tipos de datos y `.describe()` para ver estadísticas simples como promedios, mínimos y máximos.
- **Verificación de Datos:** Usar funciones como `.isna().sum()` para encontrar y contar rápidamente espacios en blanco o campos vacíos en tus columnas.

3. Simple Repository Organization / Organización Simple del Repositorio

 EN:

Keep your work organized so your GitHub repository stays professional and easy to navigate from the start:

 ES:

Mantén tu trabajo organizado para que tu repositorio de GitHub se vea profesional y sea fácil de navegar desde el principio:

- What follow-along and self-review codebooks will help you perform this work?

 EN:

To successfully complete the initial stage of the project using basic Python, you do not need a complex matrix of advanced scripts. For this fundamental phase, your workflow focuses on **a single, well-structured exploratory notebook** that serves as your follow-along guide and your own self-review checklist.

 ES:

Para completar con éxito la etapa inicial del proyecto utilizando Python básico, no se necesita una matriz compleja de scripts avanzados. Para esta fase fundamental, tu flujo de trabajo se centra en **un único cuaderno exploratorio bien estructurado** que funciona como tu guía práctica y tu propia lista de auto-revisión.

The Course 2 Codebook Architecture / La Arquitectura del Cuaderno del Curso 2



- **Follow-Along Purpose:** This interactive notebook is designed to transition you from looking at static files to actively manipulating tables with code. You use it to load raw data files, visually scan the first few observations, and check if Python understands the values correctly.
- **Key Coding Milestones:**

1. **Library Ingestion:** Importing the core toolkit using `import pandas as pd`.
2. **Data Loading:** Transforming a flat `.csv` file into an active memory structure using `pd.read_csv()`.
3. **Structural Inspection:** Running `.head()` to view the top 5 rows, `.info()` to audit column structures, and `.describe()` to extract simple statistical summaries (like minimum values, maximum values, and column counts).



ES:

- **Propósito Práctico (Follow-Along):** Este cuaderno interactivo está diseñado para guiarte en la transición de mirar archivos estáticos a manipular activamente tablas con código. Lo utilizas para cargar archivos de datos brutos, escanear visualmente las primeras observaciones y verificar si Python entiende los valores correctamente.
- **Hitos Clave de Programación:**

1. **Ingestión de Librerías:** Importar el kit de herramientas esenciales usando `import pandas as pd`.
2. **Carga de Datos:** Transformar un archivo `.csv` plano en una estructura de memoria activa mediante `pd.read_csv()`.
3. **Inspección Estructural:** Ejecutar `.head()` para ver las primeras 5 filas, `.info()` para auditar las estructuras de las columnas y `.describe()` para extraer resúmenes estadísticos simples (como valores mínimos, máximos y conteos de columnas).



The Self-Review Codebook Checklist / Lista de Auto-Revisión del Cuaderno



EN:

When you complete your coding sections, use this simple checklist directly within your notebook comments to review your own work before pushing it to GitHub:

1. **Data Quality Check:** Did you run `.isna().sum()` to explicitly search for and count empty spaces or missing rows?
2. **Value Sanity Check:** When looking at `.describe()`, did you spot any impossible numbers for this baseline level (such as negative numbers in a price or fare column)?

3. **Data Type Alignment:** Did the data columns load as expected? (For instance, verifying if text columns are listed as `object` and counts are listed as `int64` or `float64`).



ES:

Cuando completes tus secciones de código, utiliza esta lista de verificación simple directamente dentro de los comentarios de tu cuaderno para revisar tu propio trabajo antes de subirlo a GitHub:

1. **Control de Calidad de Datos:** ¿Ejecutaste `.isna().sum()` para buscar y contar explícitamente espacios vacíos o filas faltantes?
2. **Control de Sensatez de Valores:** Al mirar `.describe()`, ¿detectaste números imposibles para este nivel de línea base (como números negativos en una columna de precios o tarifas)?
3. **Alineación de Tipos de Datos:** ¿Las columnas de datos se cargaron como se esperaba? (Por ejemplo, verificar si las columnas de texto aparecen como `object` y los conteos como `int64` o `float64`).

- What are some additional activities a resourceful learner would perform before starting to code?



EN:

Before writing your very first line of code in Python, a resourceful and organized learner goes beyond just opening a blank notebook. Performing a few tactical, non-coding preparation steps saves hours of frustration downstream and builds strong professional habits from day one.



ES:

Antes de escribir la primera línea de código en Python, un estudiante ingenioso y organizado va más allá de simplemente abrir un cuaderno en blanco. Realizar algunos pasos tácticos de preparación que no requieren programación ahorra horas de frustración en el futuro y construye hábitos profesionales sólidos desde el primer día.

1. Domain Immersion & Glossary Building / Inmersión en el Dominio y Glosario



EN:

- **Read the Metadata Documentation:** Before inspecting data with Python, read the data dictionary or column descriptions to understand what the abbreviations stand for (e.g., learning what `VendorID` or `tpep_pickup_datetime` mean in the context of New York City taxis).

- **Build a Simple Domain Glossary:** Jot down brief notes on how the specific industry operates. Understanding basic business rules—such as how initial flag drops, metered distance, and toll rates combine—helps you spot weird data anomalies later.

 **ES:**

- **Leer la Documentación de Metadatos:** Antes de inspeccionar los datos con Python, lee el diccionario de datos o las descripciones de las columnas para entender qué significan las abreviaturas (por ejemplo, aprender qué significa `VendorID` o `tpep_pickup_datetime` en el contexto de los taxis de Nueva York).
- **Crear un Glosario Simple del Dominio:** Toma notas breves sobre cómo opera esa industria específica. Comprender las reglas básicas del negocio —como la tarifa inicial fija, la distancia medida y los peajes— te ayudará a detectar anomalías extrañas en los datos más adelante.

2. Visual & Structural File Inspection / Inspección Visual y Estructural del Archivo

 **EN:**

- **The "Sneak Peek" Audit:** Open the raw `.csv` file using a standard text editor (like Notepad) or a spreadsheet viewer for a few seconds. Do not edit it, just visually check how fields are separated (commas, semicolons) and see if the headers line up nicely.
- **Identify Structural Constraints:** Check the file size on your computer. Knowing if you are handling a lightweight 100 KB file versus a massive multi-gigabyte dataset changes how careful you need to be with your local computer environment and memory.

 **ES:**

- **Auditoría de "Vistazo Rápido":** Abre el archivo `.csv` bruto usando un editor de texto estándar (como el Bloc de notas) o un visor de hojas de cálculo por unos segundos. No lo edites, solo verifica visualmente cómo están separados los campos (comas, puntos y comas) y si los encabezados se alinean bien.
- **Identificar Restricciones Estructurales:** Revisa el tamaño del archivo en tu computadora. Saber si estás manejando un archivo ligero de 100 KB o un conjunto de datos masivo de varios gigabytes cambia qué tan cuidadoso debes ser con el entorno de memoria de tu computadora local.

3. Mental Mapping & Pseudo-Coding / Mapeo Mental y Pseudo-Código

 **EN:**



- **Write Down a Logical Checklist:** Grab a piece of paper or open a simple text file and write down your goal using plain words (e.g., "1. Load data, 2. Count rows, 3. Find empty boxes, 4. Check prices").
- **Map Expected Inputs vs. Outputs:** Sketch a quick mental picture or layout of what your target clean table should look like. Deciding beforehand what columns are essential for your initial goal keeps your code focused and clean.



ES:

- **Escribir una Lista de Verificación Lógica:** Toma un papel o abre un archivo de texto simple y escribe tu objetivo usando palabras sencillas (por ejemplo, "1. Cargar datos, 2. Contar filas, 3. Buscar casillas vacías, 4. Revisar precios").
- **Mapear Entradas vs. Salidas Esperadas:** Diseña un mapa mental rápido de cómo debería verse tu tabla limpia final. Decidir de antemano qué columnas son esenciales para tu meta inicial mantiene tu código enfocado y limpio.



PACE: Analyze Stage

- Will the available information be sufficient to achieve the goal based on your intuition and the analysis of the variables?

EN:

Based on statistical intuition and a structural analysis of the variables available at this stage of the program, **yes, the information is completely sufficient to achieve the specific goals of Course 2 (Get Started with Python)**. At this point, your objective is not to build a mathematical prediction model, but rather to perform a basic health audit of the dataset. The core parameters provided in the raw file are more than enough to establish your first data profile.

ES:

Basado en la intuición estadística y en un análisis estructural de las variables disponibles en esta etapa del programa, **sí, la información es completamente suficiente para lograr los objetivos específicos del Curso 2 (Get Started with Python)**.

En este punto, tu objetivo no es construir un modelo matemático de predicción, sino realizar una auditoría básica de la salud del conjunto de datos. Los parámetros clave proporcionados en el archivo bruto son más que suficientes para establecer tu primer perfil de datos.

Variable Breakdown & Analytical Sufficiency / Desglose de Variables y Suficiencia Analítica

1. Spatial & Temporal Baseline Parameters / Parámetros Base Espacio-Temporales

- trip_distance** (EN: Continuous numeric / ES: Numérico continuo): * **Sufficiency:** Perfectly sufficient to calculate basic statistics (`.describe()`). It allows you to find minimums, maximums, and averages to understand the physical length of the trips.
 - Suficiencia:** Perfectamente suficiente para calcular estadísticas básicas (`.describe()`). Permite encontrar mínimos, máximos y promedios para entender la longitud física de los viajes.
- tpep_pickup_datetime & tpep_dropoff_datetime** (EN: Text objects / ES: Objetos de texto):
 - Sufficiency:** Even though they load as basic text string objects (`object`), they are sufficient for Course 2 to practice identifying data types via `.info()` and recognizing that they will need conversion later.

- **Suficiencia:** Aunque se cargan como objetos de cadena de texto básicos (**object**), son suficientes para el Curso 2 para practicar la identificación de tipos de datos a través de **.info()** y reconocer que necesitarán conversión más adelante.

2. Financial Core Parameters / Parámetros Financieros Centrales

● **fare_amount** (EN: Continuous numeric / ES: Numérico continuo):

- **Sufficiency:** This is the most critical column for your data sanity check. It is completely sufficient for detecting systemic recording errors (such as finding impossible negative prices or zero fares) using simple pandas filtering.
- **Suficiencia:** Esta es la columna más crítica para tu control de sensatez de datos. Es completamente suficiente para detectar errores de registro sistémicos (como encontrar precios negativos imposibles o tarifas en cero) usando filtros simples de pandas.

3. Categorical Control Fields / Campos de Control Categóricos

● **VendorID & Payment_type** (EN: Discrete integers / ES: Enteros discretos):

- **Sufficiency:** Highly sufficient for learning how to group and count categorical data. They allow you to see how many transactions were processed by each vendor platform or payment format without needing advanced transformations.
- **Suficiencia:** Altamente suficiente para aprender a agrupar y contar datos categóricos. Te permiten ver cuántas transacciones fueron procesadas por cada plataforma de proveedor o formato de pago sin necesidad de transformaciones avanzadas.



Intuitive Conclusion / Conclusión Intuitiva



EN:

The raw columns contain a high volume of rows with direct operational records. For a baseline python exploratory phase, **there is no missing information or structural void** that would stop you from successfully completing the data profile. The data is structurally sufficient for initial exploration.



ES:

Las columnas brutas contienen un alto volumen de filas con registros operativos directos. Para una fase exploratoria inicial en Python, **no hay información faltante ni vacíos estructurales** que te impidan completar con éxito el perfil de datos. Los datos son estructuralmente suficientes para la exploración inicial.

- How would you build summary dataframe statistics and assess the min and max range of the data?



When starting out with basic data exploration in Python using **Pandas**, building summary statistics and assessing values like minimums and maximums is your first line of defense against corrupted data. At this early stage, you do not need complex programming loops; Pandas has built-in features that extract this structure instantly.



Al comenzar con la exploración básica de datos en Python usando **Pandas**, crear estadísticas de resumen y evaluar valores como mínimos y máximos es tu primera línea de defensa contra datos corruptos. En esta etapa inicial, no necesitas bucles de programación complejos; Pandas tiene funciones integradas que extraen esta estructura de forma instantánea.

1. Automatic Summary Statistics: The `.describe()` Command / Estadísticas de Resumen Automáticas: El Comando `.describe()`



The fastest way to build a summary dataframe is by calling the `.describe()` method on your active dataset.

- By default, it automatically filters for numeric columns and outputs a structured matrix containing the count, mean (average), standard deviation, minimum, maximum, and the 25th, 50th (median), and 75th percentiles.

```
import pandas as pd

# 1. Load the raw data / Cargar los datos brutos
df = pd.read_csv("02_AUTOMATIDATA__python_eda_automatidata.csv")

# 2. Generate the summary table / Generar la tabla de resumen
summary_stats = df.describe()

print(summary_stats)
```



La forma más rápida de crear un resumen de un dataframe es llamando al método `.describe()` en tu conjunto de datos activo.

- Por defecto, filtra automáticamente las columnas numéricas y muestra una matriz estructurada que contiene el conteo, la media (promedio), la desviación estándar, el mínimo, el máximo y los percentiles 25, 50 (mediana) y 75.

2. Targeted Min/Max Range Assessment / Evaluación Específica de Rangos Mínimos y Máximos

EN:

While `.describe()` gives you a broad birds-eye view, you often need to isolate specific mathematical boundaries on individual columns to check for operational anomalies. You can extract individual values using standalone Pandas functions:

```
# Extract exact boundaries for a single operational metric

min_distance = df['trip_distance'].min()

max_distance = df['trip_distance'].max()

print(f"Distance Range: From {min_distance} to {max_distance} miles.")
```

ES:

Aunque `.describe()` te da una vista panorámica amplia, a menudo necesitas aislar límites matemáticos específicos en columnas individuales para comprobar anomalías operativas. Puedes extraer valores individuales utilizando funciones independientes de Pandas:

3. The Self-Review Data Sanity Test / La Prueba de Sensatez de Datos (Auto-Revisión)

EN:

Once you calculate these statistics, a resourceful learner performs a **sanity check** on the range output to discover hidden flaws before moving forward:

1. **The Zero-Boundary Trap:** If `trip_distance` shows a minimum of `0.0` but the corresponding fare price is high, it flags an immediate system entry error.
2. **The Negative Contamination:** Look closely at the minimum of financial rows like `fare_amount`. If the minimum displays a negative number (e.g., `-$5.00`), you have located negative fare anomalies that must be filtered out since real prices cannot drop below zero.

ES:

Una vez que calculas estas estadísticas, un estudiante ingenioso realiza un **control de sensatez** en los rangos obtenidos para descubrir fallas ocultas antes de avanzar:

1. **La Trampa del Limite Cero:** Si `trip_distance` muestra un mínimo de `0.0` pero el precio de la tarifa correspondiente es alto, esto alerta sobre un error inmediato de ingreso en el sistema.
2. **La Contaminación Negativa:** Mira de cerca el mínimo de las filas financieras como `fare_amount`. Si el mínimo muestra un número negativo (por ejemplo, `-$5.00`), has localizado anomalías de tarifas negativas que deben filtrarse, ya que los precios reales no pueden caer por debajo de cero.

- Do the averages of any of the data variables look unusual? Can you describe the interval data?

Analyzing Averages and Explaining Interval Data in Course 2 / Análisis de Promedios y Explicación de Datos de Intervalo en el Curso 2

 EN:

When evaluating the baseline outputs of your summary statistics (such as the mean values from `.describe()`), you must look closely to see if the statistical numbers match real-world logic. At this stage, some variables will look completely normal, while others will flag immediate anomalies. Below is the analytical breakdown of the averages and the definition of the data structure.

 ES:

Al evaluar los resultados iniciales de tus estadísticas de resumen (como los valores de la media obtenidos con `.describe()`), debes observar de cerca si los números estadísticos coinciden con la lógica del mundo real. En esta etapa, algunas variables se verán completamente normales, mientras que otras alertarán sobre anomalías inmediatas. A continuación se presenta el desglose analítico de los promedios y la definición de la estructura de los datos.

1. Do the Averages Look Unusual? / ¿Se Ven Inusuales los Promedios?

 EN:

- **trip_distance (Normal Average):** The mean trip distance usually hovers around **2.9 to 3.0 miles**. This is completely normal and logical for standard urban taxi rides across New York City.
- **fare_amount (Unusual or Contaminated Average):** While the average fare seems mathematically stable at first glance (around **\$12.00 to \$13.00**), the average is technically **skewed and unusual** because the underlying column contains invalid data.
 - **The Flaw:** Because the column contains negative prices (like **-\$5.00**) and extreme, uncleaned maximum values, the calculated mean does not reflect the true operational average of a clean taxi ride yet.



ES:

- **trip_distance (Promedio Normal):** La distancia promedio de los viajes generalmente ronda entre **2.9 y 3.0 millas**. Esto es completamente normal y lógico para trayectos urbanos estándar dentro de la ciudad de Nueva York.
- **fare_amount (Promedio Inusual o Contaminado):** Aunque la tarifa promedio parece matemáticamente estable a primera vista (alrededor de **\$12.00 a \$13.00**), el promedio es técnicamente **sesgado e inusual** debido a que la columna base contiene datos inválidos.
 - **La Falla:** Como la columna incluye precios negativos (como **-\$5.00**) y valores máximos extremos sin limpiar, la media calculada aún no refleja el verdadero promedio operativo de un viaje de taxi limpio.



2. Describing Interval Data / Descripción de los Datos de Intervalo



EN:

In statistics, **Interval Data** is a specific type of quantitative (numeric) data. To understand where it fits, it helps to look at the hierarchy of data scales: Nominal, Ordinal, Interval, and Ratio.

- **Definition:** Interval data consists of numeric values where the **exact distance (interval) between two points is equal and measurable**, but the data scale **lacks a true, absolute zero point**. In interval scales, "zero" is just an arbitrary position on a scale; it does not mean a complete absence of the property.
- **The Classic Example:** Temperature in Celsius or Fahrenheit. The difference between 10°C and 20°C is the exact same 10-degree step as the jump from 20°C to 30°C. However, 0°C does not mean "zero heat"—it is just the arbitrary point where water freezes.
- **Interval Data vs. Ratio Data in this Dataset:** * Most variables in your taxi dataset (like **trip_distance** or **fare_amount**) are actually **Ratio Data**, not interval data, because they *do* possess a true absolute zero (0.0 miles means zero physical space traveled, and \$0.00 means zero money spent).

- **The True Chronological Intervals:** The timestamp coordinates (`tpep_pickup_datetime`) function like an interval continuum. The distance between 1:00 PM and 2:00 PM is exactly 60 minutes, matching the interval between 2:00 PM and 3:00 PM, but time itself has no absolute operational zero starting point.

**ES:**

En estadística, los **Datos de Intervalo** representan un tipo específico de datos cuantitativos (numéricos). Para entender dónde encajan, resulta útil observar la jerarquía de las escalas de datos: Nominal, Ordinal, Intervalo y Razón.

- **Definición:** Los datos de intervalo consisten en valores numéricos donde la **distancia exacta (intervalo) entre dos puntos es igual y medible**, pero la escala de datos **carece de un punto cero verdadero y absoluto**. En las escalas de intervalo, el "cero" es solo una posición arbitraria; no significa la ausencia total de la propiedad.
- **El Ejemplo Clásico:** La temperatura en grados Celsius o Fahrenheit. La diferencia entre 10°C y 20°C es exactamente el mismo paso de 10 grados que el salto de 20°C a 30°C. Sin embargo, 0°C no significa "ausencia de calor"; es simplemente el punto arbitrario donde el agua se congela.
- **Datos de Intervalo vs. Datos de Razón en este Dataset:**

- La mayoría de las variables en tu conjunto de datos de taxis (como `trip_distance` o `fare_amount`) son en realidad **Datos de Razón** (Ratio Data), no datos de intervalo, porque *sí* poseen un cero absoluto verdadero (0.0 millas significa cero espacio físico recorrido, y \$0.00 significa cero dinero gastado).
- **Los Verdaderos Intervalos Cronológicos:** Las coordenadas de marca de tiempo (`tpep_pickup_datetime`) funcionan como un continuo de intervalo. La distancia entre la 1:00 PM y las 2:00 PM es exactamente de 60 minutos, igual que el intervalo entre las 2:00 PM y las 3:00 PM, pero el tiempo en sí no tiene un punto de partida cero absoluto en términos operativos.

**PACE: Construct Stage**

Note: The Construct stage does not apply to this workflow. The PACE framework can be adapted to fit the specific requirements of any project.



PAC: Execute Stage

- Given your current knowledge of the data, what would you initially recommend to your manager to investigate further prior to performing exploratory data analysis?

- What data initially presents as containing anomalies?

- What additional types of data could strengthen this dataset?