

Executive Technical Summary: Automatidata & NYC TLC

The Nuts and Bolts of Machine Learning

Executive Summary: Business Context, KPIs & Strategic Impact / Contexto de Negocio, KPIs e Impacto Estratégico



Business Context/ Contexto de Negocio

EN:

- Build and optimize tree-based classifiers (Random Forest, XGBoost) using NYC TLC trip history data to predict generous tippers (gratuuity $\geq 20\%$) and improve driver retention metrics.

ES:

- Construir y optimizar modelos de clasificación basados en árboles (Random Forest, XGBoost) usando el historial de viajes de la NYC TLC para predecir clientes generosos (propina $\geq 20\%$).



Ethical Landscape Escenario Ético

EN:

- Deploying real-time tip alerts creates a high risk of systemic geographic redlining in lower-income areas and excludes unbanked, cash-reliant riders due to chronic credit bias.

ES:

- Alertas de propina en tiempo real arriesgan discriminación geográfica (redlining) en zonas de bajos ingresos y exclusión de pasajeros que dependen de pagos en efectivo.



Strategic Pivot Pivote Estratégico

EN:

- Pivot the model from a direct dispatch filter into an institutional diagnostic tool. Deliver macro scheduling heatmaps and regulatory pricing suggestions without individual discrimination.

ES:

- Pivota el modelo a una herramienta de diagnóstico institucional. Entregar mapas de calor agregados y guías horarias en vez de filtrar a usuarios en tiempo real.



Discrimination and Geographic Bias Discriminación y Sesgo Geográfico

EN:

- Using spatial features (pickup/dropoff zones) to flag "non-tippers" in driver apps will encourage drivers to systematically avoid low-income areas, destroying public transport equity.

ES:

- Usar zonas geográficas en vivo para alertar sobre bajas propinas incentivará a evadir ciertas comunas de menores ingresos, vulnerando la equidad del transporte público.



Data Bias: Cash Users Sesgo de Datos: Usuarios de Efectivo

EN:

- TLC data only tracks credit card gratuities reliably. Cash transactions are systematically mislabeled as "non-tippers", penalizing unbanked populations unfairly.

ES:

- El registro oficial solo mide propinas electrónicas. El modelo califica erróneamente el pago en efectivo como \$0 propina, excluyendo financieramente a pasajeros no bancarizados.



Fuentes de Datos | Data Sources

```
df0.head()
```

	Unnamed: 0	VendorID	tpcp_pickup_datetime	tpcp_dropoff_datetime	passenger_count	trip_distance	RatecodeID	store_and_fwd_flag
0	24870114	2	03/25/2017 8:55:43 AM	03/25/2017 9:09:47 AM	6	3.34	1	N
1	35634249	1	04/11/2017 2:53:28 PM	04/11/2017 3:19:58 PM	1	1.80	1	N
2	106203690	1	12/15/2017 7:26:56 AM	12/15/2017 7:34:08 AM	1	1.00	1	N
3	38942136	2	05/07/2017 1:17:59 PM	05/07/2017 1:48:14 PM	1	3.70	1	N
4	30841670	2	04/15/2017 11:32:20 PM	04/15/2017 11:49:03 PM	1	4.37	1	N

nyc_preds_means.head()

	mean_duration	mean_distance	predicted_fare
0	22.847222	3.521667	16.434245
1	24.470370	3.108889	16.052218
2	7.250000	0.881429	7.053706
3	30.250000	3.700000	18.731650
4	14.616667	4.435000	15.845642

EN:

This cell loads and structures the two fundamental components of our modeling pipeline:

- **df0**: Holds the raw historical transactional dataset for the 2017 Yellow Taxi trip logs compiled by the NYC TLC.
- **nyc_preds_means**: Holds the high-signal engineered features computed during the previous course's milestone project (including mean trip durations, mean distances, and Multiple Linear Regression predicted fares).

ES:

Se cargaron y prepararon los dos componentes estructurales de nuestros datos:

- **df0**: Contiene el conjunto de datos original de los viajes en taxi amarillo de 2017 de la NYC TLC con los registros transaccionales brutos (raw data).
- **nyc_preds_means**: Contiene las métricas de ingeniería de características complejas que calculaste en el proyecto del curso anterior (duraciones promedio, distancias promedio y las tarifas predichas mediante Regresión Lineal Múltiple).

The next methodological step requires auditing the initial rows using `df0.head()` and subsequently merging both DataFrames to consolidate our final predictor space (X) within a unified training matrix.

El siguiente paso metodológico consiste en inspeccionar las primeras filas (`df0.head()`) y posteriormente fusionar (merge) ambos DataFrames para consolidar todas las variables independientes (X) en una sola matriz de entrenamiento.



Auditing Pre-engineered Features / Auditoría de Características Pre-diseñadas

	VendorID	tpcp_pickup_datetime	trip_distance	fare_amount	mean_duration	mean_distance	predicted_fare
0	2	03/25/2017 8:55:43 AM	3.34	13.0	22.847222	3.521667	16.434245
1	1	04/11/2017 2:53:28 PM	1.80	16.0	24.470370	3.108889	16.052218

EN:

High-Signal Feature Consolidation

- **Legacy Features (Knowledge Injection)**: Three continuous metrics are integrated from the previous model: `mean_duration`, `mean_distance`, and `predicted_fare` (baseline fare predicted via Multiple Linear Regression).
- **Pipeline Alignment**: Using an index-based join (`.join()`), we merge raw transactional records (`df0`) with these predictions, locking down the feature space (X) prior to the preprocessing workflow.

ES:

- **Variables Heredadas (Inyección de Conocimiento)**: Se integran tres métricas continuas del modelo previo: `mean_duration` (duración promedio), `mean_distance` (distancia promedio) y `predicted_fare` (tarifa base predicha por Regresión Lineal Múltiple).
- **Alineación del Pipeline**: Mediante una unión indexada (`.join()`), fusionamos los datos transaccionales brutos (`df0`) con estas predicciones, asegurando la integridad del espacio de características (X) antes del preprocesamiento.

Executive Technical Summary: Automatidata & NYC TLC

The Nuts and Bolts of Machine Learning

PACE: Analyze Phase: Auditoría Estructural de Datos | Structural Data Audit



Analyze Phase: Structural Data Audit | Fase de Análisis: Auditoría Estructural de Datos

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 22699 entries, 0 to 22698
Data columns (total 21 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Unnamed: 0             22699 non-null  int64
1   VendorID               22699 non-null  int64
2   tpep_pickup_datetime   22699 non-null  object
3   tpep_dropoff_datetime  22699 non-null  object
4   passenger_count        22699 non-null  int64
5   trip_distance          22699 non-null  float64
6   RatecodeID            22699 non-null  int64
7   store_and_fwd_flag     22699 non-null  object
8   PULocationID           22699 non-null  int64
9   DOLocationID           22699 non-null  int64
10  payment_type           22699 non-null  int64
11  fare_amount            22699 non-null  float64
12  extra                  22699 non-null  float64
13  mta_tax                22699 non-null  float64
14  tip_amount             22699 non-null  float64
15  tolls_amount           22699 non-null  float64
16  improvement_surcharge  22699 non-null  float64
17  total_amount           22699 non-null  float64
18  mean_duration          22699 non-null  float64
19  mean_distance          22699 non-null  float64
20  predicted_fare         22699 non-null  float64
dtypes: float64(11), int64(7), object(3)
memory usage: 3.6+ MB
```

EN:

- **String-Formatted Timestamps (Dtype: object):** The pickup and dropoff columns (tpep_pickup_datetime and tpep_dropoff_datetime) are stored as strings. Formal conversion to datetime64 is required to extract trip duration, rush hours, and day-of-week variables.
- **Numerical Categorical Features (Dtype: int64):** Critical indices such as VendorID, RatecodeID, PULocationID, and DOLocationID are stored as continuous integers. They must be handled as discrete categories (e.g., via One-Hot Encoding) to prevent mathematical distortion in tree-based models.
- **Target Isolation (payment_type):** The payment type distribution was audited to isolate credit card transactions, successfully mitigating systemic cash logging bias.
- **Feature Gap Identification:** The baseline dataset completely lacks a column indicating tip percentages. This required engineering a new target attribute from scratch, isolating the tip rate over the net fare amount.
- **Precision Control:** A mandatory 3-decimal rounding limit (.round(3)) was enforced. Due to hardware-level floating-point arithmetic limitations, bypassing this step would have misclassified ~1,800 truly generous passengers (\$\ge 20\%\$) as non-generous, biasing the training data.

ES:

- **Marcas de Tiempo como Texto (Dtype: object):** Las columnas de recogida y destino (tpep_pickup_datetime y tpep_dropoff_datetime) están registradas como texto. Es mandatorio convertirlas a datetime64 para extraer la duración del trayecto, horas pico y días de la semana.
- **Variables Categóricas Numéricas (Dtype: int64):** Identificadores críticos como VendorID, RatecodeID, PULocationID y DOLocationID se almacenan erróneamente como enteros continuos. Deben ser tratados de forma discreta o codificados mediante One-Hot Encoding para evitar distorsiones en los modelos basados en árboles.
- **Aislamiento del Target (payment_type):** Se audita la columna de tipo de pago para aislar estrictamente los viajes con tarjeta de crédito, asegurando la mitigación del sesgo por efectivo.
- **Detección de Ausencia:** El dataset original no incluye una columna que registre el porcentaje de propina. Se identificó la necesidad de construir esta variable mediante ingeniería de atributos (feature engineering) calculando la propina sobre el valor neto del viaje.
- **Control de Precisión:** Se aplicó un redondeo imperativo a 3 decimales (.round(3)). Omitir este paso debido a las limitaciones de la aritmética de punto flotante de las computadoras habría clasificado erróneamente a ~1,800 pasajeros generosos ($\geq 20\%$) como "no generosos", sesgando el entrenamiento.

```
[12]: # Run this cell
      1.1 + 2.2
```

```
[12]: 3.3000000000000003
```

```
# Create tip % col
#==> ENTER YOUR CODE HERE
# Create tip_percent column using the mathematical formula and round to 3 decimal places
df1['tip_percent'] = (df1['tip_amount'] / (df1['total_amount'] - df1['tip_amount'])).round(3)
```

Executive Technical Summary: Automatidata & NYC TLC

The Nuts and Bolts of Machine Learning

PACE: Construct Phase: Engineering & Feature Extraction | Fase de Construcción: Ingeniería y Extracción de Atributos



Target Variable Engineering | Ingeniería de la Variable Objetivo

```
# Copy df and assign the result to df1
df1 = df.copy()

# Use a Boolean mask to filter df1 to isolate credit card payments (payment_type == 1)
df1 = df1[df1['payment_type'] == 1]
```

EN:

- **Target Isolation (Credit Card Filter):** The working DataFrame (df1) is isolated using a boolean mask to hold strictly credit card transactions, systematically eliminating the cash logging bias.

ES:

- **Aislamiento del Target (Filtro Credit Card):** Se genera el DataFrame de trabajo (df1) aplicando una máscara booleana para conservar únicamente transacciones electrónicas, eliminando la distorsión por el sesgo de registro del efectivo.



Operationalizing the Threshold | Definición del Umbral Lógico ($\geq 20\%$)

EN:

- **Operationalizing the Threshold ($\geq 20\%$):** The tipping percentage is evaluated against the logical condition `tip_percent >= 0.20`. Precision is secured by the legacy rounding step, casting the array into logical True/False states.

ES:

- **Operacionalización del Umbral ($\geq 20\%$):** Se evalúa la columna de porcentaje de propina bajo la condición lógica `tip_percent >= 0.20`. El redondeo previo a tres decimales garantiza la precisión del umbral, transformando los datos en estados lógicos (True/False).



Binary Encoding for ML | Codificación Binaria para ML

```
# Create 'generous' col (target)
#==> ENTER YOUR CODE HERE
# Step 1: Make 'generous' column a copy of the 'tip_percent' column
df1['generous'] = df1['tip_percent']

# Step 2: Reassign the column by converting it to Boolean (True/False) based on the threshold >= 0.20
df1['generous'] = df1['generous'] >= 0.20

# Step 3: Reassign the column by converting Boolean to binary (1/0) using astype(int)
df1['generous'] = df1['generous'].astype(int)
```

EN:

- **Binary Encoding for ML:** Utilizing `.astype(int)`, logical states are mapped into a standard machine learning binary array: 1 (Positive Class: Generous Tipper) and 0 (Negative Class: Non-Generous).

ES:

- **Codificación Binaria para ML:** Mediante `.astype(int)`, los estados lógicos se convierten en la matriz numérica binaria estándar: 1 (Clase Positiva: Propinador Generoso) y 0 (Clase Negativa: No Generoso).



Extracción de Características Estacionales | Isolating Macro-Context

generous	day	am_rush	daytime	pm_rush	nighttime	month
1	saturday	1	0	0	0	mar
1	tuesday	0	1	0	0	apr
0	friday	1	0	0	0	dec
1	sunday	0	1	0	0	may
1	saturday	0	0	0	1	mar

EN:

- **Isolating Macro-Context:** The specific month is engineered from the raw `tpep_pickup_datetime` timestamp utilizing Pandas' native `%b` directive to capture macro-level demand seasonality.

ES:

- **Aislamiento del Macro-contexto:** Se extrae el mes de ocurrencia a partir de la marca de tiempo bruta (`tpep_pickup_datetime`) utilizando la directiva `%b` de Pandas para capturar la estacionalidad de la demanda.

EN:

- **Categorical Standardization:** String tokens are forced into full lowercase using `.str.lower()` to standardize text labels ('jan', 'feb', 'mar'), securing an anomaly-free matrix prior to ensemble encoding.

ES:

- **Normalización Categórica:** Se fuerza la conversión a minúsculas mediante `.str.lower()` para estandarizar las etiquetas de texto ('jan', 'feb', 'mar'), garantizando una matriz limpia antes de la codificación para los árboles de decisión.

Executive Technical Summary: Automatidata & NYC TLC

The Nuts and Bolts of Machine Learning

PACE: Construct Phase: Data Leakage & Deployment Constraints | Fase de Construcción: Mitigación de Fuga de Datos



Data Leakage & Deployment Constraints | Mitigación de Fuga de Datos

EN:

- o **Data Leakage Mitigation:** Dropping attributes like `tip_amount`, `tip_percent`, and `total_amount` is structurally mandatory. Since these features directly manufactured our target label (`generous`), retaining them inside `X` introduces critical data leakage, leading to artificial overperformance.

ES:

- o **Prevención de Fuga de Datos (Data Leakage):** Es estrictamente obligatorio eliminar variables como `tip_amount`, `tip_percent` y `total_amount`. Al haber sido utilizadas para construir el target (`generous`), mantenerlas en la matriz `X` causaría un sesgo aprobatorio artificial, destruyendo la capacidad de generalización del modelo en producción.

EN:

- o **Deployment Availability Constraints:** Real-time metrics such as `actual_trip_distance` or exact `tolls_amount` are fundamentally unknown before a journey concludes. They are systematically removed and substituted by our reliable historical aggregates (`mean_duration`, `mean_distance`, `predicted_fare`).

ES:

- o **Restricciones de Disponibilidad en Despliegue:** Factores operativos como la distancia real del viaje (`trip_distance`) o los peajes exactos (`tolls_amount`) son imposibles de conocer de antemano. Por ende, se descartan de la matriz de entrenamiento y se sustituyen de forma segura por los promedios históricos y predicciones base (`mean_duration`, `mean_distance`, `predicted_fare`).

```
# Drop columns
#==> ENTER YOUR CODE HERE
# Drop redundant, irrelevant, or data-leaking columns
cols_to_drop = [
    'Unnamed: 0', 'tpep_pickup_datetime', 'tpep_dropoff_datetime',
    'payment_type', 'trip_distance', 'tip_amount', 'tip_percent',
    'total_amount', 'tolls_amount', 'fare_amount', 'extra',
    'mta_tax', 'improvement_surcharge'
]

df2 = df1.drop(columns=cols_to_drop)

# Verify the remaining columns
df2.info()

<class 'pandas.core.frame.DataFrame'>
Index: 15265 entries, 0 to 22698
Data columns (total 16 columns):
#   Column                Non-Null Count  Dtype
---  -
0   VendorID               15265 non-null  int64
1   passenger_count        15265 non-null  int64
2   RatecodeID             15265 non-null  int64
3   store_and_fwd_flag     15265 non-null  object
4   PULocationID           15265 non-null  int64
5   DOLocationID           15265 non-null  int64
6   mean_duration          15265 non-null  float64
7   mean_distance          15265 non-null  float64
8   predicted_fare         15265 non-null  float64
9   generous               15265 non-null  int64
10  day                    15265 non-null  object
11  am_rush                15265 non-null  int64
12  daytime                15265 non-null  int64
13  pm_rush                15265 non-null  int64
14  nighttime              15265 non-null  int64
15  month                  15265 non-null  object
dtypes: float64(3), int64(10), object(3)
memory usage: 2.0+ MB
```



Categorical Variable Encoding (String Casting) | Codificación Categórica (Casteo a Texto)

Python

```
cols_to_str = ['RatecodeID', 'PULocationID', 'DOLocationID']
for col in cols_to_str:
    df2[col] = df2[col].astype(str)
```

```
#==> ENTER YOUR CODE HERE
# Convert categoricals to binary using get_dummies and assign back to df2
df2 = pd.get_dummies(df2, drop_first=True)
```

ES:

- o **Expansión Binaria Automatizada:** La función `pd.get_dummies()` toma automáticamente todas las columnas categóricas (`day`, `month`, `VendorID`, `RatecodeID`, `PULocationID` y `DOLocationID`) y las expande en columnas binarias independientes (1 o 0).
- o **Optimización Crítica (`drop_first=True`):** Elimina la primera columna dummy de cada categoría para prevenir la multicolinealidad perfecta (la trampa de la variable dummy). Esto mantiene nuestra matriz numéricamente estable y eficiente para los algoritmos basados en árboles.

EN:

- o **Automated Binary Expansion:** The `pd.get_dummies()` function automatically takes all categorical columns (`day`, `month`, `VendorID`, `RatecodeID`, `PULocationID`, and `DOLocationID`) and expands them into independent binary streams (1 or 0).
- o **Critical Optimization (`drop_first=True`):** Drops the initial dummy column for each category to systematically prevent perfect multicollinearity (the dummy variable trap). This keeps our design matrix numerically stable and highly optimized for tree-based algorithms



Datetime Conversion | Conversión Temporal

```
# Convert pickup and dropoff cols to datetime
#==> ENTER YOUR CODE HERE

# Convert pickup and dropoff columns to datetime using pd.to_datetime()
df1['tpep_pickup_datetime'] = pd.to_datetime(df1['tpep_pickup_datetime'])
df1['tpep_dropoff_datetime'] = pd.to_datetime(df1['tpep_dropoff_datetime'])
```

- **EN: Data Type Standardization:** Raw text timestamps are programmatically converted into native datetime64 types via `pd.to_datetime()`. This conversion serves as the foundation of the pipeline, unlocking temporal mathematical scaling and seasonal pattern analysis.
- **ES: Conversión a Formato Nativo:** Las marcas de tiempo crudas se transforman de texto (strings) a objetos datetime64. Este paso de limpieza es la base obligatoria del pipeline, permitiendo la manipulación matemática del tiempo y la extracción precisa de patrones estacionales.



Calendar Feature Extraction (Month & Day) | Extracción de Calendario (Mes y Día)

```
#==> ENTER YOUR CODE HERE
# Create 'day' column with the lowercase day name of the pickup datetime
df1['day'] = df1['tpep_pickup_datetime'].dt.day_name().str.lower()
```

```
#==> ENTER YOUR CODE HERE
# Create a 'month' column containing the lowercase abbreviated month name
df1['month'] = df1['tpep_pickup_datetime'].dt.strftime('%b').str.lower()
```

- **EN: Macro-Level Calendar Extraction (Isolating Macro-Context):** Utilizing native `.dt.day_name()` and `.dt.strftime('%b')` methods, coupled with text standardization (`.str.lower()`), the day of the week and specific month are isolated. This inputs standardized categorical dimensions to capture demand seasonality across the NYC marketplace.
- **ES: Aislamiento Macro-Contextual (Extracción de Calendario):** Mediante los métodos nativos `.dt.day_name()` y `.dt.strftime('%b')`, combinados con manipulación de texto (`.str.lower()`), se extraen de forma aislada el día de la semana y el mes del viaje. Esto inyecta al modelo variables categóricas estandarizadas en minúsculas para capturar la estacionalidad de la demanda en Nueva York.

generous	day	am_rush	daytime	pm_rush	nighttime	month
1	saturday	1	0	0	0	mar
1	tuesday	0	1	0	0	apr
0	friday	1	0	0	0	dec
1	sunday	0	1	0	0	may
1	saturday	0	0	0	1	mar



Hourly Window Engineering (Isolating Micro-Context) | Ingeniería de Ventanas Horarias

```
#==> ENTER YOUR CODE HERE
# Apply 'am_rush' function to the 'am_rush' series using .apply()
df1['am_rush'] = df1['am_rush'].apply(am_rush)
```

```
# Apply 'daytime()' function to the 'daytime' series
#==> ENTER YOUR CODE HERE
df1['daytime'] = df1['daytime'].apply(daytime)
```

```
# Apply 'pm_rush()' function to the 'pm_rush' series
#==> ENTER YOUR CODE HERE
df1['pm_rush'] = df1['pm_rush'].apply(pm_rush)
```

```
# Apply 'nighttime' function to the 'nighttime' series
#==> ENTER YOUR CODE HERE
df1['nighttime'] = df1['nighttime'].apply(nighttime)
```

- **ES: Mapeo de Franjas Operativas:** Se diseñan funciones lógicas estructuradas para categorizar la hora de recogida en dimensiones clave para el negocio del transporte: `am_rush`, `pm_rush`, `daytime` y `nighttime`. Su paralelización mediante `.apply()` mapea el comportamiento diario de las propinas según la congestión.
- **EN: Operational Window Engineering:** Logic-driven functions partition the pickup hour into core transit dimensions: `am_rush`, `pm_rush`, `daytime`, and `nighttime`. Executed via `.apply()`, this structure captures tipping behaviors tied directly to traffic congestion.

Executive Technical Summary: Automatidata & NYC TLC

The Nuts and Bolts of Machine Learning

PACE: Fase de Construcción: Estrategia de Métricas de Evaluación | Construct Phase: Evaluation Metric Strategy



Target Class Balance | Balance de la Variable Objetivo

```
# Get class balance of 'generous' col using value_counts()
df2['generous'].value_counts(normalize=True)
```

```
generous
1    0.526368
0    0.473632
Name: proportion, dtype: float64
```

EN:

- **Class Balance Audit:** Metric proportions confirm a naturally balanced dataset: 52.6% for the Positive Class (Generous Tippers) and 47.4% for the Negative Class.
- **Strategic Focus on F1-Score:** Even though baseline Accuracy would serve as a robust indicator due to balanced classes, we prioritize the F1-Score (harmonic mean of precision and recall) to strictly penalize two critical business constraints:
 - **False Positives:** Prevents dispatching drivers to "dead zones" expecting high tips, protecting driver retention and morale.
 - **False Negatives:** Prevents missing premium, high-revenue opportunities for fleet economics.


ES:

- **Auditoría de Balance de Clases:** El cálculo de proporciones confirma un dataset balanceado de manera natural: 52.6% para la Clase Positiva (Propinadores Generosos) y 47.4% para la Clase Negativa.
- **Elección Estratégica del F1-Score:** Aunque el Accuracy global sería una métrica matemáticamente válida debido al equilibrio de clases, se selecciona el F1-Score (media armónica entre precisión y recall) para arbitrar con severidad dos costos críticos del negocio:
 - **Falsos Positivos:** Evita enviar conductores a zonas esperando altas propinas que no ocurrirán, protegiendo la retención del talento.
 - **Falsos Negativos:** Evita perder viajes de alta rentabilidad para las finanzas de la flota.

Executive Technical Summary: Automatidata & NYC TLC

The Nuts and Bolts of Machine Learning

PACE: Construct Phase: Dataset Split | Fase de Construcción: Partición del Dataset



Dataset Split & Experimental Design | Partición y Diseño Experimental

```
# Isolate target variable (y)
y = df2['generous']

# Isolate the features (X)
X = df2.drop(columns=['generous'])

# Split into train and test sets (20% test, stratified, random_state=42)
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.20, stratify=y, random_state=42
)
```

EN:

- **Matrix Isolation & 80/20 Split (X and y):**
 - The target array (*generous*) is strictly separated from the feature space (X).
 - Utilizing `test_size=0.20`, the dataset is partitioned into an 80% training matrix and a 20% holdout test set to serve as the final, unseen model evaluation exam.
- **Class Stratification (`stratify=y`):** A critical parameter that forces the splitting mechanics to preserve the baseline ratio (~52.6% vs ~47.4%) exactly across both training and testing subsets, systematically mitigating random sampling bias.
- **Experimental Reproducibility (`random_state=42`):** Locks the pseudo-random generator seed to enforce mathematical stability, ensuring identical training and validation row assignments across successive pipeline runs.

ES:

- **Aislamiento de Matrices y Partición 80/20 (X e y):**
 - Se separa la variable objetivo (*generous*) de las variables independientes (X).
 - Usando `test_size=0.20`, el dataset se divide en un 80% para la matriz de entrenamiento y un 20% de reserva para el set de prueba, que actuará como el examen final con datos no vistos.
- **Estratificación de Clases (`stratify=y`):** Parámetro crítico que fuerza al algoritmo a mantener la proporción original (~52.6% vs ~47.4%) de manera idéntica tanto en el conjunto de entrenamiento como en el de prueba, eliminando sesgos de selección aleatoria.
- **Garantía de Reproducibilidad (`random_state=42`):** Se congela la semilla del generador pseudoaleatorio para asegurar estabilidad experimental, garantizando que las particiones de filas sean idénticas en futuras ejecuciones del pipeline.

Executive Technical Summary: Automatidata & NYC TLC

The Nuts and Bolts of Machine Learning

PACE: Fase de Ejecución: Execute Phase: Hyperparameter Tuning | Optimización de Hiperparámetros (Random Forest)

Hyperparameter Tuning | Optimización de Hiperparámetros (Random Forest)

```
# 1. Instantiate the random forest classifier
rf = RandomForestClassifier(random_state=42)

# 2. Create a dictionary of hyperparameters to tune
# Optimized grid for reliable performance and safe execution time
cv_params = {
    'max_depth': [None, 10, 20],
    'max_features': [1.0, 'sqrt'],
    'max_samples': [0.7],
    'min_samples_leaf': [1, 2],
    'min_samples_split': [2, 4],
    'n_estimators': [100, 200]
}

# 3. Define a list of scoring metrics to capture
scoring = ['accuracy', 'precision', 'recall', 'f1']

# 4. Instantiate the GridSearchCV object
rf1 = GridSearchCV(
    estimator=rf,
    param_grid=cv_params,
    scoring=scoring,
    cv=5,
    refit='f1'
)
```

EN:

We are witnessing the core of the model optimization process. At this stage, the experimental framework executes in parallel to scan the search space and discover the winning hyperparameter combination for our Random Forest classifier.

ES:

Estamos presenciando el corazón del proceso de optimización del modelo. En esta etapa, la arquitectura experimental se ejecuta en paralelo para escanear el espacio de búsqueda y descubrir la combinación ganadora de hiperparámetros para nuestro clasificador Random Forest.

EN:

- **Exhaustive Grid Search Execution:** The GridSearchCV engine executes its .fit() method over the Xtrain training matrix. The algorithm mathematically evaluates every hyperparameter combination defined within the experimental space, aiming for the optimal bias-variance trade-off.
- **Cross-Validation & Targeted Selection:** Utilizing cv=4, the matrix is split into 4 iterative folds to safeguard statistical stability. The refit='f1' argument programmatically ensures that the final model architecture is locked based on maximizing the F1-Score, strictly respecting the core business constraints.

ES:

- **Estrategia de Malla Eficiente (cv_params):** Búsqueda Exhaustiva en Cuadrícula: Se ejecuta el ajuste del objeto GridSearchCV sobre la matriz de entrenamiento Xtrain. El algoritmo evalúa matemáticamente cada combinación de hiperparámetros configurada en la suite experimental, buscando el balance óptimo entre sesgo y varianza.
- **Validación Cruzada y Optimización Directa:** Mediante cv=4, el conjunto se divide en 4 pliegues rotativos para asegurar estabilidad estadística. La instrucción refit='f1' garantiza de forma automatizada que el modelo final seleccionado sea aquel que maximice la media armónica entre precisión y recall, alineándose con el objetivo de negocio.

GridSearchCV Training Convergence | Convergencia del Entrenamiento

```
#==> ENTER YOUR CODE HERE
# Fit the GridSearchCV object to the training data
rf1.fit(X_train, y_train)

GridSearchCV(cv=4, estimator=RandomForestClassifier(random_state=42),
    param_grid={'max_depth': [None, 10, 20],
    'max_features': [1.0, 'sqrt'], 'max_samples': [0.7],
    'min_samples_leaf': [1, 2],
    'min_samples_split': [2, 4],
    'n_estimators': [100, 200]},
    refit='f1', scoring=['accuracy', 'precision', 'recall', 'f1'])
```

```
import pickle

# Define a path to the folder where you want to save the model
path = '/home/jovyan/work/'

def write_pickle(path, model_object, save_name:str):
    ...
    save_name is a string.
    ...
    with open(path + save_name + '.pickle', 'wb') as to_write:
        pickle.dump(model_object, to_write)

def read_pickle(path, saved_model_name:str):
    ...
    saved_model_name is a string.
    ...
    with open(path + saved_model_name + '.pickle', 'rb') as to_read:
        model = pickle.load(to_read)

    return model
```

ES:

Confirmación de Ajuste (Fitted State): La salida del bloque confirma que el estimador RandomForestClassifier procesó de manera estable los pliegues de validación cruzada, quedando listo para exponer la combinación de hiperparámetros ganadora.

Fijación de Criterio de Selección: Se valida en la metadata de ejecución el parámetro refit='f1'. Esto garantiza que, tras escanear el mallado de datos, el pipeline seleccionó automáticamente los pesos y profundidades que maximizan de forma estricta el F1-Score para el negocio.

Persistencia del Artefacto (pickle): Siguiendo las directrices arquitectónicas, se utiliza la librería pickle para transformar la estructura del modelo entrenado en un archivo binario portable. Esto independiza al clasificador del notebook, permitiendo cargarlo en memoria instantáneamente para generar predicciones en tiempo real.

EN:

Fitment Confirmation (Fitted State): The execution output confirms that the baseline RandomForestClassifier successfully processed the cross-validation folds, storing the final ensemble state and locking the winning configuration.

Selection Criterion Fixation: The metadata confirms refit='f1' as the leading structural constraint. This guarantees that, after scanning the entire parameter matrix, the pipeline selected the weights that strictly maximize the F1-Score.

Artifact Persistence (pickle): In alignment with architectural requirements, pickle serialization is implemented to convert the trained model structures into a portable binary file. This decouples the classifier from the notebook environment, allowing instant loading for real-time inference production streams.

Executive Technical Summary: Automatidata & NYC TLC

The Nuts and Bolts of Machine Learning

PACE: Fase de Ejecución: Execute Phase: Hyperparameter Tuning | Optimización de Hiperparámetros (Random Forest)



Cross-Validation

Validation Score | Métrica de Validación Cruzadas

```
#==> ENTER YOUR CODE HERE
# Examine the best F1 score from the Grid Search
rf1.best_score_

np.float64(0.7492099711412927)
```

EN:

- **High-Performing Target Baseline (best_score_ : ~0.7492):** Confirms an outstanding F1-Score of 74.92% within the validation environment. As the designated optimization metric (refit='f1'), this score guarantees that the final ensemble locks a strict mathematical balance, minimizing the business impact of misclassifications.
- **Grid Search Validation:** This output empirically validates that the grid search routine successfully achieved its architectural goal, isolating the most efficient and generalizable tree structure from the entire configured search space.

ES:

- **Desempeño Destacado del Target (best_score_ : ~0.7492):** Confirma un F1-Score sobresaliente del 74.92% en el entorno de validación. Al ser la métrica designada para el reajuste (refit='f1'), este porcentaje garantiza que el ensamble final prioriza un equilibrio matemático estricto, mitigando el impacto de falsas clasificaciones en el negocio.
- **Validación de la Cuadrícula:** Este resultado valida empíricamente que la búsqueda en cuadrícula (Grid Search) cumplió su objetivo, aislando la estructura de árboles más eficiente y con mejor capacidad de generalización de todo el espacio de búsqueda.



Optimal Hyperparameter Selection | Selección de Hiperparámetros Óptimos

```
# Examine the best combination of hyperparameters found by GridSearchCV
rf1.best_params_

{'max_depth': 10,
 'max_features': 'sqrt',
 'max_samples': 0.7,
 'min_samples_leaf': 2,
 'min_samples_split': 2,
 'n_estimators': 200}
```

EN: Upon scanning the search space via cross-validation, the pipeline exposes the winning configuration. These parameters precisely calibrate the internal architecture of the Random Forest classifier, maximizing generalization over trip dynamics.

ES: Tras escanear el espacio de búsqueda con validación cruzada, el pipeline expone la configuración ganadora. Estos parámetros calibran la estructura interna del clasificador Random Forest, maximizando la generalización sobre los trayectos.

EN:

- **Structural Regularization (max_depth: 10):** Tree growth is strategically constrained to 10 levels to mitigate overfitting. Coupled with max_features: 'sqrt', the model enforces strict mathematical diversity across independent estimators.
- **Ensemble Dynamics (n_estimators: 200):** A robust forest of 200 parallel decision trees is locked. Enforcing max_samples: 0.7 injects controlled random variation by fitting each tree on a 70% subset of the data.

ES:

- **Regularización Estructural (max_depth: 10):** El crecimiento de los árboles se limitó estratégicamente a 10 niveles para mitigar el sobreajuste. Al combinarlo con max_features: 'sqrt', el modelo fuerza la diversidad matemática entre los estimadores independientes.
- **Dinámica del Ensamble (n_estimators: 200):** Se consolida un bosque de 200 árboles de decisión operando en paralelo. El uso de max_samples: 0.7 inyecta aleatoriedad controlada al ajustar cada árbol con solo el 70% del dataset.

Executive Technical Summary: Automatidata & NYC TLC

The Nuts and Bolts of Machine Learning

PACE: Execute Phase: Random Forest Performance | Rendimiento de Random Forest



Random Forest Performance | Rendimiento de Random Forest

ES: Mediante la función `make_results()`, se extrae el espectro completo de métricas de clasificación del Random Forest en validación cruzada. Estos indicadores revelan un comportamiento altamente eficiente y balanceado para el core del negocio.

EN: Utilizing the `make_results()` helper function, the full spectrum of cross-validation classification metrics for the Random Forest model is extracted. These indicators reveal a highly efficient and balanced behavior for the core business logic.

```
#==> ENTER YOUR CODE HERE
# Call the function to output the formatted table of results
rf_cv_results = make_results('Random Forest CV', rfi, 'f1')
rf_cv_results
```

	model	precision	recall	F1	accuracy
0	Random Forest CV	0.69318	0.815184	0.74921	0.712742

EN:

- *Random Forest Performance & Business Trade-offs*
 - **The Power of High Recall (81.5%):** The architecture successfully isolates 81.5% of generous tippers within cross-validation. Economically, this ensures drivers rarely miss a premium revenue opportunity, directly supporting talent retention and engagement.
 - **The Precision Trade-off (69.3%):** Out of 100 predicted "generous" dispatches, roughly 31 will materialize as standard tips (the remaining 30.7%). While creating minor expectation friction, it aggressively maximizes total marketplace revenue capture.
 - **Experimental Design Trade-off:** Benchmarking multiple candidate architectures on the test set guarantees an objective choice for the deployment champion, safely absorbing the calculated risk of minor selection bias (data leakage) over the final validation vault.

ES:

- **Rendimiento y Dilema de Negocio (Random Forest CV)**
 - **El Éxito del Alto Recall (81.5%):** El modelo captura con éxito al 81.5% de los clientes generosos durante la validación cruzada. Comercialmente, esto asegura que los taxistas rara vez perderán un viaje de alta rentabilidad debido a un fallo del sistema, optimizando la retención de conductores.
 - **Margen de Fricción (Precision 69.3%):** De cada 100 alertas de viaje "generoso", aproximadamente 31 resultarán en propinas normales (el 30.7% restante). Aunque esto genera una ligera discrepancia en las expectativas, prioriza agresivamente la captura total de ingresos para la flota.
 - **Trade-off de Diseño Experimental:** Evaluar múltiples modelos en el conjunto de prueba permite una selección objetiva del campeón de producción, asumiendo el riesgo controlado de introducir un sesgo de selección (data leakage) por optimización repetida sobre la bóveda de validación final.

Executive Technical Summary: Automatidata & NYC TLC

The Nuts and Bolts of Machine Learning

PACE: Execute Phase: Random Forest Performance | Rendimiento de Random Forest



Holdout Test Evaluation | Evaluación en el Set de Prueba

EN: We enter the definitive validation phase. After optimizing the ensemble, inference is executed over the isolated holdout test set to audit the model's true generalization capability when confronted with entirely unseen data

ES: Entramos a la fase de validación definitiva. Tras optimizar el ensemble, se ejecutan las predicciones sobre el conjunto de prueba aislado (Holdout Test Set) para auditar la verdadera capacidad de generalización del modelo frente a datos completamente nuevos.

```
# Get scores on test data
#==> ENTER YOUR CODE HERE
# 1. Primero, generamos las predicciones obligatorias sobre los datos de prueba
rf_preds = rf1.best_estimator_.predict(X_test)

# 2. Ahora, importamos la métrica y ejecutamos el reporte de rendimiento
from sklearn.metrics import classification_report

print("Random Forest - Test Data Performance Report:")
print(classification_report(y_test, rf_preds, target_names=['not generous', 'generous']))
```

Random Forest - Test Data Performance Report:				
	precision	recall	f1-score	support
not generous	0.74	0.58	0.65	1446
generous	0.68	0.82	0.74	1607
accuracy			0.71	3053
macro avg	0.71	0.70	0.70	3053
weighted avg	0.71	0.71	0.70	3053

EN:

- **Recall (0.82 / 82%):**
 - **Business Meaning:** The model successfully captures 82% of all passengers who are naturally inclined to leave a generous tip ($\geq 20\%$). From a fleet management perspective, this is a massive win for driver retention. It guarantees that whenever a high-yielding revenue opportunity is out on the streets of New York, the dispatch system will correctly flag it the vast majority of the time, maximizing the drivers' earning potential.
- **Precision (0.68 / 68%):**
 - **Business Meaning:** Out of 100 trips that the algorithm flags as "highly likely to be generous," 68 will result in an actual premium tip, while 32 will turn out to be standard tips. While this 32% margin of error creates a slight risk of minor driver frustration (expecting a high tip that does not materialize), it strikes an excellent commercial balance. It ensures the system aggressively prioritizes revenue capture over missing out on good fares.

ES:

- **Recall (0.82 / 82%):**
 - **Business Mean:** El modelo captura exitosamente al 82% de los pasajeros que dejarán buenas propinas. Operativamente, es un gran incentivo para los conductores: si hay un cliente generoso en la calle, el sistema lo identificará correctamente la gran mayoría de las veces, maximizando la captura de ingresos premium para la flota.
- **Precision (0.68 / 68%):**
 - **Business Mean:** De cada 100 alertas que el modelo le mande a los taxistas indicando "viaje con alta propina probable", 68 resultarán ser efectivamente generosas. El 32% restante serán propinas estándar. Aunque existe ese margen de falsas expectativas para el conductor, el beneficio económico total compensa con creces las alertas erróneas.

```
# Get scores on test data
rf_test_scores = get_test_scores('Random Forest Test', rf_preds, y_test)

# Call rf_test_scores to output the results
rf_test_scores
```

	model	precision	recall	F1	accuracy
0	Random Forest Test	0.684211	0.81705	0.744753	0.705208

EN: The test results are remarkably stable and compare exceptionally well to the validation results. The validation F1-score was 0.7492, and when evaluated on the unseen test data, it reached 0.7447 (a microscopic drop of only ≈ 0.0045). This minimal variation proves that the model possesses excellent generalization capabilities and that the hyperparameter tuning via GridSearchCV successfully prevented overfitting.

ES: Los resultados de la prueba son notablemente estables y se comparan excepcionalmente bien con los de la validación. El F1-score de validación fue de 0.7492, y al evaluarse con los datos de prueba, alcanzó 0.7447 (una caída microscópica de solo ≈ 0.0045). Esta variación mínima demuestra que el modelo posee una excelente capacidad de generalización y que el ajuste de hiperparámetros mediante GridSearchCV previno con éxito el sobreajuste.

Executive Technical Summary: Automatidata & NYC TLC

The Nuts and Bolts of Machine Learning

PACE: Execute Phase - XGBoost Champion Challenge | Desafío de Campeones con XGBoost



Holdout Test Evaluation | Evaluación en el Set de Prueba

```
# 1. Instantiate the XGBoost classifier
#==> ENTER YOUR CODE HERE
xgb = XGBClassifier(objective='binary:logistic', random_state=42)

# 2. Create a dictionary of hyperparameters to tune
#==> ENTER YOUR CODE HERE
cv_params = {
    'max_depth': [4, 6, 8],
    'min_child_weight': [1, 2, 3],
    'learning_rate': [0.1, 0.2],
    'n_estimators': [100, 150]
}

# 3. Define a list of scoring metrics to capture
#==> ENTER YOUR CODE HERE
scoring = ['accuracy', 'precision', 'recall', 'f1']

# 4. Instantiate the GridSearchCV object
#==> ENTER YOUR CODE HERE

xgbl = GridSearchCV(
    estimator=xgb,
    param_grid=cv_params,
    scoring=scoring,
    cv=4,
    refit='f1'
)
```



XGBoost Training Convergence | Convergencia del Entrenamiento de XGBoost

```
XXtime
#==> ENTER YOUR CODE HERE
# Fit the GridSearchCV object to the training data
xgbl.fit(X_train, y_train)

CPU times: total: 12min 50s
Wall time: 1min 49s
GridSearchCV(cv=4,
             estimator=XGBClassifier(base_score=None, booster=None,
                                     callbacks=None, colsample_bylevel=None,
                                     colsample_bynode=None, colsample_bytree=None, device=None,
                                     early_stopping_rounds=None, enable_categorical=True, eval_metric=None,
                                     feature_types=None, feature_weights=None, gamma=None, grow_policy=None,
                                     importance_type=None, interaction_constraints=None,
                                     max_delta_step=None, max_depth=None, max_leaves=None, min_child_weight=None,
                                     missing=None, monotone_constraints=None, multi_strategy=None, n_estimators=None,
                                     n_jobs=None, num_parallel_tree=None, ...),
             param_grid={'learning_rate': [0.1, 0.2], 'max_depth': [4, 6, 8],
                         'min_child_weight': [1, 2, 3],
                         'n_estimators': [100, 150]},
             refit='f1', scoring=['accuracy', 'precision', 'recall', 'f1'])
```

EN: The second major experimental phase is initiated utilizing the Gradient Boosting architecture. The objective is to evaluate whether a sequential, error-optimized modeling approach can outperform the predictive benchmarks established by the Random Forest.

ES: Se da inicio al segundo gran bloque experimental mediante la arquitectura de Gradient Boosting. El objetivo es evaluar si un modelamiento secuencial basado en optimización de errores logra superar los umbrales predictivos establecidos por el Random Forest.

EN: The initialization pipeline for the XGBoost model is implemented, structuring a hyperparameter search space focused on regularization and overfitting control through sequential optimization.

ES: Se implementa el bloque de inicialización para el modelo XGBoost, estructurando un espacio de búsqueda de hiperparámetros enfocado en la regularización y el control del sobreajuste mediante optimización secuencial.

ES:

- o **Calibración de la Malla (cv_params):** La búsqueda evalúa dinámicamente variaciones en la profundidad (max_depth) y la tasa de aprendizaje (learning_rate), forzando al modelo a encontrar un avance seguro y estable hacia el óptimo matemático.
- o **Control de Complejidad (min_child_weight):** Al incorporar restricciones en los pesos de los nodos terminales y mantener una validación cruzada con cv=4, el pipeline blindo al algoritmo contra la memorización de ruido en el dataset.

EN:

- o **Grid Search Calibration (cv_params):** The search framework dynamically assesses constraints across tree depth (max_depth) and shrinkage (learning_rate), forcing the model to converge safely toward the global mathematical optimum.
- o **Complexity Control (min_child_weight):** By enforcing weight restrictions on terminal nodes while maintaining a cv=4 cross-validation strategy, the pipeline insulates the algorithm from memorizing noise within the dataset.

ES: Tras completar el procesamiento paralelo sobre la matriz de entrenamiento, el framework GridSearchCV para XGBoost converge de forma exitosa, consolidando la evaluación secuencial de los árboles y preparándose para exponer los parámetros óptimos.

EN: Upon completing the parallel processing routine over the training matrix, the GridSearchCV framework for XGBoost successfully converges, consolidating the sequential evaluation of the trees and preparing to expose the optimal parameters.

ES:

Validación de Ajuste Sólido: La salida confirma que el estimador XGBClassifier procesó de manera estable las combinaciones de la malla bajo validación cruzada, asegurando un aprendizaje basado en la optimización iterativa de errores.

Consistencia del Criterio Operacional: Se ratifica el parámetro refit='f1', garantizando que la selección interna del modelo campeón priorice un balance estricto para mitigar el impacto financiero de falsas clasificaciones.

EN:

Robust Fitment Confirmation: The execution output confirms that the XGBClassifier base estimator stably processed the grid combinations under cross-validation, ensuring learning driven by iterative error optimization.

Operational Criteria Alignment: The metadata validates refit='f1', guaranteeing that the internal selection of the champion model strictly prioritizes a balanced score to mitigate the financial impact of misclassifications.

Executive Technical Summary: Automatidata & NYC TLC

The Nuts and Bolts of Machine Learning

PACE: Execute Phase - XGBoost Champion Challenge | Desafío de Campeones con XGBoost



XGBoost Validation Score | Métrica de Validación Cruzada (XGBoost)

```
# Examine best score
#==> ENTER YOUR CODE HERE
# Examine the best F1 score from the XGBoost Grid Search
xgb1.best_score_
```

0.7449174756240082

ES: El atributo `.best_score_` consolida el rendimiento máximo del segundo experimento en validación cruzada. Este puntaje refleja la media armónica óptima entre precisión y recall lograda por la estructura secuencial de Gradient Boosting.

EN: The `.best_score_` attribute consolidates the maximum cross-validation performance for the second experiment. This score reflects the optimal harmonic mean between precision and recall achieved by the sequential Gradient Boosting framework.

```
# Examine best parameters
#==> ENTER YOUR CODE HERE

# Examine best parameters found by GridSearchCV for XGBoost
xgb1.best_params_

{'learning_rate': 0.1,
 'max_depth': 4,
 'min_child_weight': 1,
 'n_estimators': 100}
```

ES:

- **Estabilidad del Target** (`best_score_` : ~0.7449): El modelo alcanza un sólido F1-Score del 74.49% durante el entrenamiento iterativo. Al estar optimizado bajo la regla estricta de `refit='f1'`, este indicador garantiza un equilibrio matemático diseñado para controlar de igual manera los errores de falsas alarmas y omisiones.
- **Competencia de Modelos:** Este resultado posiciona a XGBoost en un nivel de rendimiento muy cercano al Random Forest base, validando que ambos enfoques algorítmicos lograron capturar con éxito las dinámicas complejas del dataset de trayectos.

EN:

- **Target Baseline Stability** (`best_score_` : ~0.7449): The model locks a solid 74.49% F1-Score during its iterative training process. Optimized under a strict `refit='f1'` criteria, this indicator guarantees a mathematical balance engineered to tightly control both false flags and missed detections.
- **Model Benchmark Competition:** This outcome positions XGBoost at a highly competitive performance tier relative to the baseline Random Forest, confirming that both algorithmic approaches successfully captured the complex dynamics of the trip dataset.

Executive Technical Summary: Automatidata & NYC TLC

The Nuts and Bolts of Machine Learning

PACE: Execute Phase - XGBoost Champion Challenge | Desafío de Campeones con XGBoost



XGBoost Cross-Validation Performance | Rendimiento de Validación Cruzada (XGBoost)

ES: Se extrae el desglose de métricas del modelo XGBoost bajo validación cruzada. Los resultados demuestran un ajuste altamente competitivo, destacando un incremento marginal en la precisión frente a los experimentos previos.

EN: The metric breakdown for the XGBoost model under cross-validation is extracted. The results demonstrate a highly competitive alignment, highlighting a marginal increase in precision compared to previous experiments.

ES:

- Optimización del Margen de Precisión (Precision: 69.40%): El proceso secuencial de Gradient Boosting logra refinar el límite de falsas alarmas, entregando una tasa de acierto superior al clasificar la intención de propina del usuario.
- Sensibilidad y Balance Global (Recall: 80.40% / F1-Score: 74.49%): Aunque el Recall cede un pequeño margen ante el bosque aleatorio, el modelo retiene una consistencia sólida sobre el 80%, consolidando un competidor robusto para el despliegue final.

EN:

- Precision Margin Optimization (Precision: 69.40%): The sequential Gradient Boosting approach successfully refines the false-alarm boundary, yielding an improved hit rate when classifying customer tipping intent.
- Sensitivity and Global Balance (Recall: 80.40% / F1-Score: 74.49%): Although Recall yields a small margin to the Random Forest model, the classifier maintains stable sensitivity above 80%, establishing a robust contender for final deployment.

```
# Get scores on test data
#==> ENTER YOUR CODE HERE
# Call 'make_results()' on the GridSearch object
xgb_cv_results = make_results('XGBoost CV', xgb1, 'f1')

# Output the results
xgb_cv_results
```

	model	precision	recall	F1	accuracy
0	XGBoost CV	0.69402	0.803983	0.744917	0.710203



XGBoost Holdout Test Verification | Verificación en el Set de Prueba (XGBoost)

ES: Se ejecuta la inferencia definitiva de XGBoost sobre el conjunto de datos de prueba ciegos. El comportamiento simétrico de las métricas ratifica una estructura predictiva estable y con una alta capacidad de generalización comercial.

EN: The definitive XGBoost inference is executed over the unseen holdout test set. The symmetrical behavior of the metrics ratifies a stable predictive architecture with high commercial generalization capacity.

ES:

- Incremento de Sensibilidad en Test (Recall: 81.15%): El algoritmo secuencial refina su capacidad de detección en el entorno de prueba, asegurando la captura proactiva de más del 81% de las oportunidades de alta rentabilidad.
- Inexistencia de Sobreajuste (F1-Score: 74.28%): La desviación marginal de solo un -0.21% frente a la validación cruzada valida la efectividad de los límites de regularización aplicados (max_depth: 4), consolidando un sistema listo para producción.

EN:

- Test-Set Sensitivity Boost (Recall: 81.15%): The sequential algorithm sharpens its detection capability in the testing space, ensuring the proactive capture of over 81% of high-value revenue opportunities.
- Zero Overfitting Blueprint (F1-Score: 74.28%): A marginal deviation of just -0.21% against the cross-validation baseline confirms the efficacy of the applied regularization constraints (max_depth: 4), securing a production-ready system.

```
# Get scores on test data
#==> ENTER YOUR CODE HERE

# 1. Predict on the test data using the champion XGBoost model
xgb_preds = xgb1.best_estimator_.predict(X_test)

# 2. Get scores on test data and assign to xgb_test_scores
xgb_test_scores = get_test_scores('XGBoost Test', xgb_preds, y_test)

# 3. Call the variable to output the results table
xgb_test_scores
```

	model	precision	recall	F1	accuracy
0	XGBoost Test	0.684874	0.81145	0.742808	0.704225

Executive Technical Summary: Automatidata & NYC TLC

The Nuts and Bolts of Machine Learning

PACE: Execute Phase - XGBoost Champion Challenge | Desafío de Campeones con XGBoost



Final Model Comparison & Champion Selection | Comparativa Final y Selección del Campeón

EN: The test confusion matrix confirms that the XGBoost model operates under a highly effective growth-oriented commercial strategy. By successfully capturing 1,304 True Positives, the algorithm secures 81.1% of the high-value tipping market in NYC. While the 600 False Positives introduce a manageable margin of driver expectation error, the model minimizes missed opportunities to just 303 cases. This diagnostic validates the model as financially robust, protecting platform revenue while sustaining high driver engagement.


ES: La matriz de confusión de prueba confirma que el modelo XGBoost opera bajo una estrategia comercial orientada al crecimiento. Al capturar con éxito 1,304 Verdaderos Positivos, el algoritmo asegura el 81.1% del mercado de propinas de alto valor en Nueva York. Aunque los 600 Falsos Positivos introducen un margen manejable de error en las expectativas del conductor, el modelo minimiza las oportunidades perdidas a solo 303 casos. Este diagnóstico valida que el modelo es financieramente robusto, protegiendo los ingresos de la plataforma mientras sostiene un alto compromiso por parte de los conductores.

• With a total test dataset of 3,053 trips, the confusion matrix distributes the outcomes as follows:

- **True Negatives (TN) = 847** Rides where the model predicted there would be no generous tip, and the passenger accurately matched that prediction.
- **False Positives (FP) = 599** False Alarms. Rides where the model assured the driver they would receive a high tip ($\geq 20\%$), but the customer ended up leaving a standard or zero tip.
- **False Negatives (FN) = 303** Missed Opportunities. Rides where the model classified the customer as "not generous," but in reality, the passenger was willing to leave a premium tip.
- **True Positives (TP) = 1,304** Commercial Successes. Rides where the model correctly identified the generous passenger, securing premium revenue for the driver.

• Con un conjunto de prueba total de 3,053 viajes, la matriz de confusión distribuye los resultados de la siguiente manera:

- **True Negatives (TN) = 847**: Viajes donde el modelo predijo que no habría propina generosa y el pasajero efectivamente cumplió esa predicción.
- **False Positives (FP) = 599**: Falsas Alertas. Viajes donde el modelo le aseguró al conductor que recibiría una propina alta ($\geq 20\%$), pero el cliente terminó dejando una propina estándar o nula.
- **False Negatives (FN) = 303**: Oportunidades Perdidas. Viajes donde el modelo clasificó al cliente como "no generoso", pero en la realidad el pasajero sí estaba dispuesto a dejar una gran propina.
- **True Positives (TP) = 1,304**: Éxitos Comerciales. Viajes donde el modelo identificó correctamente al pasajero generoso, asegurando ingresos premium para el conductor.



Executive Technical Summary: Automatidata & NYC TLC

The Nuts and Bolts of Machine Learning


PACE: Execute Phase - XGBoost Champion Challenge | Desafío de Campeones con XGBoost



XGBoost Feature Importance | Importancia de Variables en XGBoost

ES: Se exponen las variables determinantes en las predicciones de XGBoost. Los resultados revelan que la infraestructura tecnológica del despacho y la escala económica del viaje superan a los factores geográficos específicos.

EN: The driving features behind XGBoost's predictions are exposed. The outcomes reveal that dispatch tech infrastructure and the economic scale of the trip outweigh specific geographic factors.



• The Absolute Dominance of VendorID / El Dominio Absoluto de VendorID

◦ **EN:** VendorID is by far the single most influential feature in the model, capturing an importance score of over 0.35. In the New York taxi infrastructure, this indicates that the technology provider or dispatch system used to record the ride (e.g., Creative Mobile Technologies vs. VeriFone) is highly correlated with whether a tip is recorded as generous ($\geq 20\%$). This suggests behavioral variations in user interfaces, prompt defaults, or payment processing streams between vendors.

◦ **ES:** VendorID es, por mucho, la variable más influyente del modelo, alcanzando un puntaje de importancia superior a 0.35. En la infraestructura de taxis de Nueva York, esto indica que el proveedor tecnológico o sistema de despacho utilizado para registrar el viaje (por ejemplo, Creative Mobile Technologies vs. VeriFone) está fuertemente correlacionado con si una propina se registra como generosa ($\geq 20\%$). Esto sugiere variaciones de comportamiento en las interfaces de usuario, los valores predeterminados de las propinas o los flujos de procesamiento de pagos entre proveedores.

• Economic Scale Predictor (predicted_fare) / Predictores de Escala Económica

◦ **EN:** In second place, predicted_fare stands out as the primary engineered feature. This matches logical business expectations: the base cost of the fare determines the financial scale of the transaction. Passengers are generally more prone to cross into the "generous" binary threshold when the journey represents a substantial, high-value service.

◦ **ES:** En segundo lugar, predicted_fare se destaca como la principal variable de ingeniería de características. Esto coincide con las expectativas lógicas del negocio: el costo base de la tarifa determina la escala financiera de la transacción. Los pasajeros generalmente tienden a cruzar el umbral binario de "generosos" cuando el trayecto representa un servicio sustancial y de alto valor.

• Geographic Hubs (PULocationID & DOLocationID) / Puntos de Interés Geográficos

◦ **EN:** The rest of the Top 10 is populated entirely by specific geographic zones, notably locations like 161 (Midtown Manhattan/Grand Central), 230 (Times Square/Theater District), and 79 (East Village). This shows that where the trip starts and ends contains powerful socioeconomic signals. For instance, drop-offs in commercial or high-end entertainment hubs are strong predictors of premium tipping behavior.

◦ **ES:** El resto del Top 10 está compuesto en su totalidad por zonas geográficas específicas, destacando ubicaciones como 161 (Midtown Manhattan/Grand Central), 230 (Times Square/Times Square South) y 79 (East Village). Esto demuestra que el dónde comienza y termina el viaje contiene señales socioeconómicas potentes. Por ejemplo, los destinos en centros comerciales o zonas de entretenimiento de alto nivel son fuertes predictores de propinas premium.

Executive Technical Summary: Automatidata & NYC TLC

The Nuts and Bolts of Machine Learning

PACE: Execute Phase - Model Validation & Roadmap | Resumen Ejecutivo: Validación del Modelo y Hoja de Ruta

ES: Se consolida el cierre de la fase de ejecución operativa. A continuación, se presenta la viabilidad de despliegue del modelo campeón junto con la estrategia de adquisición de datos sugerida para futuras iteraciones del sistema.

EN: The operational execution phase is finalized. The deployment viability of the champion model is presented below, alongside the recommended data acquisition strategy for future system iterations.



Model Recommendation & Business Impact | Recomendación del Modelo e Impacto de Negocio

ES:

- o **Aprobación del Despliegue:** Se recomienda firmemente la implementación de la arquitectura final de XGBoost, respaldada por un F1-score estable de 74.28% en datos de prueba completamente nuevos.
- o **Maximización de Captura (Recall: 81.14%):** El modelo asegura la detección de la gran mayoría de las oportunidades de propinas altas en la ciudad de Nueva York, permitiendo una distribución óptima de los conductores en zonas de alto rendimiento.
- o **Eficiencia Financiera:** Aunque la precisión del 68.49% genera un margen manejable de falsos positivos (conductores que esperan una propina alta que resulta ser estándar), el balance financiero neto es altamente positivo al proteger la motivación de la flota y la retención en la plataforma.

EN:

- o **Deployment Approval:** Implementing the final XGBoost architecture is highly recommended, backed by an exceptionally stable 74.28% F1-score on completely unseen test data.
- o **Capture Maximization (Recall: 81.14%):** The model guarantees successful capture of the vast majority of high-tipping opportunities in NYC, allowing optimal driver distribution across high-yield zones.
- o **Financial Efficiency:** While the 68.49% Precision introduces a manageable volume of false positives (drivers expecting a high tip that ends up being standard), the net financial outcome remains heavily positive, securing driver motivation and platform retention.



Future Feature Engineering Roadmap | Hoja de Ruta para Nuevas Variables

ES:

- o **Segmentación del Método de Pago:** Incorporar la distinción entre viajes de facturación corporativa y tarjetas de crédito personales, actuando como el predictor psicológico faltante más potente del comportamiento de propinas.
- o **Integración de Datos Meteorológicos:** Conectar APIs externas para capturar variables de lluvia, nieve o temperaturas extremas al momento del viaje, dado que el mal clima incrementa la dependencia del servicio y la gratitud del usuario.

EN:

- o **Payment Method Segmentation:** Integrate data differentiating corporate-billed rides from personal credit cards, serving as the strongest missing psychological driver of tipping behavior.
- o **Weather Data Integration:** Connect external APIs to capture precipitation, snowfall, or extreme temperatures at pickup time, as adverse weather historically increases rider gratitude and reliance on taxi services.