


Course Four

Regression Analysis: Simplifying Complex Data Relationships



Instructions

Use this PACE strategy document to record decisions and reflections as you work through this end-of-course project. As a reminder, this document is a resource that you can reference in the future, and a guide to help you consider responses and reflections posed at various points throughout projects.

Course Project Recap

Regardless of which track you have chosen to complete, your goals for this project are:

- ☐ Complete the questions in the Course 4 PACE strategy document
- ☐ Answer the questions in the Jupyter notebook project file
- ☐ Build a multiple linear regression model
- ☐ Evaluate the model
- ☐ Create an executive summary for team members


Relevant Interview Questions

Completing the end-of-course project will empower you to respond to the following interview topics:

- Describe the steps you would take to run a regression-based analysis
- List and describe the critical assumptions of linear regression
- What is the primary difference between R^2 and adjusted R^2 ?
- How do you interpret a Q-Q plot in a linear regression model?
- What is the bias-variance tradeoff? How does it relate to building a multiple linear regression model? Consider variable selection and adjusted R^2 .

Reference Guide

This project has seven tasks; the visual below identifies how the stages of PACE are incorporated across those tasks.



Data Project Questions & Considerations



PACE: Plan Stage

- Who are your external stakeholders for this project?

Managerial Leadership (Umar Mahmood): Reviews pipeline alignment and analytical validity. / Revisa la alineación del pipeline y la validez analítica.

Operations & Clients (DeShawn Washington): Requires optimization of trip metrics and fare transparency for drivers. / Requiere optimización de métricas de viaje y transparencia de tarifas para conductores.

Financial Strategy (Helena Jones): Leverages predictive insights to evaluate revenue growth and fleet sustainability. / Utiliza los insights predictivos para evaluar el crecimiento de ingresos y la sostenibilidad de la flota.

- What are you trying to solve or accomplish?

EN: Predict taxi fares and analyze trip patterns in New York City using exploratory data analysis (EDA) and regression modeling. The goal is to build a reliable predictive tool that helps the Taxicab Commission optimize pricing transparency and fleet operations.

ES: Predecir tarifas de taxi y analizar patrones de viaje en la ciudad de Nueva York mediante análisis exploratorio de datos (EDA) y modelado de regresión. El objetivo es



construir una herramienta predictiva confiable que ayude a la Comisión de Taxis a optimizar la transparencia de precios y las operaciones de la flota.

- What are your initial observations when you explore the data?

- *EN:* Variables like trip distance and fare amount contain extreme anomalies, including negative fares, zero distances with high costs, and massive dollar amounts that require extensive data cleaning.
- *ES:* Variables como la distancia del viaje y el monto de la tarifa contienen anomalías extremas, incluyendo tarifas negativas, distancias de cero con costos altos y montos masivos que requieren una limpieza profunda.

Data Type Alignment / Alineación de Tipos de Datos:

- *EN:* Pickup and drop-off datetime columns are stored as objects (strings) and must be converted to datetime formats to accurately calculate trip duration as a new feature.
- *ES:* Las columnas de fecha y hora de recogida y destino están almacenadas como objetos (strings) y deben convertirse a formatos datetime para calcular con precisión la duración del viaje como una nueva variable.

Highly Skewed Metrics / Métricas Altamente Sesgadas:

- *EN:* Distance and total cost metrics show a heavy right-skewed distribution; the majority of trips are short and cheap, while a minor percentage represents long, expensive airport or cross-borough commutes.
- *ES:* Las métricas de distancia y costo total muestran una distribución fuertemente sesgada a la derecha; la mayoría de los viajes son cortos y económicos, mientras que un porcentaje menor representa traslados largos y costosos a aeropuertos o entre distritos.

Inconsistent Rate Codes / Códigos de Tarifa Inconsistentes:

- *EN:* Certain standard trips do not align logically with their registered rate codes (e.g., fixed-rate JFK airport codes applied to short Manhattan rides), indicating structural data noise.
- *ES:* Ciertos viajes estándar no se alinean lógicamente con sus códigos de tarifa registrados (ej. códigos de tarifa fija de JFK aplicados a viajes cortos dentro de Manhattan), indicando ruido estructural en los datos.



- What resources do you find yourself using as you complete this stage?

- *EN:* **pandas** and **numpy** for structural data manipulation, filtering out negative values, and datetime type casting; **seaborn** and **matplotlib** to build box plots and histograms for outlier inspection.
- *ES:* **pandas** y **numpy** para la manipulación estructural de datos, filtrado de valores negativos y conversión de tipos datetime; **seaborn** y **matplotlib** para construir diagramas de caja e histogramas para la inspección de outliers.

Methodological Frameworks / Marcos Metodológicos:

- *EN:* The PACE framework to structure the workflow sequentially from Planning to Analysis, and internal project documentation specifying NYC Taxicab Commission operational rules.
- *ES:* El marco de trabajo PACE para estructurar el flujo de manera secuencial desde la Planificación hasta el Análisis, y documentación interna del proyecto que especifica las reglas operativas de la Comisión de Taxis de Nueva York.



PACE: Analyze Stage

- What are some purposes of EDA before constructing a multiple linear regression model?

Verification of Linear Assumptions / Verificación de Supuestos Lineales:

- *EN:* Assess the linear relationship between independent variables and the target (**fare_amount**) using scatter plots, and inspect residual distributions using histograms or Q-Q plots.
- *ES:* Evaluar la relación lineal entre las variables independientes y el objetivo (**fare_amount**) usando gráficos de dispersión, e inspeccionar la distribución de residuos con histogramas o gráficos Q-Q.

Multicollinearity Detection / Detección de Multicolinealidad:

- *EN:* Generate correlation matrices and heatmaps to identify highly correlated predictors (such as **trip_distance** and time-based metrics) that could destabilize model coefficients and impair interpretability.

- *ES*: Generar matrices de correlación y mapas de calor para identificar predictores altamente correlacionados (como `trip_distance` y métricas de tiempo) que puedan desestabilizar los coeficientes del modelo y afectar la interpretabilidad.

Outlier Treatment / Tratamiento de Valores Atípicos:

- *EN*: Utilize box plots to isolate extreme anomalies (e.g., negative fares or multi-thousand-dollar rides) that could disproportionately skew the ordinary least squares (OLS) regression line.
- *ES*: Utilizar diagramas de caja para aislar anomalías extremas (ej. tarifas negativas o viajes de miles de dólares) que puedan sesgar desproporcionadamente la línea de regresión de mínimos cuadrados ordinarios (OLS).

Feature Engineering and Transformation / Ingeniería y Transformación de Variables:

- *EN*: Guide mathematical transformations (like log scaling right-skewed distributions) and determine necessary categorical encodings (such as dummy variables for pickup/drop-off zones).

ES: Guiar transformaciones matemáticas (como aplicar escalas logarítmicas a distribuciones sesgadas a la derecha) y determinar las codificaciones categóricas necesarias (como variables dummy para las zonas de recogida/destino).

- Do you have any ethical considerations at this stage?

Socioeconomic Equity in Pricing / Equidad Socioeconómica en las Tarifas:

- *EN*: Over-indexing on geographic features (like specific pickup or drop-off neighborhoods) could lead to algorithmic bias, inadvertently inflating prices or reducing ride availability for lower-income areas.
- *ES*: Indexar en exceso variables geográficas (como vecindarios específicos de recogida o destino) podría generar sesgos algorítmicos, inflando precios o reduciendo la disponibilidad de viajes en zonas de menores ingresos.

Privacy and Passenger De-anonymization / Privacidad y Desanonimización de Pasajeros:

- *EN*: Even if direct identifiers are removed, combining precise pickup/drop-off coordinates with detailed timestamps risks re-identifying specific individuals' travel routines, violating privacy principles.

- *ES:* Incluso si se eliminan identificadores directos, combinar coordenadas precisas de origen/destino con marcas de tiempo detalladas corre el riesgo de re-identificar las rutinas de viaje de personas específicas, vulnerando la privacidad.

Transparency and Fair Earnings / Transparencia y Ganancias Justas:

- *EN:* The data used to train pricing algorithms must reflect transparent structures to ensure that drivers receive fair compensation and are not financially penalized by extreme, unaccounted-for data anomalies.
- *ES:* Los datos utilizados para entrenar algoritmos de precios deben reflejar estructuras transparentes para garantizar que los conductores reciban una compensación justa y no sean penalizados por anomalías extremas no contabilizadas.



PACE: Construct Stage

- Do you notice anything odd?

Tarifas Negativas y Valores en Cero (**fare_amount**):

- *EN:* There are registered trips with negative fare values and zero dollar amounts, which is mathematically impossible for a standard transaction and signals data entry errors or system glitches.
- *ES:* Existen viajes registrados con valores de tarifa negativos y montos en cero, lo cual es matemáticamente imposible para una transacción estándar y señala errores de entrada de datos o fallos del sistema.

Viajes con Distancia Cero pero Tarifas Altas:

- *EN:* Several instances show a **trip_distance** of exactly **0.0** miles, yet they charge significant fixed or variable fare amounts, indicating that time spent waiting or manual override codes are corrupting the baseline distance metric.
- *ES:* Varios registros muestran una **trip_distance** de exactamente **0.0** millas, pero cobran montos de tarifa significativos (fijos o variables), lo que indica que el tiempo de espera o códigos de anulación manual están corrompiendo la métrica de distancia base.

Inconsistencias en Códigos de Tarifa (RatecodeID):

- **EN:** Standard rides within Manhattan sometimes have flat-rate airport codes assigned (like JFK or Newark), while genuine long-distance airport trips are misclassified as standard metered rates, threatening model stability.
- **ES:** Viajes estándar dentro de Manhattan a veces tienen asignados códigos de tarifa plana de aeropuerto (como JFK o Newark), mientras que viajes reales de larga distancia a aeropuertos están mal clasificados como tarifas estándar con taxímetro, amenazando la estabilidad del modelo.

Distorsión por Propinas con Tarjeta de Crédito vs. Efectivo:

- **EN:** The `tip_amount` column only records tips paid via credit card; cash tips are systematically registered as `0.0`, which artificially underreports the true total cost of cash-based transactions.
- **ES:** La columna `tip_amount` solo registra propinas pagadas con tarjeta de crédito; las propinas en efectivo se registran sistemáticamente como `0.0`, lo que subreporta artificialmente el costo total real de las transacciones en efectivo.

- Can you improve it? Is there anything you would change about the model?

1. Feature Engineering / Ingeniería de Variables

- **Trip Duration / Duración del Viaje:**

- **EN:** Convert pickup and drop-off datetime strings into datetime objects to calculate total trip duration in minutes, capturing traffic delays that distance alone misses.
- **ES:** Convertir los strings de fecha y hora en objetos datetime para calcular la duración total del viaje en minutos, capturando retrasos por tráfico que la distancia sola no registra.

- **Temporal Features / Variables Temporales:**

- **EN:** Extract "Day of the week" and "Hour of the day" to create time-block flags (e.g., *Morning Rush Hour*, *Weekend Night*), aligning the model with dynamic urban demand.
- **ES:** Extraer el "Día de la semana" y la "Hora del día" para crear bloques horarios (ej. *Hora Punta Mañana*, *Noche de Fin de Semana*), alineando el modelo con la demanda urbana dinámica.

- **Airport Trip Indicator / Indicador de Viajes al Aeropuerto:**



- **EN:** Create a binary flag (\$1\$ or \$0\$) based on **PULocationID** and **DOLocationID** for trips involving JFK, LaGuardia, or Newark airports to isolate flat-rate pricing structures.
- **ES:** Crear una variable binaria (\$1\$ o \$0\$) basada en **PULocationID** y **DOLocationID** para viajes que involucren los aeropuertos JFK, LaGuardia o Newark, aislando las estructuras de tarifa plana.



2. Data Cleaning & Target Refinement / Limpieza de Datos y Refinamiento del Objetivo

• Filtering Anomalies / Filtrado de Anomalías:

- **EN:** Drop rows where **fare_amount** ≤ 0 and handle zero-distance trips with high costs by either removing them or imputing the distance based on location pair averages.
- **ES:** Eliminar filas donde **fare_amount** ≤ 0 y gestionar viajes con distancia cero y costos altos, ya sea removiéndolos o imputando la distancia según los promedios del par de ubicaciones.

• Target Variable Optimization / Optimización de la Variable Objetivo:

- **EN:** Shift the target variable from **total_amount** to **fare_amount** to exclude **tip_amount**, as credit card tips are tracked but cash tips are missing, which distorts the OLS baseline.
- **ES:** Cambiar la variable objetivo de **total_amount** a **fare_amount** para excluir **tip_amount**, ya que se registran las propinas con tarjeta pero faltan las de efectivo, lo que distorsiona la base OLS.



3. Model Architecture Changes / Cambios en la Arquitectura del Modelo

• Logarithmic Transformation / Transformación Logarítmica:

- **EN:** Apply a log transformation ($\log(y)$) to the target variable to stabilize residuals and handle the heavily right-skewed distribution of NYC taxi fares.
- **ES:** Aplicar una transformación logarítmica ($\log(y)$) a la variable objetivo para estabilizar los residuos y manejar la distribución fuertemente sesgada a la derecha de las tarifas de Nueva York.

• Tree-Based Machine Learning / Aprendizaje Automático Basado en Árboles:

- **EN:** Propose migrating from Multiple Linear Regression to tree-based ensemble models (**Random Forest** or **XGBoost**) to natively capture non-linear feature interactions without breaking OLS assumptions.



- **ES:** Proponer la migración de Regresión Lineal Múltiple a modelos de ensamble basados en árboles (**Random Forest** o **XGBoost**) para capturar de forma nativa interacciones no lineales sin romper los supuestos de OLS.

- What resources do you find yourself using as you complete this stage?

Python Data Stack / Stack de Datos de Python:

- **EN:** **pandas** and **numpy** for structural data manipulation, filtering out mathematical noise, and datetime type casting; **seaborn** and **matplotlib** to construct box plots and correlation heatmaps for outlier inspection.
- **ES:** **pandas** y **numpy** para la manipulación estructural de datos, filtrado de ruido matemático y conversión de tipos datetime; **seaborn** y **matplotlib** para construir diagramas de caja y mapas de calor de correlación para la inspección de outliers.

Methodological & Operational Frameworks / Marcos Metodológicos y Operativos:

- **EN:** The structured guidelines of the PACE framework to maintain workflow tracking, and NYC Taxicab Commission design briefs detailing official rate codes and geographic boundaries.
- **ES:** Los lineamientos estructurados del marco PACE para mantener el seguimiento del flujo de trabajo, e informes de diseño de la Comisión de Taxis de Nueva York que detallan los códigos de tarifa oficiales y los límites geográficos.



PACE: Execute Stage

- What key insights emerged from your model(s)?

1. Primary Fare Drivers / Predictores Principales de la Tarifa

• Trip Distance dominance / Dominancia de la Distancia:

- **EN:** `trip_distance` emerged as the single most statistically significant predictor. For every additional mile traveled, the baseline fare increases by a predictable, stable margin, confirming that spatial distance remains the core pillar of the pricing structure.
- **ES:** `trip_distance` surgió como el predictor estadísticamente más significativo. Por cada milla adicional recorrida, la tarifa base aumenta en un margen predecible y estable, confirmando que la distancia espacial sigue siendo el pilar central de la estructura de precios.

• The Duration Factor / El Factor Duración:

- **EN:** When time-based metrics (derived from pickup and drop-off datetimes) are introduced, they hold substantial predictive power. Distance alone fails to capture the financial impact of Manhattan gridlock; traffic delays heavily subsidize the final fare through duration coefficients.
- **ES:** Cuando se introducen métricas basadas en el tiempo (derivadas de las horas de inicio y término), estas poseen un poder predictivo sustancial. La distancia por sí sola no logra capturar el impacto financiero del embotellamiento en Manhattan; los retrasos por tráfico subsidian fuertemente la tarifa final a través de los coeficientes de duración.



2. Model Limitations & Anomalies / Limitaciones del Modelo y Anomalías

• Flat-Rate Distortion / Distorsión por Tarifa Plana:

- **EN:** The multiple linear regression model struggles significantly with fixed-fare commutes (such as the standard flat rate between Manhattan and JFK Airport). Because a linear model assumes a continuous increase based on distance, these fixed-price trips create large, clustered residuals (errors).
- **ES:** El modelo de regresión lineal múltiple experimenta dificultades significativas con los viajes de tarifa fija (como la tarifa plana estándar entre Manhattan y el Aeropuerto JFK). Debido a que un modelo lineal asume un aumento continuo basado en la distancia, estos viajes de precio fijo generan residuos (errores) grandes y agrupados.

• The Cash Tip Blindspot / El Punto Ciego de las Propinas en Efectivo:

- **EN:** Evaluating `total_amount` introduces structural bias because the dataset only logs credit card tips. Cash tips are recorded as `$0.0`, meaning the model artificially underestimates the true cost of cash-based transactions, corrupting ordinary least squares (OLS) assumptions if left unadjusted.
- **ES:** Evaluar `total_amount` introduce un sesgo estructural porque el conjunto de datos solo registra propinas con tarjeta de crédito. Las propinas en efectivo se registran como `$0.0`, lo que significa que el modelo subestima artificialmente

el costo real de las transacciones en efectivo, corrompiendo los supuestos de mínimos cuadrados ordinarios (OLS) si no se ajusta.

- What business recommendations do you propose based on the models built?



1. Operational & Pricing Strategy / Estrategia Operativa y de Precios

- **Separate Fare from Tips for Predictive Tools / Separar la Tarifa de las Propinas en Herramientas Predictivas:**

- **EN:** Base all customer-facing fare estimation tools strictly on the `fare_amount` (regulated baseline) rather than `total_amount` to prevent the model from underestimating costs due to the missing cash-tip data.
- **ES:** Basar todas las herramientas de estimación de tarifas de cara al cliente estrictamente en el `fare_amount` (tarifa base regulada) en lugar del `total_amount`, evitando que el modelo subestime costos debido a la falta de datos de propinas en efectivo.

- **Isolate Flat-Rate Airport Corridors / Aislar los Corredores de Tarifa Plana de Aeropuertos:**

- **EN:** Implement a hardcoded, rule-based bypass for known airport pairs (e.g., Manhattan to JFK) instead of relying on the linear model, ensuring absolute price transparency and removing heavy residuals from the core operational pipeline.
- **ES:** Implementar un desvío basado en reglas duras para pares de aeropuertos conocidos (ej. Manhattan a JFK) en lugar de depender del modelo lineal, asegurando una transparencia absoluta de precios y eliminando residuos pesados del pipeline operativo central.



2. Data Engineering & Technical Roadmap / Hoja de Ruta Técnica e Ingeniería de Datos

- **Mandatory Integration of Temporal & Traffic Features / Integración Obligatoria de Variables Temporales y de Tráfico:**

- **EN:** Upgrade the data collection pipeline to natively engineer `trip_duration` and rush-hour temporal flags before the data reaches the inference engine, as distance alone cannot absorb the financial impact of urban gridlock.
- **ES:** Actualizar el pipeline de recolección de datos para generar de forma nativa la `trip_duration` y bloques temporales de hora punta antes de que los datos



lleguen al motor de inferencia, ya que la distancia sola no puede absorber el impacto financiero del embotellamiento urbano.

● **Transition to Tree-Based Ensembles / Transición a Ensamblados Basados en Árboles:**

- **EN:** Shift the machine learning architecture from Multiple Linear Regression to **Random Forest** or **XGBoost** in the next deployment sprint to successfully capture non-linear geographic interactions and handle data outliers without structural distortion.
- **ES:** Migrar la arquitectura de aprendizaje automático de Regresión Lineal Múltiple a **Random Forest** o **XGBoost** en el próximo sprint de despliegue para capturar con éxito las interacciones geográficas no lineales y manejar outliers sin distorsión estructural.

- To interpret model results, why is it important to interpret the beta coefficients?

Quantification of Impact (Direction and Magnitude) / Cuantificación del Impacto (Dirección y Magnitud)

- **EN:** Beta coefficients establish the exact mathematical relationship between a predictor and the target variable. The **sign** (\$+\$ or \$-\$) indicates the direction of the effect, while the **value** quantifies the exact change in the target variable for every single-unit increase in that specific predictor, holding all other variables constant.
- **ES:** Los coeficientes beta establecen la relación matemática exacta entre un predictor y la variable objetivo. El **signo** (\$+\$ o \$-\$) indica la dirección del efecto, mientras que el **valor** cuantifica el cambio exacto en la variable objetivo por cada unidad que aumente ese predictor específico, manteniendo todas las demás variables constantes.
- *Alineación con Automatidata:* Te permite decir con certeza: "Por cada milla adicional de distancia (*trip_distance*), la tarifa base aumenta exactamente en \$X dólares".

2. Feature Importance and Resource Prioritization / Importancia de Variables y Priorización de Recursos

- **EN:** In standardized models, comparing the magnitude of different beta coefficients allows data scientists to rank features by their predictive strength. This helps stakeholders understand which operational levers have the highest ROI or influence over the business outcome.
- **ES:** En modelos estandarizados, comparar la magnitud de los diferentes coeficientes beta permite a los científicos de datos clasificar las variables según su fuerza predictiva.



Esto ayuda a los stakeholders a entender qué palancas operativas tienen el mayor ROI o influencia sobre el resultado del negocio.

- **Alineación con Automatidata:** Te ayuda a demostrarle a Umar Mahmood o Helena Jones si el tráfico (**trip_duration**) tiene más o menos impacto financiero relativo que la distancia bruta contratada.

3. Business Strategy and "What-If" Simulations / Estrategia de Negocio y Simulaciones Causa-Efecto

- **EN:** Interpreting betas shifts the model from a passive forecasting tool to an active decision-making framework. It empowers management to run scenario simulations (e.g., *"If traffic delays increase by 10 minutes due to city construction, how will our fleet's revenue projection scale?"*).
- **ES:** Interpretar las betas transforma el modelo de una herramienta pasiva de pronóstico a un marco activo de toma de decisiones. Permite a la gerencia realizar simulaciones de escenarios (ej. *"Si los retrasos por tráfico aumentan 10 minutos debido a construcciones en la ciudad, ¿cómo escalará nuestra proyección de ingresos?"*).

4. Sanity Checking and Model Debugging / Control de Cordura y Depuración del Modelo

- **EN:** Reviewing coefficients is an essential diagnostic step to detect multicollinearity or data leakage. If a beta coefficient displays an illogical sign (e.g., if a longer trip distance unexpectedly shows a negative fare coefficient), it signals that predictors are highly correlated or corrupted by structural noise, violating ordinary least squares (OLS) assumptions.
- **ES:** Revisar los coeficientes es un paso diagnóstico esencial para detectar multicolinealidad o fuga de datos (*data leakage*). Si un coeficiente beta muestra un signo ilógico (ej. si una distancia de viaje más larga muestra inesperadamente un coeficiente de tarifa negativo), es una señal de que los predictores están altamente correlacionados o corrompidos por ruido estructural, rompiendo los supuestos de mínimos cuadrados ordinarios (OLS).

- What potential recommendations would you make?

1. Operational & Pricing Strategy / Estrategia Operativa y de Precios

- **Target Variable Refinement / Refinamiento de la Variable Objetivo:**



- **EN:** Shift the core predictive target from `total_amount` to `fare_amount` for all future estimation tools. Since cash tips are systematically missing from the dataset (recorded as `$0.0`), predicting the total cost introduces a structural downward bias. Basing tools on the regulated fare baseline ensures customer transparency and protects driver earnings.
- **ES:** Cambiar el objetivo predictivo central de `total_amount` a `fare_amount` para todas las futuras herramientas de estimación. Dado que las propinas en efectivo faltan sistemáticamente en el dataset (registradas como `$0.0`), predecir el costo total introduce un sesgo a la baja. Basar las herramientas en la tarifa base regulada asegura la transparencia para el cliente y protege las ganancias del conductor.

- **Rule-Based Routing for Flat-Rate Corridors / Enrutamiento por Reglas para Corredores de Tarifa Plana:**

- **EN:** Do not rely on the linear model to estimate fares for airport commutes (such as Manhattan-JFK). A linear regression model assumes continuous cost accumulation based on distance, creating severe prediction errors (residuals) when hitting fixed-price structures. Implement a hardcoded, rule-based bypass to override the model for known airport zone pairs.
- **ES:** No depender del modelo lineal para estimar tarifas en trayectos hacia o desde aeropuertos (como Manhattan-JFK). Un modelo de regresión lineal asume una acumulación continua de costo según la distancia, generando severos errores de predicción (residuos) al enfrentarse a estructuras de precio fijo. Implementar un desvío basado en reglas duras para anular el modelo en pares de zonas de aeropuertos conocidos.



2. Data Engineering & Technical Roadmap / Hoja de Ruta Técnica e Ingeniería de Datos

- **Mandatory Temporal & Traffic Feature Engineering / Ingeniería de Variables Temporales y de Tráfico Obligatoria:**

- **EN:** Upgrade the data pipeline to natively calculate `trip_duration` (derived from pickup and drop-off datetimes) and extract rush-hour temporal flags before feeding the model. The model proves that distance alone cannot absorb the financial impact of urban gridlock; traffic delays heavily subsidize the final fare through duration coefficients.
- **ES:** Actualizar el pipeline de datos para calcular de forma nativa la `trip_duration` (derivada de las horas de inicio y término) y extraer bloques temporales de hora punta antes de alimentar al modelo. El modelo demuestra que la distancia sola no puede absorber el impacto financiero del embotellamiento urbano; los retrasos por tráfico subsidian fuertemente la tarifa final a través de los coeficientes de duración.



- **Architecture Transition to Non-Linear Machine Learning / Transición de Arquitectura a Machine Learning No Lineal:**

- **EN:** Propose migrating from Multiple Linear Regression to tree-based ensemble algorithms (**Random Forest Regressor** or **XGBoost**) in the next development sprint. Tree-based models handle non-linear feature interactions (such as the combined effect of specific hours and geographic zones) natively, are completely immune to multicollinearity, and manage extreme urban outliers without breaking statistical assumptions.
- **ES:** Proponer la migración de Regresión Lineal Múltiple a algoritmos de ensamble basados en árboles (**Random Forest Regressor** o **XGBoost**) en el próximo sprint de desarrollo. Los modelos basados en árboles manejan interacciones no lineales de variables (como el efecto combinado de horas específicas y zonas geográficas) de forma nativa, son inmunes a la multicolinealidad y gestionan los outliers urbanos extremos sin romper los supuestos estadísticos.

- Do you think your model could be improved? Why or why not? How?

Why the Model Needs Improvement / ¿Por qué el modelo necesita mejoras?

- **Violation of Linear Assumptions / Violación de Supuestos Lineales:**

- **EN:** The relationship between predictors like time/geography and taxi fares isn't strictly linear. For example, severe traffic jams drop speed drastically but inflate costs exponentially, a pattern that multiple linear regression struggles to map accurately.
- **ES:** La relación entre los predictores como el tiempo/geografía y las tarifas de taxi no es estrictamente lineal. Por ejemplo, el tráfico pesado reduce la velocidad drásticamente pero infla los costos exponencialmente, un patrón difícil de mapear con una regresión lineal.

- **Sensitivity to Extreme Outliers / Sensibilidad a Valores Atípicos Extremos:**

- **EN:** OLS regression minimizes the sum of squared residuals, meaning extreme anomalies (like multi-thousand-dollar data entry errors or zero-distance trips with high costs) disproportionately pull the regression line away from the true operational average.



- **ES:** La regresión OLS minimiza la suma de los residuos al cuadrado, lo que significa que las anomalías extremas (como errores de digitación de miles de dólares o viajes de distancia cero con costos altos) desvían desproporcionadamente la línea de regresión de la media operativa real.

● The Cash Tip Data Blindspot / El Punto Ciego de las Propinas en Efectivo:

- **EN:** Evaluating `total_amount` introduces a structural bias because cash tips are recorded as `$0.0` while credit card tips are logged properly. This creates an artificial skew in the target variable that compromises model integrity.
- **ES:** Evaluar el `total_amount` introduce un sesgo estructural debido a que las propinas en efectivo se registran como `$0.0` mientras que las de tarjetas de crédito se registran correctamente. Esto genera un sesgo artificial en la variable objetivo que compromete la integridad del modelo.



How to Improve It / ¿Cómo mejorarlo?

1. Data Cleansing & Target Optimization / Limpieza de Datos y Optimización del Objetivo

● Target Shift / Cambio de Variable Objetivo:

- **EN:** Change the target variable from `total_amount` to `fare_amount` (the regulated base fare) to bypass the missing cash tip noise completely.
- **ES:** Cambiar la variable objetivo de `total_amount` a `fare_amount` (la tarifa base regulada) para evitar por completo el ruido de las propinas en efectivo faltantes.

● Strict Anomaly Filtering / Filtrado Estricto de Anomalías:

- **EN:** Programmatically drop all rows where `fare_amount` ≥ 0 or where `trip_distance` is zero yet high fees are present, cleaning the training distribution.
- **ES:** Eliminar de forma programática todas las filas donde `fare_amount` ≥ 0 o donde la `trip_distance` sea cero pero existan cobros altos, limpiando la distribución de entrenamiento.

2. Advanced Feature Engineering / Ingeniería de Variables Avanzada

● Trip Duration Extraction / Extracción de Duración del Viaje:

- **EN:** Convert pickup and drop-off timestamp strings into datetime objects to compute total minutes. Traffic delays hold massive predictive weight that distance alone cannot absorb.
- **ES:** Convertir los strings de marcas de tiempo de recogida y destino en objetos datetime para calcular los minutos totales. Los retrasos por tráfico poseen un peso predictivo masivo que la distancia sola no puede absorber.

● Temporal Segmentation / Segmentación Temporal:



- **EN:** Extract features like "Hour of the Day" and "Day of the Week" to build explicit categories for peak demand hours (e.g., *Morning Rush Hour*, *Friday Night*).
- **ES:** Extraer variables como la "Hora del Día" y el "Día de la Semana" para construir categorías explícitas de alta demanda (ej. *Hora Punta Mañana*, *Viernes por la Noche*).

3. Architecture Migration (Tree-Based Machine Learning) / Migración de Arquitectura (Machine Learning Basado en Árboles)

- **Transition to Random Forest or XGBoost / Transición a Random Forest o XGBoost:**

- **EN:** Migrate the pipeline toward non-linear ensemble models like **Random Forest Regressor** or **XGBoost**. These algorithms natively capture non-linear feature interactions (such as specific hours crossing with specific pickup zones), are completely immune to multicollinearity, and handle extreme urban outliers without breaking statistical assumptions.
 - **ES:** Migrar el pipeline hacia modelos de ensamble no lineales como **Random Forest Regressor** o **XGBoost**. Estos algoritmos capturan de forma nativa interacciones no lineales (como horas específicas cruzadas con zonas de recogida particulares), son inmunes a la multicolinealidad y manejan outliers urbanos extremos sin romper los supuestos estadísticos.
- What business/organizational recommendations would you propose based on the models built?



1. Operational & Pricing Strategy / Estrategia Operativa y de Precios

- **Target Variable Refinement / Refinamiento de la Variable Objetivo:**

- **EN:** Base all customer-facing fare estimation tools strictly on the **fare_amount** (the regulated baseline cost) rather than **total_amount**. Because cash tips are systematically missing from the dataset (recorded as **\$0.0**), predicting the total transaction value introduces an artificial downward bias. Focusing predictive tools on the core fare protects driver compensation and ensures accurate upfront pricing for passengers.
- **ES:** Basar todas las herramientas de estimación de tarifas de cara al cliente estrictamente en el **fare_amount** (el costo base regulado) en lugar del **total_amount**. Dado que las propinas en efectivo faltan sistemáticamente en el conjunto de datos (registradas como **\$0.0**), predecir el valor total de la transacción introduce un sesgo a la baja artificial. Enfocar las herramientas



predictivas en la tarifa base protege la compensación del conductor y asegura precios iniciales precisos para los pasajeros.

- **Rule-Based Routing for Flat-Rate Corridors / Enrutamiento por Reglas para Corredores de Tarifa Plana:**

- **EN:** Implement a hardcoded, rule-based bypass to override the regression model for known fixed-price commutes, such as the standard flat rate between Manhattan and JFK Airport. A linear regression model assumes continuous cost accumulation based on distance and time, which generates massive prediction errors (residuals) when applied to fixed-price zone structures.
- **ES:** Implementar un desvío basado en reglas duras para anular el modelo de regresión en trayectos de precio fijo conocidos, como la tarifa plana estándar entre Manhattan y el Aeropuerto JFK. Un modelo de regresión lineal asume una acumulación continua de costos basada en la distancia y el tiempo, lo que genera errores de predicción masivos (residuos) al aplicarse a estructuras de zonas con precios fijos.



2. Data Engineering & Technical Roadmap / Hoja de Ruta Técnica e Ingeniería de Datos

- **Mandatory Integration of Temporal & Traffic Features / Integración Obligatoria de Variables Temporales y de Tráfico:**

- **EN:** Upgrade the data pipeline to natively calculate `trip_duration` (derived from pickup and drop-off timestamps) and extract peak demand temporal flags (e.g., *Morning Rush Hour*, *Weekend Night*) before feeding the model. The model coefficients demonstrate that distance alone cannot absorb the financial impact of urban gridlock; traffic delays heavily subsidize the final fare through duration variables.
- **ES:** Actualizar el pipeline de datos para calcular de forma nativa la `trip_duration` (derivada de las marcas de tiempo de inicio y término) y extraer bloques temporales de alta demanda (ej. *Hora Punta Mañana*, *Noche de Fin de Semana*) antes de alimentar al modelo. Los coeficientes del modelo demuestran que la distancia sola no puede absorber el impacto financiero del embotellamiento urbano; los retrasos por tráfico subsidian fuertemente la tarifa final a través de las variables de duración.

- **Architecture Transition to Non-Linear Machine Learning / Transición de Arquitectura a Machine Learning No Lineal:**

- **EN:** Shift the machine learning infrastructure from Multiple Linear Regression to tree-based ensemble algorithms (**Random Forest Regressor** or **XGBoost**) in the next development sprint. Tree-based models natively capture complex, non-linear feature interactions (such as specific hours crossing with complex geographic boundaries), are completely immune to multicollinearity, and handle extreme urban outliers without breaking statistical assumptions.



- **ES:** Migrar la arquitectura de aprendizaje automático de Regresión Lineal Múltiple a algoritmos de ensamble basados en árboles (**Random Forest Regressor** o **XGBoost**) en el próximo sprint de desarrollo. Los modelos basados en árboles capturan de forma nativa interacciones de variables complejas y no lineales (como horas específicas cruzadas con límites geográficos complejos), son completamente inmunes a la multicolinealidad y gestionan los valores atípicos urbanos extremos sin romper los supuestos estadísticos.

- Given what you know about the data and the models you were using, what other questions could you address for the team?



1. Supply & Demand Optimization / Optimización de Oferta y Demanda

- **Predicting High-Value Trip Influxes / Predicción de Afluencia de Viajes de Alto Valor:**

- **EN:** “Can we predict the exact time blocks and geographic clusters where high-fare or high-tip rides are most likely to originate?” By converting this into a classification or clustering problem, we can help fleet operations dynamically position drivers in premium zones (e.g., business districts right before evening rush hour or airport terminals during specific flight arrival waves), maximizing fleet utility.
- **ES:** “¿Podemos predecir los bloques horarios y clústeres geográficos exactos donde es más probable que se originen viajes de alta tarifa o altas propinas?” Al convertir esto en un problema de clasificación o clustering, podemos ayudar a operaciones a posicionar dinámicamente a los conductores en zonas premium, maximizando la utilidad de la flota.

- **Identifying Fleet Deadhead and Idle Times / Identificación de Tiempos Muertos de la Flota:**

- **EN:** “Which pickup-to-dropoff corridors result in the highest rate of ‘deadheading’ (drivers returning empty without a passenger)?” Analyzing geographic pairs allows the organization to incentivize specific drop-off zones or adjust baseline pricing structures to compensate drivers who are pulled into low-demand urban boundaries.
- **ES:** “¿Qué corredores de origen-destino resultan en la mayor tasa de ‘viajes vacíos’ (conductores que regresan sin pasajeros)?” Analizar pares geográficos permite a la organización incentivar zonas de destino específicas o ajustar

precios base para compensar a los conductores desplazados a zonas de baja demanda.

2. Payment Behavioral Intelligence / Inteligencia de Comportamiento de Pago

• Tipping Predictors and Customer Segmentation / Predictores de Propinas y Segmentación de Clientes:

- **EN:** “What behavioral factors (such as trip duration, specific hours, or location pairs) maximize the probability of receiving a premium credit card tip (*tip_amount*)?” While cash tips remain a data blindspot, modeling credit card tips through logistic regression or tree-based classification can uncover deep behavioral insight into passenger satisfaction profiles and corporate vs. casual rider segments.
- **ES:** “¿Qué factores de comportamiento (como la duración del viaje, horas específicas o pares de ubicaciones) maximizan la probabilidad de recibir una propina premium con tarjeta (*tip_amount*)?” Mientras que las propinas en efectivo son un punto ciego, modelar propinas con tarjeta mediante regresión logística o clasificación basada en árboles puede revelar insights sobre perfiles de satisfacción y segmentos de pasajeros corporativos vs. casuales.

• Payment Method Propensity Forecasting / Pronóstico de Propensión al Método de Pago:

- **EN:** “Can we accurately predict whether a passenger will pay via credit card versus cash based on their pickup location and time?” This helps revenue operations forecast digital transaction fee overheads and assists compliance and security teams in identifying patterns linked to high-volume cash handling.
- **ES:** “¿Podemos predecir con precisión si un pasajero pagará con tarjeta o efectivo basándonos en su ubicación de recogida y la hora?” Esto ayuda a operaciones financieras a pronosticar los costos por comisiones de transacciones digitales y asiste a los equipos de seguridad a identificar patrones vinculados al manejo de efectivo de alto volumen.

3. Operational Risk & Anomalies / Riesgo Operativo y Anomalías

• Algorithmic Fraud and Telemetry Defect Detection / Detección Algorítmica de Fraude y Defectos de Telemetría:

- **EN:** “What systemic features characterize trips that log high fares but record zero miles (*trip_distance == 0.0*)?” Instead of treating these as pure noise to be deleted, we can isolate them into an anomaly detection sub-pipeline to



identify manual rate-code overrides by drivers, software bugs in taximeters, or potential billing fraud.

- **ES:** “¿Qué características sistémicas definen a los viajes que registran tarifas altas pero marcan cero millas (`trip_distance == 0.0`)?” En lugar de tratarlos como puro ruido a eliminar, podemos aislarlos en un sub-pipeline de detección de anomalías para identificar alteraciones manuales de tarifas por conductores, bugs de software en taxímetros o fraudes potenciales de facturación.

- **Macro-Traffic Congestion Impact Mapping / Mapeo del Impacto Macro de la Congestión Urbana:**

- **EN:** “How severely does urban gridlock decelerate average trip velocity across different seasons or days of the week, and what is its net financial cost to fleet efficiency?” By tracking the divergence between distance and time-to-destination over a temporal timeline, we can provide the Corporate Taxicab Commission with hard data to negotiate city toll policies or adjust rush-hour surcharges.
- **ES:** “¿Con qué gravedad reduce el embotellamiento urbano la velocidad promedio de los viajes según temporadas o días de la semana, y cuál es su costo financiero neto en la eficiencia de la flota?” Al rastrear la divergencia entre distancia y tiempo de destino a lo largo de una línea temporal, podemos proveer a la Comisión de Taxis datos duros para negociar políticas de peajes urbanos o ajustar recargos por hora punta.

- Do you have any ethical considerations at this stage?



1. Socioeconomic Equity & Algorithmic Fairness / Equidad Socioeconómica y Imparcialidad Algorítmica

- **Geographic Price Discrimination / Discriminación Geográfica de Precios:**

- **EN:** Over-indexing on geographic coordinates (such as pickup or drop-off zone IDs) can lead to unintentional algorithmic bias. If the model learns that rides to specific lower-income or marginalized neighborhoods consistently yield lower tips or longer delays, it could skew pricing upward or disincentivize drivers from serving those areas. This can restrict accessible transportation options for vulnerable populations.



- **ES:** Indexar en exceso coordenadas geográficas (como IDs de zonas de recogida o destino) puede generar sesgos algorítmicos no intencionados. Si el modelo aprende que los viajes a vecindarios específicos de menores ingresos o marginados resultan en menores propinas o mayores retrasos, podría inflar los precios o desincentivar a los conductores de atender esas áreas, restringiendo las opciones de transporte para poblaciones vulnerables.

● **Impact on Driver Livelihoods / Impacto en el Sustento de los Conductores:**

- **EN:** Predictive tools must balance passenger affordability with fair driver compensation. If the model relies heavily on corrupted metrics—such as underreporting total earnings due to missing cash tip records—it risks setting baseline pricing structures too low, directly harming the livelihood of the workforce relying on the platform.
- **ES:** Las herramientas predictivas deben equilibrar la accesibilidad para el pasajero con una compensación justa para el conductor. Si el modelo depende de métricas corrompidas (como el subreporte de ingresos debido a la falta de registro de propinas en efectivo), corre el riesgo de establecer estructuras de precios base demasiado bajas, dañando directamente el sustento de la fuerza laboral.



2. Data Privacy & Passenger Anonymization / Privacidad de Datos y Anonimización de Pasajeros

● **Re-identification Risks via Spatiotemporal Data / Riesgos de Re-identificación por Datos Espaciotemporales:**

- **EN:** Even when explicit personal identifiers (names, credit card numbers) are removed, spatiotemporal data remains highly unique. Combining precise pickup and drop-off location IDs with exact minute-level timestamps creates a data signature that can easily leak an individual's private routines, daily commutes, or workplace locations, violating core user privacy frameworks.
- **ES:** Incluso cuando se eliminan los identificadores personales explícitos (nombres, números de tarjeta), los datos espaciotemporales siguen siendo únicos. Combinar IDs precisos de origen/destino con marcas de tiempo detalladas al minuto crea una firma de datos que puede revelar rutinas privadas, traslados diarios o lugares de trabajo, vulnerando los marcos de privacidad del usuario.

● **Data Governance and Purpose Limitation / Gobernanza de Datos y Limitación de Propósito:**

- **EN:** As data professionals, the team must ensure that data collected strictly for municipal fleet logistics and fare estimation is not repurposed or sold for invasive behavioral advertising or external surveillance profiling without explicit user consent.



- **ES:** Como profesionales de datos, el equipo debe garantizar que los datos recopilados estrictamente para la logística de la flota municipal y la estimación de tarifas no se reutilicen ni se vendan para publicidad conductual invasiva o perfiles de vigilancia externa sin el consentimiento explícito del usuario.