T+
Executive Report: Taxi Fare Data Preparation

Project: Automatidata | Client: New York City Taxi & Limousine Commission (TLC)
PACE Phase: Analyze (Data Preparation and Structuring)

Business Context/ Contexto de Negocio

- EN: The TLC oversees 200,000+ vehicles and 1 million daily trips. The challenge is transforming this massive dataset into fare transparency tools.
- ES: La TLC supervisa más de 200,000 vehículos y 1 millón de viajes diarios. El desafío es transformar este volumen de datos en herramientas de transparencia tarifaria.

Project Overview / Visión General del Proyecto

- EN: Goal: Build a fare estimation model. EDA revealed critical anomalies (e.g., 0-mile trips) that require data cleaning for model accuracy.
- ES: Objetivo: Crear un modelo de estimación de tarifas. El EDA reveló anomalías (ej. viajes de 0 millas) que requieren limpieza para asegurar la precisión.

Business Questions/ Preguntas de Negocio

- Relationship between distance and fare? / ¿Relación entre distancia y tarifa?
- Variations by time or day? / ¿Variaciones por hora o día?
- Impact of geographic zones? / ¿Impacto de las zonas geográficas?

T+
Executive Report: Taxi Fare Data Preparation

Project: Automatidata | Client: New York City Taxi & Limousine Commission (TLC)
PACE Phase: Analyze (Data Preparation and Structuring)

Data Cleaning & Exploration / Exploración y Limpieza de Datos
PACE Phase: Analyze (Data Cleaning & Exploration)

Dataset Dimensions / Dimensiones del Dataset

- EN: Analysis of 22,699 unique trips with 18 features, providing a statistically significant sample for fare modeling.
- ES: Análisis de 22,699 viajes únicos con 18 variables, proporcionando una muestra estadísticamente significativa para el modelado de tarifas

```
# Check the shape (number of rows and columns) of the dataset
# Revisar la forma (número de filas y columnas) del conjunto de datos
print("Dataset size (rows, columns):", df.shape)

# Alternative: Check the total number of elements
# Alternativa: Revisar el número total de elementos
print("Total number of cells:", df.size)
```

```
Dataset size (rows, columns): (22699, 18)
```

Observaciones Directas / Direct Observations

Payment & Tips / Pagos y Propinas

- EN: Discovered a correlation between payment type and recorded tips; cash payments show $0 tips, indicating a data recording limitation.
- ES: Se descubrió una correlación entre el tipo de pago y las propinas registradas; los pagos en efectivo muestran $0 de propina, indicando una limitación en el registro de datos.

payment_type	tip_amount
1	2.76
1	4.00
1	1.45
1	6.39
2	0.00
1	2.06
1	9.86
1	1.78
2	0.00
1	2.75

Fare Composition / Composición de la Tarifa

- EN: Verified that the total fare is a sum of six distinct components, identifying 'fare_amount' as the primary target for predictive modeling.
- ES: Se verificó que la tarifa total es la suma de seis componentes distintos, identificando 'fare_amount' como el objetivo principal para el modelo predictivo.

fare_amount	extra	mta_tax	tip_amount	tolls_amount	improvement_surcharge	total_amount
13.0	0.0	0.5	2.76	0.0	0.3	16.56
16.0	0.0	0.5	4.00	0.0	0.3	20.80
6.5	0.0	0.5	1.45	0.0	0.3	8.75
20.5	0.0	0.5	6.39	0.0	0.3	27.69
16.5	0.5	0.5	0.00	0.0	0.3	17.80
9.0	0.5	0.5	2.06	0.0	0.3	12.36
47.5	1.0	0.5	9.86	0.0	0.3	59.16
16.0	1.0	0.5	1.78	0.0	0.3	19.58
9.0	0.0	0.5	0.00	0.0	0.3	9.80
13.0	0.0	0.5	2.75	0.0	0.3	16.55

T+
Executive Report: Taxi Fare Data Preparation

Project: Automatidata | Client: New York City Taxi & Limousine Commission (TLC)
PACE Phase: Analyze (Data Preparation and Structuring)

Data Cleaning & Exploration / Exploración y Limpieza de Datos
PACE Phase: Analyze (Data Cleaning & Exploration)

Statistical Insights & Data Cleaning

Handling Anomalies / Manejo de Anomalías

Extreme Value Detection / Detección de Valores Extremos

- Identified negative fare values (min: -$120) and maximum outliers of $999.90.
- Se identificaron valores de tarifa negativos (mín: -$120) y valores atípicos máximos de $999.90.

	fare_amount
count	22.699.000.000
mean	13.026.629
std	13.243.791
min	-120.000.000
25%	6.500.000
50%	9.500.000
75%	14.500.000
max	999.990.000

- Observation: Trips with 0 distance but associated costs were detected. A business review is recommended to determine if these are cancellations or sensor errors before proceeding with removal.
- Observación: Se detectaron viajes con distancia 0 pero con costos asociados. Se recomienda una revisión con el área de negocio para determinar si corresponden a cancelaciones o errores de sensor antes de su depuración.

Percentile Analysis / Análisis de Percentiles

Significant Distribution Skew / Sesgo Significativo en la Distribución

- The median trip distance is 1.61 miles, while the 75th percentile is only 3.06 miles. The jump to a 33.96-mile maximum confirms that long-distance trips are statistical outliers.
- La distancia mediana es de 1.61 millas, mientras que el percentil 75 es de solo 3.06 millas. El salto hacia un máximo de 33.96 millas confirma que los viajes de larga distancia son valores atípicos estadísticos.

	trip_distance	total_amount
count	22.699.000.000	22.699.000.000
mean	2.913.313	16.310.502
std	3.653.171	16.097.295
min	0.000000	-120.300.000
25%	0.990000	8.750.000
50%	1.610.000	11.800.000
75%	3.060.000	17.800.000
max	33.960.000	1.200.290.000

Highlight de Percentiles

- EN: Data Concentration: 75% of all trips cost less than $17.80, highlighting that the $1,200 maximum is a high-leverage outlier that represents less than 1% of the data.
- ES: Concentración de Datos: El 75% de los viajes cuestan menos de $17.80, resaltando que el máximo de $1,200 es un valor atípico de alto impacto que representa menos del 1% de los datos.

T+
Executive Report: Taxi Fare Data Preparation

Project: Automatidata | Client: New York City Taxi & Limousine Commission (TLC)
PACE Phase: Feature Engineering: Construct Phase

Data Cleaning & Exploration / Exploración y Limpieza de Datos
PACE Phase: Feature Engineering: Construct Phase

Deriving Temporal Insights / Derivación de Hallazgos Temporales

- EN: Converted date columns from text format to temporal format (datetime) and engineered a new metric: trip_duration (in minutes).
- This allows the model to account for traffic-related time costs, distinguishing between physical distance and urban congestion.
- ES: Se convirtieron las columnas de fecha de formato de texto a formato temporal (datetime) y se creó una nueva métrica: trip_duration (en minutos).
- Esto permite que el modelo considere los costos de tiempo relacionados con el tráfico, diferenciando entre la distancia física y la congestión urbana.

```
# Convert data columns to datetime
#==> ENTER YOUR CODE HERE
# Convert data columns to datetime
# Convertir las columnas de datos a formato datetime
df['tpep_pickup_datetime'] = pd.to_datetime(df['tpep_pickup_datetime'])
df['tpep_dropoff_datetime'] = pd.to_datetime(df['tpep_dropoff_datetime'])

# Derive 'trip_duration' column (in minutes)
# Crear la columna 'trip_duration' (en minutos)
df['trip_duration'] = (df['tpep_dropoff_datetime'] - df['tpep_pickup_datetime']).dt.total_seconds(

# Check the first few rows to confirm
# Revisar las primeras filas para confirmar
df[['tpep_pickup_datetime', 'tpep_dropoff_datetime', 'trip_duration']].head()
```

	tpep_pickup_datetime	tpep_dropoff_datetime	trip_duration
0	2017-03-25 08:55:43	2017-03-25 09:09:47	14.066667
1	2017-04-11 14:53:28	2017-04-11 15:19:58	26.500000
2	2017-12-15 07:26:56	2017-12-15 07:34:08	7.200000
3	2017-05-07 13:17:59	2017-05-07 13:48:14	30.250000
4	2017-04-15 23:32:20	2017-04-15 23:49:03	16.716667

Data Readiness / Preparación de Datos

- EN: The transformation ensures that pickup and dropoff times are mathematically operational, setting the stage for analyzing peak-hour pricing.
- ES: La transformación asegura que las horas de recogida y llegada sean matemáticamente operativas, preparando el terreno para analizar precios en horas pico.

Strategic Insight: The Business Value of trip_duration

- Capturing the "Traffic Factor"
  - While trip_distance measures physical space, trip_duration captures the impact of New York City traffic. A 2-mile trip during rush hour can be costlier in terms of time and resources than a 5-mile trip at midnight. Including this variable allows the model to differentiate between distance-based costs and time-based congestion.
- Capturando el "Factor Tráfico"
  - Mientras que trip_distance mide el espacio físico, trip_duration captura el impacto del tráfico en NYC. Un viaje de 2 millas en hora pico puede ser más costoso en tiempo y recursos que uno de 5 millas a medianoche. Incluir esta variable permite al modelo diferenciar entre costos por distancia y congestión por tiempo.

T+
Executive Report: Taxi Fare Data Preparation

Project: Automatidata | Client: New York City Taxi & Limousine Commission (TLC)
PACE Phase: Feature Engineering: Construct Phase

Data Cleaning & Exploration / Exploración y Limpieza de Datos
PACE Phase: Feature Engineering: Construct Phase

Visual Evidence of Extreme Outliers / Evidencia Visual de Valores Atípicos

- EN: Boxplots confirm extreme dispersion in both distance and duration. Specifically, trip_duration shows entries near 1,400 minutes, which are likely system errors or unclosed trips that must be removed.
- ES: Los diagramas de caja confirman una dispersión extrema tanto en distancia como en duración. Específicamente, trip_duration muestra registros cercanos a los 1,400 minutos, probablemente errores de sistema o viajes no cerrados que deben eliminarse.

Data Concentration / Concentración de Datos

- EN: The compact nature of the boxes highlights that the vast majority of taxi activity occurs within very narrow ranges (under 5 miles and 30 minutes).
- ES: La naturaleza compacta de las cajas resalta que la gran mayoría de la actividad de los taxis ocurre en rangos muy estrechos (menos de 5 millas y 30 minutos).

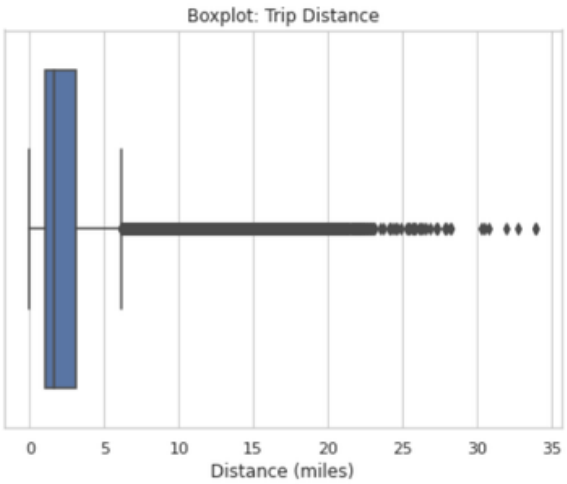

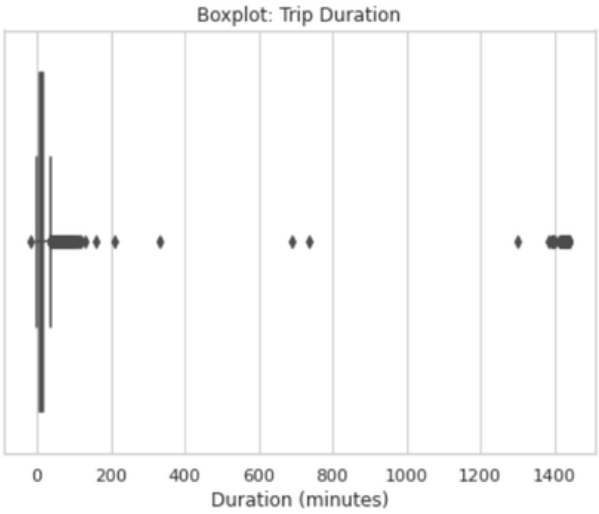

T+
Executive Report: Taxi Fare Data Preparation

Project: Automatidata | Client: New York City Taxi & Limousine Commission (TLC)
PACE Phase: Feature Engineering: Construct Phase

Data Cleaning & Exploration / Exploración y Limpieza de Datos
PACE Phase: Feature Engineering: Construct Phase

Trip Distance Distribution

Operational Volume Analysis

- The histogram reveals a high concentration of trips between 1 and 2 miles. This "right-skewed" distribution indicates that NYC taxi operations are primarily focused on short-distance urban mobility.

Análisis de Volumen Operativo

- El histograma revela una alta concentración de viajes entre 1 y 2 millas. Esta distribución con sesgo a la derecha indica que las operaciones de taxi en NYC se centran principalmente en la movilidad urbana de corta distancia.

Model Impact

- Predictive accuracy in the 0-5 mile range is essential, as it represents the bulk of the revenue and service frequency.

Impacto en el Modelo

- La precisión predictiva en el rango de 0 a 5 millas es esencial, ya que representa la mayor parte de los ingresos y la frecuencia del servicio.

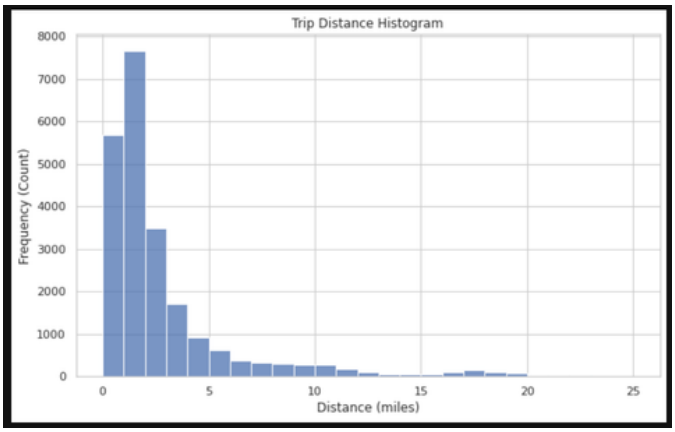

Market Dynamics: The "Long Tail" Effect

- Market Segments
  - The distribution shows a "Long Tail" starting after 5 miles. While the volume is low, it remains constant up to 25 miles. This represents a distinct high-value segment, likely associated with inter-borough trips or airport transfers.
- Segmentos de Mercado
  - La distribución muestra una "Larga Cola" a partir de las 5 millas. Aunque el volumen es bajo, se mantiene constante hasta las 25 millas. Esto representa un segmento de alto valor diferenciado, probablemente asociado con viajes entre distritos o traslados a aeropuertos.

T+
Executive Report: Taxi Fare Data Preparation

Project: Automatidata | Client: New York City Taxi & Limousine Commission (TLC)
PACE Phase: Feature Engineering: Construct Phase

Data Cleaning & Exploration / Exploración y Limpieza de Datos
PACE Phase: Feature Engineering: Construct Phase

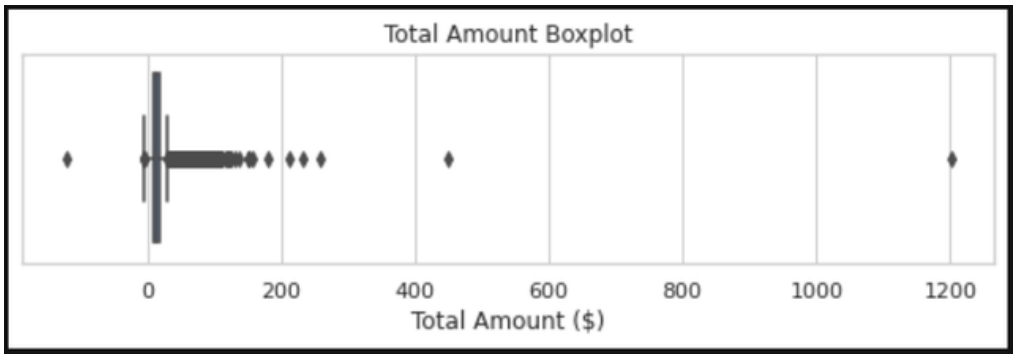

Financial Integrity: Total Amount Analysis

- **Extreme Economic Outliers / Detección de Valores Extremos**
  - EN: A massive outlier of $1,200 was identified. Much like the 1,400-minute trip duration, this value is a critical anomaly that could bias fare prediction models if not investigated or removed.
  - ES: Se observó un punto masivo de $1,200. Al igual que la duración de 1,400 minutos, este valor es una anomalía crítica que podría sesgar los modelos de predicción de tarifas si no se investiga o elimina.

- **Negative Fare Detection / Presencia de Valores Negativos**
- EN: The boxplot reveals negative values near -$120. Since negative fares lack commercial sense, this confirms the need for deep cleaning to remove system errors or non-operational records.
- ES: El boxplot revela valores negativos cercanos a -$120. Dado que las tarifas negativas no tienen sentido comercial, esto confirma la necesidad de una limpieza profunda para eliminar errores de sistema o registros no operativos.

- **Economic "Long Tail" / Visualización de la "Larga Cola"**
- EN: There is a constant density of points between $100 and $300, followed by high-impact values at $450 and $1,200. This confirms the "Long Tail" theory: a massive volume of small urban fares versus a niche high-impact segment.
- ES: Hay una densidad constante de puntos entre $100 y $300, seguidos de valores de alto impacto en $450 y $1,200. Esto confirma la teoría de la "Larga Cola": un volumen masivo de tarifas urbanas pequeñas frente a un segmento de nicho de alto impacto.

T+
Executive Report: Taxi Fare Data Preparation

Project: Automatidata | Client: New York City Taxi & Limousine Commission (TLC)
PACE Phase: Feature Engineering: Construct Phase

Data Cleaning & Exploration / Exploración y Limpieza de Datos
PACE Phase: Feature Engineering: Construct Phase

EN: Passenger Load Distribution

- Single-Passenger Dominance: Nearly 70% of trips involve a single passenger, highlighting that NYC taxi usage is primarily individual.
- Group Travel Capacity: Significant volume in 5-6 passenger segments suggests a consistent demand for larger vehicle types (SUVs/Vans).
-
- Data Integrity: Identified 33 records with "0 passengers," which will be flagged for removal during the Execute phase to maintain model purity.

```
#==> ENTER YOUR CODE HERE
# Examine the unique values in the passenger_count column
# Examinar los valores únicos en la columna passenger_count
df['passenger_count'].value_counts()
```

```
1    16117
2     3305
5     1143
3      953
6      693
4      455
0       33
Name: passenger_count, dtype: int64
```

- ES: Distribución de Carga de Pasajeros
- Dominio de Pasajero Único: Cerca del 70% de los viajes involucran a un solo pasajero, resaltando que el uso de taxis en NYC es principalmente individual.
- Capacidad de Viajes en Grupo: El volumen significativo en los segmentos de 5-6 pasajeros sugiere una demanda constante de vehículos grandes (SUVs/Vans).
- Integridad de Datos: Se identificaron 33 registros con "0 pasajeros", los cuales serán marcados para eliminación durante la fase de Ejecución para mantener la pureza del modelo.
- EN: Fare consistency across all passenger counts confirms that distance and time are the primary price drivers, not group size. The presence of revenue in "0 passenger" trips reinforces the need for data sanitization.
- ES: La consistencia de la tarifa en todos los niveles de pasajeros confirma que la distancia y el tiempo son los principales motores del precio, no el tamaño del grupo. Los ingresos en viajes de "0 pasajeros" refuerzan la necesidad de saneamiento de datos.

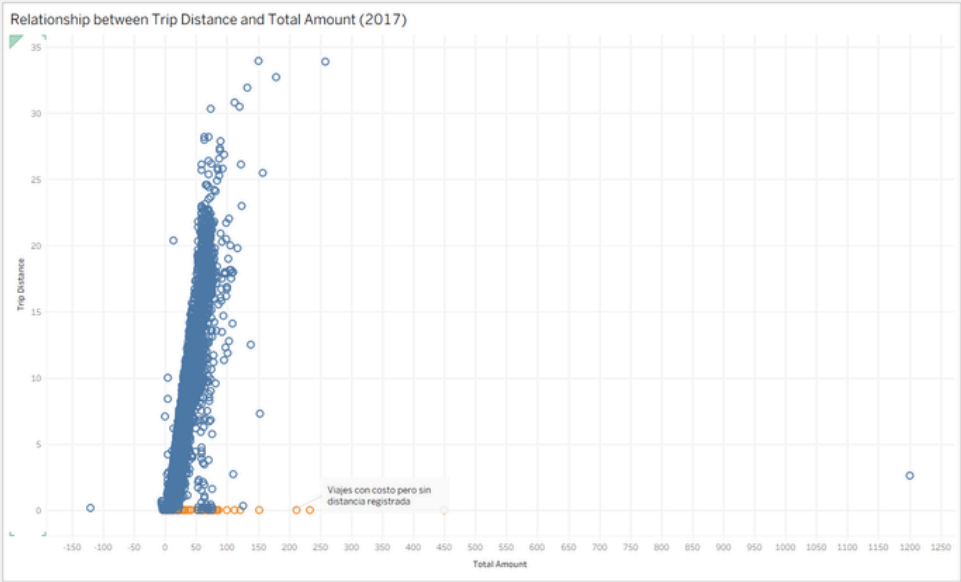

T+
Executive Report: Taxi Fare Data Preparation

Project: Automatidata | Client: New York City Taxi & Limousine Commission (TLC)
PACE Phase: Feature Engineering: Construct Phase

Data Cleaning & Exploration / Exploración y Limpieza de Datos
PACE Phase: Feature Engineering: Construct Phase

Executive Summary & Next Steps / Resumen Ejecutivo y Próximos Pasos

EN: Project Readiness

The dataset has been successfully audited and enriched. By implementing the "Traffic Factor" through trip_duration and defining clear sanitization rules for outliers and financial anomalies, the data is now robust and ready for the modeling phase.

ES: Preparación del Proyecto

El conjunto de datos ha sido auditado y enriquecido con éxito. Al implementar el "Factor Tráfico" mediante trip_duration y definir reglas claras de saneamiento para valores atípicos y anomalías financieras, los datos ahora son robustos y están listos para la fase de modelado.

Rule 1: Logical Minimums / Mínimos Lógicos

- ES: Eliminar registros con passenger_count == 0 y total_amount <= 0. Un viaje real requiere al menos un pasajero y un ingreso positivo.
- EN: Remove records with passenger_count == 0 and total_amount <= 0. A valid trip requires at least one passenger and a positive fare.

Rule 2: Outlier Cap / Límite de Valores Atípicos

- ES: Filtrar duraciones superiores a 3 horas (180 min) y montos superiores a $500 para proteger la estabilidad del modelo contra errores de sistema.
- EN: Filter durations exceeding 3 hours (180 min) and amounts over $500 to protect model stability against system errors.

Rule 3: Feature Readiness / Preparación de Variables

- ES: Utilizar la nueva columna trip_duration como predictor principal junto con la distancia, integrando el "Factor Tráfico" en el algoritmo.
- EN: Use the new trip_duration column as a primary predictor alongside distance, integrating the "Traffic Factor" into the algorithm.